



inaoe

**Extracción de Características y
Clasificación de Señales Electromiográficas
Utilizando la Transformada Hilbert-Huang y
Redes Neuronales**

Por

Ing. Irving Aaron Cifuentes González

Tesis Sometida como requisito parcial para
obtener el grado de **Maestro en ciencias en la
especialidad de Electrónica** en el Instituto
Nacional de Astrofísica, Óptica y Electrónica,
(INAOE).

Asesores:

Dr. Juan Manuel Ramírez Cortés

Dr. Rubén Alejos Palomares

©INAOE 2012

El autor otorga al INAOE el permiso de
reproducir copias totales o parciales de es tesis



Resumen

En este trabajo se presentan dos métodos basados en Redes Neuronales para su uso futuro en el control de una prótesis transfemoral. El primer método se basa en el reconocimiento de patrones en las señales de EMG para la identificación de 3 movimientos. Se propone un nuevo vector de características basado en la transformada Hilbert-Huang y se incluye el diseño y construcción de un prototipo para la adquisición de señales de Electromiografía. El segundo método consiste en realizar una estimación de posición y velocidad angular. En esta última estrategia se consideran dos problemas inherentes en la adquisición de las señales de EMG: el retraso electromecánico y la fatiga muscular. Varios resultados de estimación de posición y velocidad angular bajo condiciones con y sin fatiga muscular son presentados. Se observó un incremento en el error de estimación durante el análisis de los datos que presentaban fatiga muscular, así como también, un incremento en el retraso electromecánico. Este método fue desarrollado en colaboración de la Universidad de Roma TRE como parte de una corta estancia de investigación.

Abstract

In this work two new strategies based on Neural Networks are presented; the first one consists in the development of one system for pattern recognition of legs movements with the introduction of a new feature vector based on the Hilbert-Huang Transform. The development and the construction of one prototype for Electromyographic signals acquisition with four channels is presented. The second method is based on the estimation of the angular position and the angular velocity. In this method, the electromechanical delay and the muscular fatigue were considered. The results showed an increase at the estimation error on presence of muscular fatigue. The electromechanical delay, as well, has showed an increase under muscular fatigue conditions. This method was developed with the collaboration of the Roma TRE University as result of one research stay.

Tabla de Contenido

Resumen	2
Abstract.....	3
Tabla de Contenido.....	4
Lista de Figuras	6
Lista de Tablas.....	10
Capítulo 1: Introducción	11
1.1 Motivación	11
1.2 Justificación.....	11
1.3 Antecedentes.....	14
1.3.1 Control mioeléctrico.....	15
1.4 Objetivo General.....	15
1.5 Objetivos particulares	15
1.6 Organización de la Tesis	16
Capítulo 2: Marco Teórico	17
2.1 Introducción.....	17
2.2 Electromiografía.....	19
2.3 Localización de los electrodos, forma, tamaño, distancia inter-electrodo y material.	22
2.4 Sistemas de control mioeléctrico basados en reconocimiento de patrones.....	26
2.4.1 Adquisición y segmentación de datos.....	26
2.4.2 Extracción de características	31
2.4.3 Clasificación.....	44
Capítulo 3: Desarrollo	48
3.1 Introducción.....	48
3.2 Método I: Reconocimiento de patrones en señales de EMG.....	48
3.2.1 Etapa de Adquisición de la señal de EMG.....	52
3.2.2 Segmentación y extracción de características.....	61
3.2.3 Materiales y métodos	62
3.2.4 Clasificación	65

3.3 Método II: Estimación del ángulo y velocidad durante la flexión y la extensión de la pierna.....	65
3.3.1 Materiales y Métodos	66
3.3.2 Extracción de características	71
3.3.3 Clasificación	72
Capítulo 4: Resultados.....	74
4.1 Introducción.....	74
4.2 Método I: Reconocimiento de patrones en señales de EMG.....	74
4.2.1 Hardware de Adquisición de señales de EMG	74
4.2.2 Extracción de Características	92
4.2.3 Clasificación	93
4.3 Método II: Estimación de ángulo y velocidad durante la flexión y extensión de la pierna.....	96
Capítulo 5: Conclusiones	111
5.1 Conclusiones	111
5.2 Trabajo Futuro.....	113

Lista de Figuras

Figura 1-1. Población con algún tipo de discapacidad, México, 2010.....	12
Figura 1-2. Distribución porcentual de la población con discapacidad por tipo de limitación (Puebla 2010).	13
Figura 1-3. Prótesis Transfemoral.....	14
Figura 2-1. Esquema representativo del mecanismo básico de control y de los componentes de la UM. [6]	18
Figura 2-2. Espectro de frecuencia de las señales de EMG. [6]	19
Figura 2-3. Resultados de un inventario en el que se hace uso de sensores para sEMG en laboratorios europeos obtenidos escaneando 6 volúmenes de revistas (1991-1997). a) Histograma del diámetro del electrodo. b) Histograma de la distancia inter-electrodo [6].	22
Figura 2-4. Localización de los electrodos de aguja y superficiales (parte frontal del cuerpo) [10].....	24
Figura 2-5. Localización de los electrodos de aguja y superficiales (parte posterior del cuerpo) [10].....	25
Figura 2-6. Sistemas de control mioeléctrico basados en reconocimiento de patrones [3].	26
Figura 2-7. Representación esquemática del espectro de potencia de la señal de EMG. El área sombreada indica la perdida de la señal cuando el filtro <i>notch</i> es usado para rechazar frecuencias 50-60Hz. [11].	29
Figura 2-8. Segmentación adyacente disjunta [13].....	30
Figura 2-9. Segmentación superpuesta [13].....	30
Figura 2-10. Árbol de descomposición Wavelet para el cálculo de los coeficientes de aproximación (<i>CAi</i>) y detalle (<i>CDi</i>) y Lp and Hp hacen referencia a los filtros pasa-bajas y pasa-altas respectivamente.	39
Figura 2-11. Espectro Hilbert-Huang con actividad de EMG.	42
Figura 2-12. Espectro Hilbert-Huang sin actividad de EMG.	43
Figura 2-13. Método para la obtención de la frecuencia cuya amplitud es máxima.....	43
Figura 2-14. Neurona artificial [13].	45
Figura 2-15. Red neuronal con una capa de entrada, una capa oculta y una capa de salida [13].	46
Figura 3-1. Diagrama de las etapas del sistema de adquisición y clasificación de señales de EMG.	49
Figura 3-2. Diagrama de las etapas del sistema de adquisición y clasificación de señales de EMG [54].....	51
Figura 3-3. Diagrama esquemático de la etapa de adquisición de señales de EMG.	52
Figura 3-4.Circuito de EMG de un solo canal.....	53
Figura 3-5. Diagrama esquemático de la etapa de alimentación y Tierra virtual.....	54
Figura 3-6.Circuito de RLD [55].....	55
Figura 3-7.Filtro pasa bandas (20-500Hz).....	57
Figura 3-8.Circuito promediador para el electrodo de referencia.....	58
Figura 3-9.Interfaz de usuario usada para la selección de los patrones de EMG.	59

Figura 3-10. Selección del segmento temporal y la frecuencia con la que han sido adquiridos los datos.....	59
Figura 3-11. Parámetros del filtro Butterworth.....	60
Figura 3-12.Opciones para visualizar el espectro de Fourier y el espectro Hilbert-Huang.	60
Figura 3-13. Construcción de vectores de características.....	61
Figura 3-14. Tres clases de movimiento para el experimento.	63
Figura 3-15. Método para la adquisición y clasificación de las señales de EMG	64
Figura 3-16. Diagrama de bloques del método propuesto para la estimación del ángulo y la velocidad. . x_i corresponde a la muestra de la señal de sEMG en el tiempo i y $y(i + 50)$ corresponde a la posición angular 50ms después del tiempo i	66
Figura 3-17. Experimento de extensión y flexión de la pierna usando la máquina de extensión de piernas.....	68
Figura 3-18. Localización de los electrodos de superficie.	69
Figura 3-19. Posicionamiento de los electrodos del sistema BTS FreeEMG.....	69
Figura 3-20. Localización del electro goniómetro.	70
Figura 3-21. Posición angular medida por el electrogoniómetro.....	70
Figura 3-22. Estructura de la red neuronal. Se han usado la posición θ y la velocidad angular $\dot{\theta}$ como salida de entrenamiento para la Red Neuronal.....	73
Figura 4-1.Circuito impreso para la adquisición de las señales de EMG.....	75
Figura 4-2. Espectro de frecuencia de un registro de EMG.....	77
Figura 4-5. Registro simultáneo de los 4 canales de sEMG, movimiento de Flexión.....	79
Figura 4-6. Campo magnético recolectado por los cables de adquisición. a) Los cables conductores forman un lazo cerrado (área sombreada) donde el paciente y el dispositivo electrónico son considerados en el circuito. El cambio en el campo magnético que pasa a través de esta área induce una corriente en el lazo. b) Este efecto puede ser minimizado entrelazando los cables y manteniéndolo cerca del cuerpo para reducir el área que se forma entre ellos [51].	80
Figura 4-7.Espectro de Fourier para los 4 canales de sEMG, movimiento de Dorsiflexión.	81
Figura 4-8.Espectro de Fourier para los 4 canales de sEMG, movimiento de Extensión..	82
Figura 4-9.Espectro de Fourier para los 4 canales de sEMG, movimiento de Flexión.....	82
Figura 4-10. Espectro Hilbert-Huang de la señal $y = \sin 60t + \sin (20t)$. El espectro muestra los dos componentes de frecuencia localizados en los 20 y 60Hz, lo que corresponde con la señal de prueba.	84
Figura 4-11. Descomposición Modal Empírica de un registro de sEMG en 6 componentes o IMFs.....	85
Figura 4-12. Espectro Hilbert de las señales de sEMG provenientes del <i>Vastus Medialis</i> durante el movimiento de Dorsiflexión.	86
Figura 4-13. Espectro Hilbert de las señales de sEMG provenientes del <i>Semimembranosus</i> durante el movimiento de Dorsiflexión.	86
Figura 4-14. Espectro Hilbert de las señales de sEMG provenientes del <i>Vastus Lateralis</i> durante el movimiento de Dorsiflexión.	87
Figura 4-15. Espectro Hilbert de las señales de sEMG provenientes del <i>Biceps Femoris</i> durante el movimiento de Dorsiflexión.	87

Figura 4-16. Espectro Hilbert de las señales de sEMG provenientes del <i>Vastus Medialis</i> durante el movimiento de Extensión	88
Figura 4-17. Espectro Hilbert de las señales de sEMG provenientes del <i>Semimembranosus</i> durante el movimiento de Extensión.....	88
Figura 4-18. Espectro Hilbert de las señales de sEMG provenientes del <i>Vastus Lateralis</i> durante el movimiento de Extensión	89
Figura 4-19. Espectro Hilbert de las señales de sEMG provenientes del <i>Biceps Femoris</i> durante el movimiento de Extensión	89
Figura 4-20. Espectro Hilbert de las señales de sEMG provenientes del <i>Vastus Medialis</i> durante el movimiento de Flexión.	90
Figura 4-21. Espectro Hilbert de las señales de sEMG provenientes del <i>Semimembranosus</i> durante el movimiento de Flexión.	90
Figura 4-22. Espectro Hilbert de las señales de sEMG provenientes del <i>Vastus Lateralis</i> durante el movimiento de Flexión.	91
Figura 4-23. Espectro Hilbert de las señales de sEMG provenientes del <i>Biceps Femoris</i> durante el movimiento de Flexión.	91
Figura 4-24. Porcentaje de clasificación (promedio sobre 10 entrenamientos de la Red Neuronal). Para N número de neuronas en la capa oculta (A). Para 2N número de neuronas (B) y para cada ventana temporal (100 y 250 ms) respectivamente.....	95
Figura 4-25. Registros de sEMG correspondientes a las flexiones isométricas.....	97
Figura 4-26. Registros de sEMG correspondientes a las flexiones dinámicas.....	97
Figura 4-26. Espectro de Fourier de la señal de sEMG filtrada y normalizada del músculo <i>Rectus Femoris</i> durante una extensión isométrica de pierna a) sin fatiga muscular, b) con fatiga muscular. Es posible observar cómo se presenta la comprensión del espectro de frecuencia y el cambio en la amplitud de la señal bajo condiciones de fatiga.....	98
Figura 4-27. Espectro Hilbert-Huang de la señal de sEMG del músculo <i>Rectus Femoris</i> durante una extensión isométrica sin fatiga muscular.	99
Figura 4-28. Espectro Hilbert-Huang de la señal de sEMG del músculo <i>Rectus Femoris</i> durante una extensión isométrica con fatiga muscular.....	99
Figura 4-29. Graficas del RMSE correspondiente a los movimientos dinámicos. Es posible observar como el FV2 obtuvo mejor desempeño que el FV1.	102
Figura 4-30. Graficas del CC correspondiente a los movimientos dinámicos. Es posible observar como el FV2 obtuvo mejor desempeño que el FV1.	102
Figura 4-31. Estimación del ángulo de flexión de la pierna durante una contracción isométrica.	103
Figura 4-32. Resultado de la estimación del ángulo de flexión de la pierna durante una contracción isométrica luego de aplicar un filtrado pasa-bajas de 4Hz Butterworth de orden 2.	104
Figura 4-33. Resultado de la Estimación de la velocidad angular durante el ejercicio de flexión isométrica de la pierna, luego de aplicar un filtrado pasa-bajas de 4Hz Butterworth de orden 2	104
Figura 4-34. Estimación del ángulo de flexión de la pierna durante una contracción dinámica.	105

Figura 4-35. Estimación del ángulo de flexión de la pierna durante una contracción dinámica. La señal fue filtrada usando un filtro pasa-bajas de 4Hz Butterworth de orden 2.	105
Figura 4-36. Resultado de la Estimación de la velocidad angular durante el ejercicio de flexión dinámica de la pierna,.....	106
Figura 4-37. Resultado de la estimación del ángulo de flexión de la pierna durante una contracción isométrica bajo condiciones de fatiga muscular.	106
Figura 4-38. Resultado de la estimación de la velocidad angular durante el ejercicio de flexión de isométrica de la pierna bajo condiciones de fatiga muscular.....	107
Figura 4-39. Resultado de la estimación del ángulo de flexión de la pierna durante una contracción dinámica bajo condiciones de fatiga muscular.	107
Figura 4-40. Resultado de la estimación de la velocidad angular durante el ejercicio de flexión dinámica de la pierna bajo condiciones de fatiga muscular.....	108
Figura 4-41. Resultado de la estimación de la posición angular durante el ejercicio de flexión isométrica de la pierna bajo condiciones de fatiga muscular (Sujeto 1).	109
Figura 4-42. Resultado de la estimación de la velocidad angular durante el ejercicio de flexión dinámica de la pierna bajo condiciones de fatiga muscular (Sujeto 1).	109
Figura 4-43. Señal de sEMG registrada con el BTS FreeEMG y con el prototipo construido. Las señales fueron normalizadas y filtradas.	110

Lista de Tablas

Tabla 2-1. Características de sEMG y EMG invasiva.....	21
Tabla 3-1. Algunos trabajos sobre reconocimiento de patrones de señales de EMG.....	50
Tabla 3-2. Características propuestas para el reconocimiento de patrones en señales de EMG.....	62
Tabla4-1.Componentes electrónicos usados en la construcción del prototipo.....	76
Tabla4-2. Vectores de características usados en el reconocimiento de patrones de sEMG.	92
Tabla 4-3. Porcentajes de clasificación obtenidos con la Red Neuronal. (Promedio de 10 entrenamientos).....	94
Tabla 4-4. Valores promedios de RMSE y CC para la posición angular obtenidos con la Red Neuronal para los tres sujetos. (Promedio de 5 entrenamientos).....	101
Tabla 4-5. Valores promedios de RMSE y CC para la velocidad angular obtenidos con la Red Neuronal para los tres sujetos. (Promedio de 5 entrenamientos).....	101

Capítulo 1: Introducción

1.1 Motivación

La motivación de este trabajo es ayudar a las personas con discapacidades motrices, específicamente, a las personas que sufren de algún tipo de amputación transfemoral (amputación por arriba de la rodilla).

Hoy en día la mayoría de las prótesis que se encuentran en el mercado son activadas de manera mecánica (usando interruptores), lo que dificulta la rehabilitación del paciente. Las prótesis mioeléctricas son aquellas que utilizan un control basado en la información que proviene directamente del cerebro y puede ser adquirida desde los músculos remanentes después de realizar la amputación. Estos dispositivos tienen un precio muy elevado ya que permiten al paciente poder controlar la prótesis de manera “natural”, por este motivo se buscan desarrollar nuevas estrategias para el desarrollo de un control mioeléctrico en prótesis que no implique un costo económico elevado.

1.2 Justificación

Según las estadísticas del INEGI [1], en México, para el año 2010 las personas que poseen algún tipo de discapacidad son 5 millones 739 mil 270 lo que representa 5.1% de la población total. La gráfica de la figura 1-1 muestra los 10 estados del país que presentan el mayor número de personas con algún tipo de discapacidad. El estado de Puebla ocupa el quinto lugar a nivel nacional en cuanto al número de habitantes, así mismo, sustenta el sexto lugar con mayor número de personas con discapacidad. En Puebla, la posibilidad de padecer alguna limitación física o mental se incrementa con la edad, siendo para el año 2010 que la población masculina entre 15 a 29 años con alguna discapacidad es de 2.1%, mientras que para las edades de entre 60 a 84 años es de un 22.6%. La población femenina muestra un patrón similar. Para las edades de entre 60 a 64

años se tiene que 24 de cada 100 padecen algún tipo de limitación para poder realizar sus actividades cotidianas. De la población con discapacidad presente en el estado de Puebla, se tiene que el 52.2% son hombres mientras que el 47.8% son mujeres (INEGI) [1].

De entre los tipos de discapacidades clasificadas por el tipo de limitación se encuentran las siguientes: discapacidad para caminar o moverse, ver, oír, hablar o comunicarse, atender el cuidado personal, poner atención o aprender y del tipo mental. La gráfica de la figura 1-2 muestra el porcentaje que ocupan cada uno de los diferentes tipos de discapacidades para el estado de Puebla en el año 2010. Es importante notar que la principal discapacidad que se presenta en la población es la de caminar o moverse ocupando un 57.4%.



Figura 1-1. Población con algún tipo de discapacidad, México, 2010.

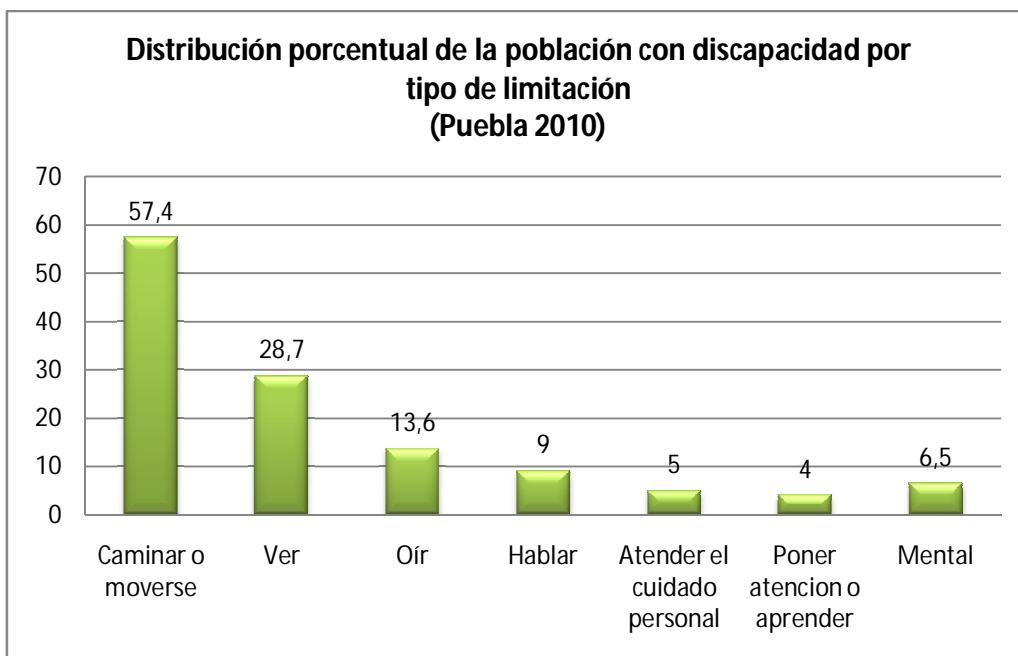


Figura 1-2. Distribución porcentual de la población con discapacidad por tipo de limitación (Puebla 2010).

Siendo la limitación para moverse la principal discapacidad en el estado de Puebla, es necesario tomar acciones para tratar de contrarrestar estas tendencias y así, mejorar la calidad de vida de estas personas. En la Universidad De las Américas de Puebla se ha estado trabajado en el desarrollo de una prótesis robótica de 4 grados de libertad [2] con movimiento en el plano sagital para personas que sufren de amputaciones del tipo transfemoral. Sin embargo este prototipo carece de control. Es debido a esto que surgió la propuesta de realizar un trabajo en conjunto UDLAP-INAOE para desarrollar un sistema de interfaz humano-máquina para el control de la prótesis transfemoral.

1.3 Antecedentes

El origen de las prótesis se remonta a la antigüedad donde se reemplazaban los miembros perdidos por extensiones de madera o con algún tipo de metal. A partir de los años 90's, y con el avance en la tecnología y los microprocesadores se ha podido dar origen a nuevos dispositivos protésicos muy sofisticados, haciendo énfasis en el paciente y en sus necesidades particulares. Las prótesis transfemorales son aquellas que reemplazan el miembro amputado por arriba de la rodilla. Una prótesis transfemoral tiene los siguientes elementos: suspensión, socket, rodilla, pilar y el pie.

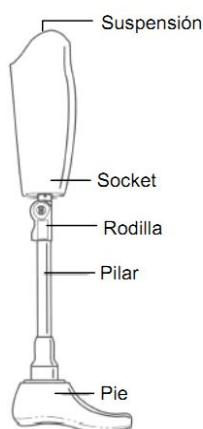


Figura 1-3. Prótesis Transfemoral [56].

El proceso de amputación resulta ser un golpe más emocional que físico ya que ocasiona depresión y baja autoestima en la persona que ha sufrido el trauma, además, este proceso debe hacerse de tal manera que, para la etapa de recuperación, se cuente con un muñón sano. Esto se logra cubriendo suturando la parte del hueso con la parte restante del músculo, a este tipo de sutura se le suele llamar “Boca de pescado” y ayuda a que el muñón no cree presión entre el hueso y la prótesis. Hoy en día, las prótesis pueden restablecer casi en su totalidad la funcionalidad del miembro perdido y se les puede encontrar en muchas variedades y formas, las hay para caminar, correr y hasta escalar montañas.

1.3.1 Control mioeléctrico

Las señales mioeléctricas son señales generadas por la actividad eléctrica de los músculos. Estas señales contienen gran cantidad de información que puede ser utilizada para identificar la intención del movimiento de un sujeto. El control mioeléctrico utiliza reconocimiento de patrones en señales mioeléctricas o señales de electromiografía (EMG) generados por los músculos para obtener información útil y posteriormente utilizarla en un sistema de control [3]. Una de las principales ventajas que ofrece el control mioeléctrico es que ofrece un control automático, esto significa que no se tiene que activar manualmente algún interruptor como es el caso en el control de prótesis mecánico [2]. También ofrece la posibilidad de adquirir las señales de forma no invasiva usando electrodos de superficie, los cuales no presentan ninguna molestia para el sujeto que los usa. Sin embargo, las señales de EMG están altamente contaminadas de ruido, lo que dificulta su análisis.

1.4 Objetivo General

Desarrollar un sistema para la adquisición de señales de electromiografía de superficie (sEMG) y desarrollar dos estrategias para el control mioeléctrico de una prótesis transfemoral.

1.5 Objetivos particulares

- Diseñar un prototipo para la adquisición de las señales de EMG de superficie.
- Seleccionar vectores de características adecuados para el reconocimiento de patrones en las señales de sEMG.
- Realizar una clasificación de movimientos basados en señales de EMG usando diferentes técnicas y diferentes vectores de características.

- Implementar un sistema para estimar la posición y velocidad angular de la pierna durante ejercicios de flexión y extensión de pierna usando únicamente las señales de sEMG.

1.6 Organización de la Tesis

En esta sección se presenta un breve resumen de los capítulos contenidos en el documento de Thesis.

Capítulo 1. Se presenta un panorama de la población con discapacidad en México y particularmente en el estado de Puebla, así como también, el objetivo general y los objetivos particulares.

Capítulo 2. En este capítulo se presentan los fundamentos teóricos que se requieren para realizar el trabajo propuesto. Se presentan algunos conceptos básicos sobre electromiografía y técnicas de procesamiento digital de señales.

Capítulo 3. Se describen las dos estrategias desarrolladas para lograr los objetivos planteados en el capítulo 1. Se presentan los protocolos experimentales así como también, una breve descripción de las herramientas, sensores, software y hardware utilizados.

Capítulo 4. Presenta los resultados obtenidos para los dos métodos propuestos. Tablas y figuras representativas son mostradas en esta sección.

Capítulo 5. Se presentan las conclusiones y trabajo futuro.

Capítulo 2: Marco Teórico

2.1 Introducción

La bioelectricidad se entiende como la habilidad de los tejidos para generar energía eléctrica [4]. Las funciones realizadas por el cuerpo humano son llevadas a cabo a través de impulsos eléctricos los cuales son el resultado de la acción electroquímica de ciertos tipos de células que generan una diferencia de potencial mediante partículas ionizadas: iones de potasio, calcio o sodio [5]. Uno de los primeros en contribuir en el campo de la actividad eléctrica en los seres vivos fue Luigi Galvani [6] quien, en 1786, descubrió la electricidad animal en una extremidad de rana. Hizo pasar corriente eléctrica en los nervios del anfibio y se percató que se producía un movimiento como respuesta al estímulo eléctrico.

El sistema nervioso es el encargado de mandar impulsos eléctricos desde el cerebro hasta el resto del cuerpo. La unidad básica del sistema nervioso es la neurona, una célula especializada en recibir y transmitir impulsos eléctricos denominados potenciales de acción, los cuales viajan a través de las membranas celulares y forman el principal medio de comunicación entre tejidos y células dentro del cuerpo humano [5]. El sistema nervioso también es el responsable de controlar al sistema motor, el cual está formado por la espina dorsal, el sistema esquelético y los músculos. Existe un tipo de neuronas especializadas que conforman el sistema motor humano y reciben el nombre de motoneuronas. Las motoneuronas son las encargadas de mandar y recibir impulsos eléctricos desde la espina dorsal hasta las fibras musculares [6]. En el músculo es posible distinguir entre 2 unidades fundamentales: la unidad anatómica y la unidad funcional. La primera es la llamada fibra muscular, mientras que la segunda, recibe el nombre de unidad motora. La unidad motora (UM) [6] es un grupo de fibras musculares que reciben estímulos eléctricos (inervación) por una sola neurona motora figura 2-1.

Realizar un simple movimiento requiere la intervención y trabajo en conjunto de muchas neuronas. El proceso es como sigue: se genera la orden en el cerebro y se transmite en forma de un impulso eléctrico, este impulso viaja a través de la espina dorsal y llega hasta las motoneuronas responsables de inervar el músculo que realizará la acción estimulando las fibras musculares y produciendo así, la expansión o inhibición del músculo.

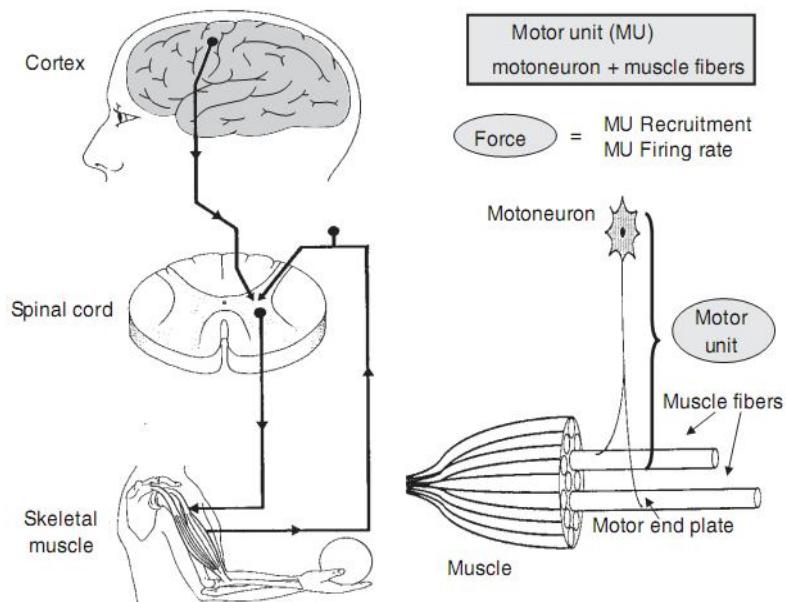


Figura 2-1. Esquema representativo del mecanismo básico de control y de los componentes de la UM. [6]

2.2 Electromiografía

La electromiografía (EMG) es un campo especializado en el uso de dispositivos electrónicos para medir la actividad eléctrica de los músculos [5]. H. Piper fue el primero en estudiar la EMG y en 1912, Alemania, construyó un prototipo basado en un galvanómetro. En 1924 Gasser y Erlanger hicieron un estudio similar pero utilizando un osciloscopio; cuatro años después, Proebster observó las señales producidas por la denervación de los músculos abriendo así el campo de la EMG clínica [6]. A partir de 1980 con la introducción de las computadoras se pudieron realizar estudios más amplios sobre las señales de EMG.

En una contracción muscular voluntaria [6] la fuerza es modulada por una serie de cambios en la frecuencia de la actividad de las UMs, es decir, la frecuencia de disparo de los potenciales de las UMs depende de la fuerza aplicada y la velocidad de contracción muscular. El espectro de frecuencia de las unidades motoras durante una contracción muscular voluntaria (MVC) puede apreciarse en la figura 2-2. La mayor cantidad de energía de la señal de EMG se encuentra entre los 50-60Hz.

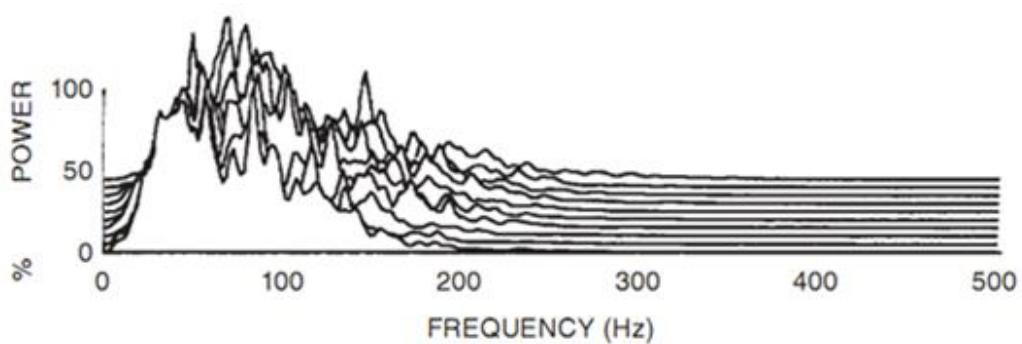


Figura 2-2. Espectro de frecuencia de las señales de EMG. [6]

En una contracción del músculo esquelético, los rangos de potenciales van desde los $50\mu\text{V}$ hasta los 5mV [7]. Para el registro se las señales de EMG se hace uso de electrodos. Un electrodo es un transductor que hace una transferencia iónica del tejido vivo del cuerpo hacia un dispositivo electrónico el cual se encarga de procesar la señal para posteriormente obtener información útil de la medición [8]. La amplitud de la señal de EMG depende de muchos factores, entre ellos tenemos los siguientes:

- Distancia inter-electrodo: Es la distancia que separa a los electrodos usados en la adquisición de la señal de EMG.
- Material de los electrodos: El material y tipo de los electrodos también influye de manera considerable el registro de EMG. Existen dos tipos de electrodos, los electrodos de gel o húmedos y los electrodos sin gel o secos. Los electrodos húmedos constan de un gel conductor para mejorar el transporte iónico entre la interface electrodo-piel. Los electrodos más populares de éste tipo son los de Ag/AgCl. Los electrodos secos son generalmente placas de metales nobles altamente conductores como lo son la plata, oro, platino y titanio y a diferencia de los electrodos húmedos, éstos no requieren de un gel conductor [6].
- Ruido y “artefactos”: Se refiere a las interferencias que se pudieran presentar al momento de realizar los registros de las señales y tienen varios orígenes; puede ser ruido electromagnético proveniente de la línea de alimentación o ruido biológico proveniente de algún otro proceso electroquímico como las señales de Electroencefalografía (EEG) o Electrocardiografía (ECG). También se presenta el artefacto por movimiento de los cables conductores de los electrodos o algún falso contacto con la piel.
- Fatiga muscular: Se presenta cuando se realizan registros exhaustivos de EMG y principalmente se debe al cansancio del músculo, lo cual se ve reflejado como un “retraso” en la tasa de disparo de potenciales en la señal [6].

Existen dos formas principales de registrar las señales electromiográficas: la electromiografía de superficie o no invasiva (sEMG) y la electromiografía invasiva. La electromiografía invasiva hace uso de electrodos de aguja. La amplitud de la señal registrada por estos electrodos depende del área de registro que ocupan, así como también, de la distancia del electrodo a la fuente de la señal (UM) [6]. La electromiografía invasiva es muy utilizada en el estudio de miopatías y análisis clínicos debido a que es posible registrar el potencial directamente de las unidades motoras, obteniendo así, una señal más libre de ruido. La electromiografía de superficie hace uso de electrodos superficiales para realizar el registro de las señales musculares. La actividad eléctrica registrada es una superposición de las señales provenientes de varias unidades motoras. En la tabla 2-1 se ofrece una comparación entre la sEMG y la EMG invasiva.

Tabla 2-1. Características de sEMG y EMG invasiva.

EMG de superficie	EMG invasiva
Uso de electrodos superficiales. Se colocan sobre la piel del músculo a medir. No requiere de supervisión médica.	Uso de electrodos de aguja (intramusculares). Se insertan directamente en el músculo para obtener los registros y requiere de supervisión médica.
La señal registrada corresponde al promedio de la actividad eléctrica de varias UM's en el músculo.	Es posible tener mediciones de una sola UM.
Los registros obtenidos presentan alto nivel de ruido.	La cantidad de ruido es menor en comparación con la sEMG.
La colocación de los electrodos no presenta molestia alguna al usuario.	La inserción de los electrodos es bastante dolorosa y requiere supervisión médica.

2.3 Localización de los electrodos, forma, tamaño, distancia inter-electrodo y material.

La distancia inter-electrodo es definida como la distancia centro a centro del área conductiva de los electrodos [6]. En la figura 2-3 b) es posible observar las diferentes medidas que han sido utilizadas en varias publicaciones europeas para el diámetro y la distancia inter-electrodo [6]. La forma del electrodo es definida como el área conductora que entra en contacto con la piel. La mayoría de las referencias bibliográficas coinciden en la forma circular como la más utilizada [6].

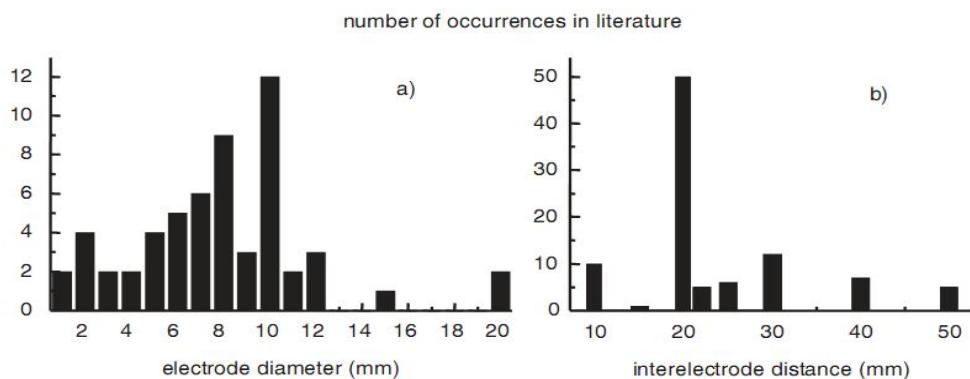


Figura 2-3. Resultados de un inventario en el que se hace uso de sensores para sEMG en laboratorios europeos obtenidos escaneando 6 volúmenes de revistas (1991-1997). a) Histograma del diámetro del electrodo. b) Histograma de la distancia inter-electrodo [6].

Una de las cuestiones más discutidas en la sEMG se refiere a la localización de los electrodos. Debido a esto se originó una iniciativa para tratar de estandarizar los siguientes factores: localización, tamaño y forma de los electrodos. Por este motivo en 1996 surge el SENIAM (*Surface Electromyography for Noninvasive Assessment of Muscles*) [9] para intentar fijar el valor de estos parámetros. El SENIAM proporciona una serie de pasos antes de realizar las mediciones de sEMG [6]:

1. Selección de los electrodos para sEMG.
2. Preparación de la piel. Limpiar con alcohol y rasurar la zona en la que se colocarán los electrodos.
3. Posicionar al paciente en la postura inicial. Esta postura puede variar dependiendo del estudio a realizar.
4. Determinar la localización de los electrodos.
5. Fijar los electrodos.
6. Finalmente probar las conexiones.

La localización de electrodos de aguja y superficiales se muestra en las figuras 2-4 y 2-5.

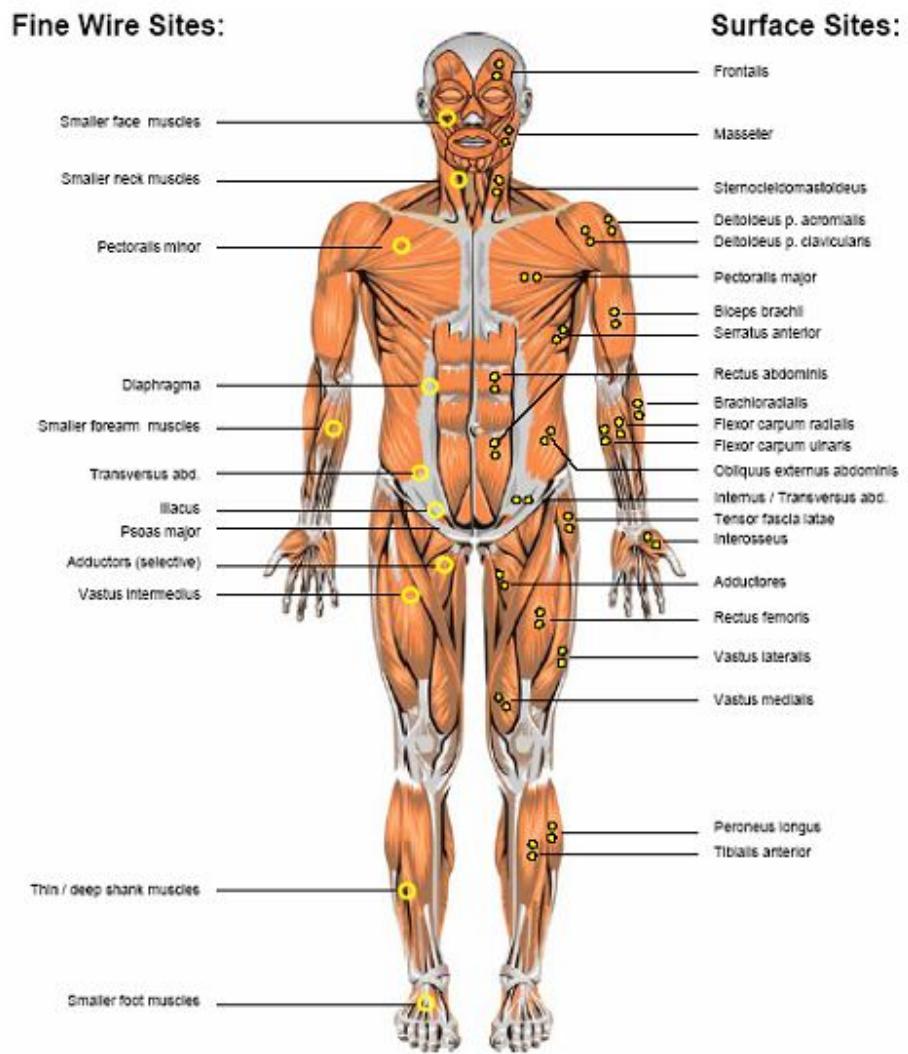


Figura 2-4. Localización de los electrodos de aguja y superficiales (parte frontal del cuerpo) [10].

Fine Wire Sites:

Surface Sites:

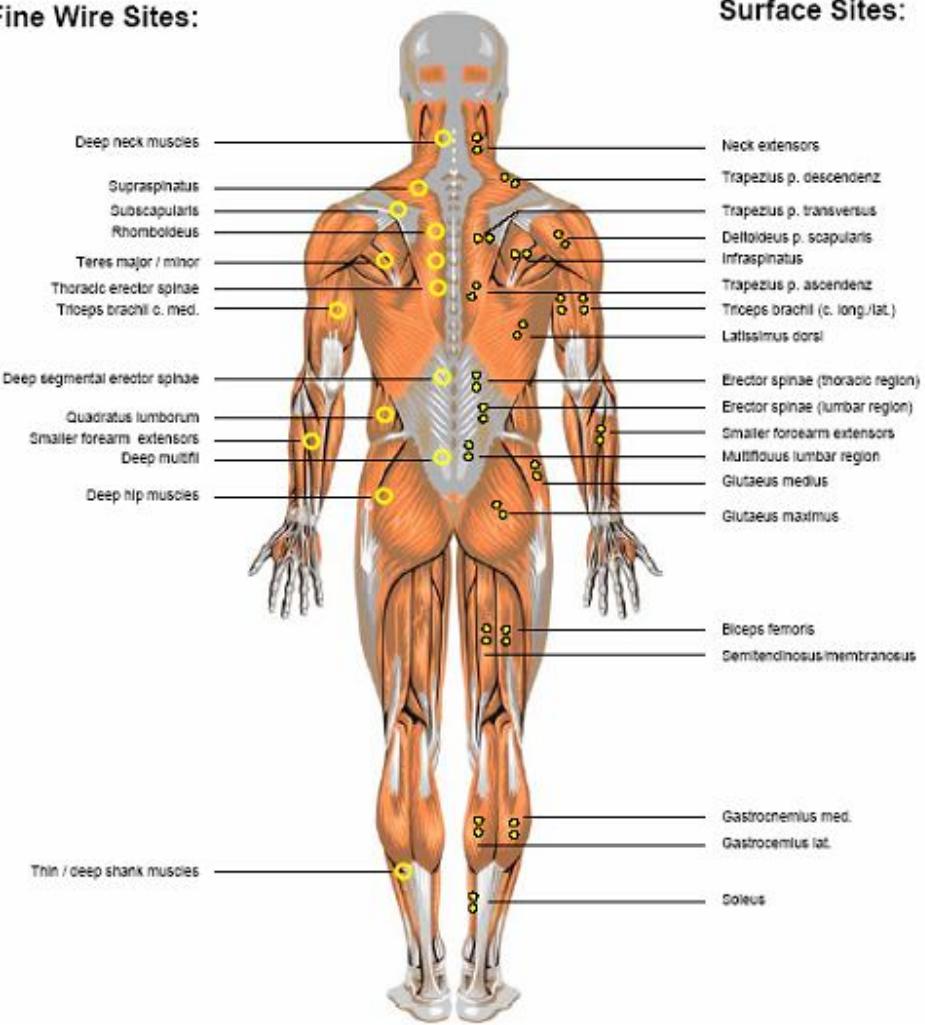


Figura 2-5. Localización de los electrodos de aguja y superficiales (parte posterior del cuerpo) [10].

2.4 Sistemas de control mioeléctrico basados en reconocimiento de patrones.

Un sistema típico de control mioeléctrico tiene un esquema como el de la figura 2-6. Se pueden identificar las etapas de adquisición/segmentación de datos, extracción de características, clasificación y la etapa de aplicación [3].

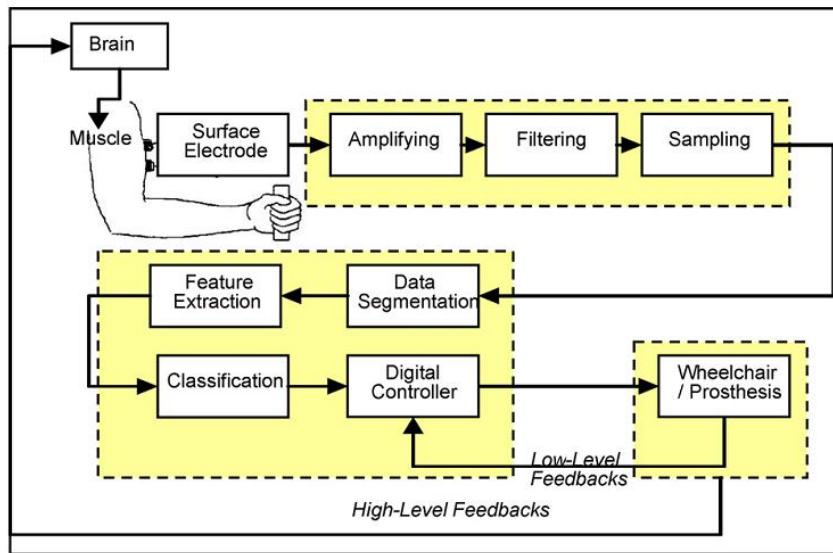


Figura 2-6. Sistemas de control mioeléctrico basados en reconocimiento de patrones [3].

2.4.1 Adquisición y segmentación de datos

En la adquisición de las señales de sEMG es posible distinguir las siguientes etapas: pre-amplificación, filtrado y la etapa de conversión de analógico a digital. Para la etapa de pre-amplificación se recomienda el uso de un amplificador de tipo diferencial con una impedancia de entrada de $10^9 - 10^{12}\Omega$ en paralelo con un capacitor de 2 – 10pF [6]. También se recomienda ubicar el pre-amplificador bastante cerca de los electrodos y del sujeto de estudio para evitar capacitancias parasitas y problemas producidos por el movimiento de los cables. Otra de las características importantes es el rechazo de modo común o CMRR (Common

Mode Rejection Ratio) [6]. El CMRR se mide en decibeles y es la razón entre la ganancia de modo diferencial y la ganancia en modo común (idealmente cero). Para las mediciones de EMG se requiere un rechazo de modo común mínimo de 90db [6]. El arreglo con amplificadores operacionales más utilizados como pre-amplificador es el amplificador de instrumentación. Este circuito es un arreglo de tres amplificadores operacionales y tiene la función de amplificar la diferencia de los voltajes presentes en sus entradas. El amplificador de instrumentación tiene la característica de tener impedancias de entrada bastante elevadas y un alto CMRR. Son utilizados frecuentemente para amplificar señales muy pequeñas como por ejemplo, las señales del cuerpo humano.

La señal proveniente de la etapa de pre-amplificación contiene una mezcla de señales biológicas y ruido del ambiente, es por esta razón que se requiere depurar o filtrar la información. El filtrado se logra usando filtros analógicos pasa-banda (20-1kHz)[6] para obtener registros únicamente de EMG. Sin embargo, las señales de ruido generadas por el movimiento de los cables se encuentran entre 0 y 15 por lo que se prefiere el uso de un filtro de 15 a 500Hz o de 20 a 500Hz.

La conversión analógica a digital (A/D) es el proceso mediante el cual se transforman las señales continuas o del mundo real a niveles de voltaje que representan un código binario. Una señal continua es aquella que, en teoría, puede tomar cualquier valor en amplitud y no se encuentra limitada a un número de puntos finitos. Un convertidor A/D acepta señales en un rango específico de voltaje, por ejemplo $\pm 5V$, el cual es subdividido en un número de niveles discretos. Este número está dado por la fórmula 2^n , donde n es el número de bits del convertidor A/D. El proceso de digitalización consta de varios pasos: muestreo, retención, cuantificación y codificación. El muestreo es la etapa en la que se toman muestras de la señal continua. La velocidad de muestreo depende de un reloj interno y recibe el nombre de frecuencia de muestreo. La etapa de retención se encarga de mantener el valor de la muestra el tiempo suficiente para que pueda ser procesado. El proceso de cuantificación consiste en medir el valor del voltaje recibido y asignarle un único valor de salida. Finalmente, la etapa de codificación

consiste en traducir el valor cuantificado a un valor binario. Una de las principales desventajas del proceso de conversión A/D es la perdida de información debido a truncamientos y redondeos efectuados durante la codificación, así como también, la aparición del efecto denominado “aliasing”. El efecto *aliasing* se presenta cuando se muestrea una señal por debajo de la frecuencia de Nyquist y genera problemas al intentar reconstruir la señal original. Para evitar este efecto, se hace uso del teorema de muestreo de Nyquist [6]. Este teorema señala que una señal puede ser completamente reconstruida sin pérdida de información si se muestrea a una frecuencia de cuando menos del doble del armónico más grande presente en la señal analógica. Para las señales musculares, la frecuencia con el armónico más grande está en el rango de 400 – 500Hz [3]. A continuación se mencionan algunas recomendaciones para poder adquirir la señal de EMG con la mayor fidelidad posible [11]:

- Amplificador de instrumentación con alto rechazo de modo común (CMRR), generalmente arriba de 90 dB.
- Amplificador de instrumentación con Alta impedancia de entrada (decenas de mega ohms).
- Distancia pequeña entre el amplificador de instrumentación y la fuente de la señal.
- Filtrado de la señal. Suele usarse un filtrado pasa bandas en el rango de 10 – 1kHz, sin embargo, para evitar el ruido generado por el movimiento de los cables (típicamente < 15Hz [12]) se usa el filtro pasa banda de 20 hasta 500 o 1kHz. También es muy frecuente el uso de filtro de muesca o *notch* para el rechazo de la tensión de alimentación (50 – 60Hz). El uso de este filtro genera una importante pérdida de información en la señal de sEMG debido a que la mayor cantidad de su energía se encuentra alrededor de estas frecuencias. Como regla, se debe evitar el uso de los filtros *notch* [11], figura 2-7.
- Conversión A/D. Generalmente se usan resoluciones mayores o iguales a 10 bits y con frecuencias de muestreo de más de 1kHz.

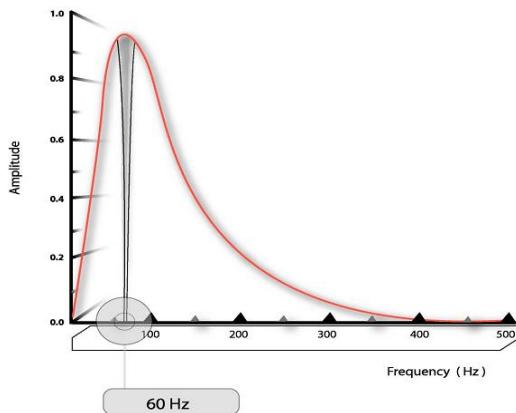


Figura 2-7. Representación esquemática del espectro de potencia de la señal de EMG. El área sombreada indica la perdida de la señal cuando el filtro *notch* es usado para rechazar frecuencias 50-60Hz. [11].

Segmentación

Un segmento es un subconjunto de muestras de una señal en la que se realiza la extracción de características. Debido a las limitaciones de tiempo real, el tamaño de los segmentos adyacentes, más el tiempo de procesamiento debe ser no mayor a 300ms. Debido a que el tiempo de procesado de los procesadores usados en el cómputo de tiempo real no excede a los 50ms, el tamaño del segmento puede variar de 32 a 250ms [13]. Existen dos técnicas para la segmentación o ventaneado de los datos: la segmentación disjunta y la superpuesta. La segmentación disjunta, figura 2-8, utiliza segmentos adyacentes disjuntos con un tamaño específico. La segmentación superpuesta, figura 2-9, consiste en deslizar un nuevo segmento sobre el segmento actual con un incremento menor al tamaño del segmento.

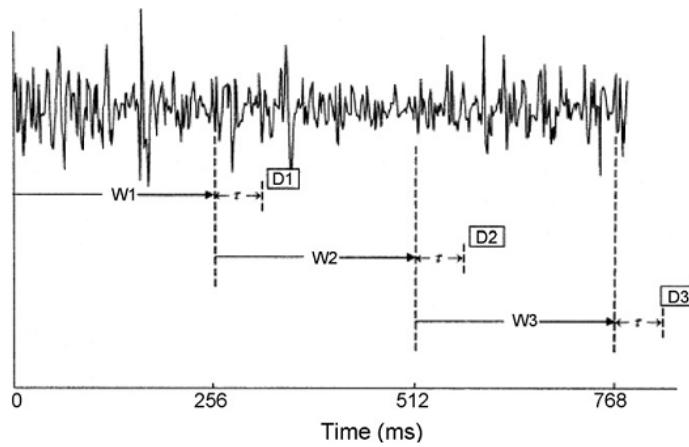


Figura 2-8. Segmentación adyacente disjunta [13].

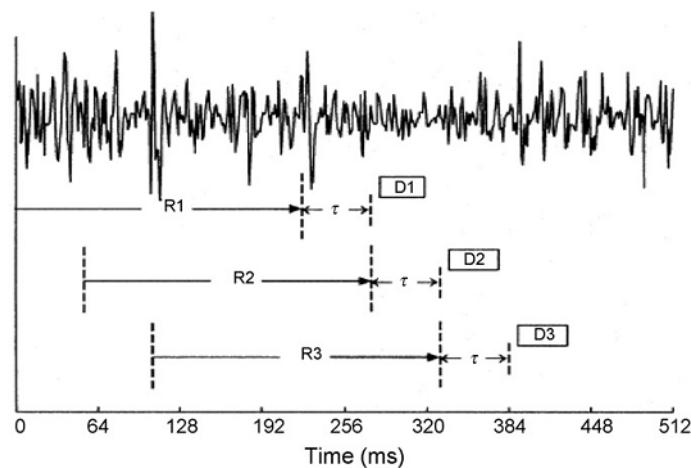


Figura 2-9. Segmentación superpuesta [13].

Oskoei y Hu [8], evaluaron segmentos disjuntos y superpuestos para fines de clasificación. Sus resultados mostraron que la segmentación disjunta con una ventana de 200ms produce mejores resultados de clasificación que una ventana sobrepuerta de tamaño de 200ms y un desplazamiento de 50ms [13]. Farina y Merletti [8], mostraron que la segmentación superpuesta solamente incrementa el tiempo de procesado y no produce ninguna mejora significante, también

observaron que una ventana de menos de 125ms produce alta variación en las características en el dominio de la frecuencia [13].

2.4.2 Extracción de características

La extracción de características consiste en obtener información relevante de la señal de sEMG mediante una transformación de los datos originales, de esta transformación se obtiene el vector de características o *Feature Vector* (FV). Existen tres tipos de características para la señal de EMG: las características en el dominio del tiempo, en el dominio de la frecuencia y en el dominio de tiempo-frecuencia.

Características en el dominio del tiempo

Las características en el dominio del tiempo son las más populares en aplicaciones de tiempo real, esto se debe a que no se necesita hacer transformación alguna de los datos [13]. Se basan simplemente en la amplitud de la señal, forma de onda y algunas características que se relacionan con la frecuencia.

Valor Integrado de EMG (IEMG)

Consiste en integrar la señal de EMG. Hacer una sumatoria a lo largo de toda la ventana de segmentación.

$$IEMG = \sum_{i=1}^N |x_i| \quad 2.1$$

Donde N es el tamaño del segmento. Y x_i es el valor de cada elemento del segmento [13].

Valor Medio Absoluto (MVA)

Estima el promedio del valor absoluto de los datos en un determinado segmento [13].

$$MVA = \frac{1}{N} \sum_{i=1}^N |x_i| \quad 2.2$$

Raíz media cuadrada (RMS)

Cuando la señal de sEMG es modelada como un proceso aleatorio Gaussiano, el RMS se relaciona a la fuerza aplicada bajo condiciones de no fatiga [3].

$$RMS = \sqrt{\frac{1}{N} \sum_{i=1}^N x_i^2} \quad 2.3$$

Desviación estándar

Representa qué tan separados están los datos con respecto a la media y se expresa en las mismas unidades que esta última.

$$STD = \sqrt{\frac{1}{N} \sum_{i=1}^{N-1} (x_i - \bar{x})^2} \quad 2.4$$

Donde \bar{x} es la media de la señal.

Longitud de forma de onda (WL)

Se refiere a la longitud de onda acumulada a lo largo del segmento. Ofrece una media de la amplitud, frecuencia y duración de la señal [13].

$$WL = \sum_{i=1}^{N-1} |x_{i+1} - x_i| \quad 2.5$$

Cruces por cero (CZ)

Es el número de veces que la señal pasa por cero, es decir, el número de veces que la señal cambia de signo en un segmento dado [13]. Ofrece una estimación de la frecuencia. Se debe de incluir un umbral en amplitud para evitar los cruces por cero producidos por el ruido de la señal. Si se tienen dos muestras, x_{i+1}, x_i , entonces se contara un cruce por cero si:

$$\{x_i > 0 \wedge x_{i+1} < 0\} \text{ or } \{x_i < 0 \wedge x_{i+1} > 0\} \text{ and } |x_{i+1} - x_i| \geq \epsilon$$

Donde ϵ es el umbral definido en amplitud.

Cambios en la pendiente de la señal (SSC)

Es el cambio de signo de la pendiente de la señal y proporciona una medida de la frecuencia [13]. Debe de introducirse un umbral para evitar el ruido. Dadas tres muestras consecutivas x_{i-1}, x_i, x_{i+1} , se incrementará el cambio de signo de la pendiente de la señal si:

$$\begin{aligned} &\{x_i > x_{i-1} \text{ and } x_i > x_{i+1}\} \text{ or } \{x_i < x_{i-1} \text{ and } x_i < x_{i+1}\} \text{ and } |x_i - x_{i+1}| \geq \epsilon \text{ or } |x_i - x_{i-1}| \\ &\geq \epsilon \end{aligned}$$

Amplitud Wilson (WAMP)

Calcula el número de veces que el valor absoluto de la diferencia de dos muestras consecutivas (x_i, x_{i+1}) supera un umbral dado [13].

$$WAMP = \sum_{i=1}^N f(|x_i - x_{i+1}|) \quad 2.6$$

$$f(x) = 1, x > \epsilon \quad \text{ó} \quad f(x) = 0 \text{ en caso contrario}$$

Histograma de EMG

Divide los elementos de la señal de EMG en k segmentos igualmente espaciados y retorna el número de elementos en cada segmento [13].

Coeficientes Auto Regresivos (AR)

Esta característica modela la señal de EMG como una serie de tiempo lineal auto regresiva y provee información acerca del estado de contracción muscular [15]. Describe cada muestra de la señal de EMG como la combinación de muestras previas más un término de error del tipo ruido blanco Gaussiano. Se define como:

$$x_k = - \sum_{i=1}^N a_i x_{k-i} + e_k \quad 2.7$$

Donde a_i es el coeficiente auto regresivo, k es el número de segmento, e_k es el término de error de ruido blanco Gaussiano y N es el orden del modelo AR.

Coeficientes Cepstrum

La señal cepstral se define como la transformada inversa de Fourier del logaritmo del espectro de potencia de la señal. El análisis usando coeficientes cepstrales se

basa en la obtención de la envolvente del espectro de frecuencias [29]. Al aplicar la FFT al espectro de frecuencias se obtiene el espectro del espectro en un nuevo dominio conocido como dominio del Cepstrum. Al retener variaciones lentes (bajas frecuencias en el nuevo dominio), se retienen las componentes que representan la envolvente del espectro de frecuencias. Dicha envolvente es una característica útil para la identificación de movimientos [29]. Esta medida provee información acerca de la tasa de cambio en diferentes bandas del espectro de frecuencia de una señal [15]. Estos coeficientes se calculan como sigue:

$$c_1 = -a_1 \quad 2.8$$

$$c_i = -a_i - \sum_{l=1}^{i-l} \left(1 - \frac{l}{i}\right) a_n c_{i-1} \quad 2.9$$

Donde a_i es el i-ésimo coeficiente AR y c_i es el i-ésimo coeficiente cepstrum, i es la dimensionalidad del modelo [15].

Características en el dominio de la frecuencia

Las características en el dominio de la frecuencia son ampliamente utilizadas para el estudio de la fatiga muscular. El espectro de la señal de EMG es influenciado por dos factores: la tasa de disparo de las UM en el rango de las bajas frecuencias (debajo de 40Hz), y por la morfología de los potenciales de acción viajando a través de la fibra muscular en el rango de las altas frecuencias (arriba de 40Hz) [3]. Durante una contracción voluntaria constante, una señal mioeléctrica puede ser considerada como no estacionaria [3]; sin embargo, se ha demostrado que durante contracciones de bajo nivel (20-30%) de la contracción voluntaria máxima (MVC) la señal puede ser considerada como estacionaria en sentido amplio; aun más, para un MVC del 50-80%, la señal puede ser considerada localmente estacionaria por periodos de 500-150ms [3].

Frecuencia mediana (FMD)

La frecuencia mediana divide el espectro de densidad de potencia (PSD) en dos.

$$FMD = \frac{1}{2} \sum_{i=1}^M PSD_i \quad 2.10$$

Donde M es la longitud del PSD, i es la i-ésima línea de PSD.

Frecuencia Media (FM)

Se define por:

$$FMN = \frac{\sum_{i=1}^M f_i PSD_i}{\sum_{i=1}^M PSD_i} \quad 2.11$$

M es el tamaño de PSD, $f_i = \frac{(i * sampling rate)}{(2 * M)}$ y PSD_i es el i-ésimo PSD.

Características en el dominio de tiempo-frecuencia

En el análisis espectral, la transformada de Fourier pierde la información de la señal concerniente al dominio del tiempo y no puede decirnos cuando un evento en particular se lleva a cabo. Esta limitación es aceptable para señales estacionarias cuyas propiedades no cambian a lo largo del tiempo [3]; sin embargo, para el análisis de señales no estacionarias como en el caso de las señales de EMG, esta limitación no es aceptable. Es por este motivo que se requiere de una herramienta de análisis que nos proporcione tanto información en frecuencia como en tiempo. Las herramientas de análisis en tiempo-frecuencia son capaces de darnos la información temporal de la cual se carece en el análisis espectral. Análogamente, los métodos que utilizan técnicas de análisis temporal no son capaces de darnos la información presente en el dominio de la frecuencia. Las técnicas de análisis en el domino tiempo-frecuencia nos permite tener acceso a la información en ambos dominios, tanto tiempo como frecuencia, lo que nos

permite realizar análisis más fiables y más completos. Sin embargo, requieren de muchas operaciones matemáticas por lo que hace el procesado mucho más tardado.

Transformada de Fourier en tiempo corto (STFT)

Consiste en aplicar la transformada de Fourier en intervalos de tiempo cortos. Se define para una señal $x(t)$ como:

$$STFT_x(t, \omega) = \int W^*(\tau - t)x(\tau)e^{-j\omega\tau}d\tau \quad 2.12$$

Donde $W(t)$ es una función de ventana y $*$ representa el complejo conjugado, τ representa el tiempo y ω la frecuencia.

Transformada Wavelet

Es una transformación donde una señal es integrada con una función o wavelet madre desplazada en tiempo y en escala [13].

$$W_x(a, b) = \int x(t) \left(\frac{1}{\sqrt{a}} \right) \psi^* \left(\frac{t-b}{a} \right) dt \quad 2.13$$

Donde $x(t)$ es la señal a transformar, ψ^* es el complejo conjugado de la wavelet madre y $\psi \left(\frac{t-b}{a} \right)$ es la versión cambiada en tiempo y escala de la wavelet madre en el tiempo b y escala a .

La transformada Wavelet Discreta (DWT) corresponde a la versión discreta de la transformada Wavelet Continua y puede ser utilizada para analizar propiedades temporales y espectrales de señales no estacionarias [17-19]. Consiste en un proceso iterativo que transforma una señal en subconjuntos de coeficientes obtenidos a diferentes escalas de frecuencia que representan una proyección de la señal original usando una versión escalada y retrasada de una Wavelet madre [18]. La representación de la DWT se presenta a continuación:

$$x(t) = \sum_{k=-\infty}^{\infty} \sum_{l=-\infty}^{\infty} d(k, l) 2^{-\frac{k}{2}} \psi(2^{-k}t - l) \quad 2.14$$

Donde k esta relacionada a a como $a = 2^k$; b se relaciona a l como $b = 2^k l$ y $d(k, l)$ es una muestra de $W_x(a, b)$ en los puntos discretos k and l , y $\psi(2^{-k}t - l)$ es la proyección retrasada y escalada de la Wavelet madre en tiempo / escala k [17].

La DWT es frecuentemente representada en forma de bancos de filtros los cuales son obtenidos usando el algoritmo de codificación sub-banda [17]. En este caso, el análisis con DWT es realizado usando un algoritmo piramidal descrito en términos de los filtros multi-resolución. En este algoritmo la señal es analizada en diferentes bandas de frecuencia con diferente resolución por medio de una descomposición de la señal en términos de los coeficientes de aproximación y detalle. El siguiente paso consiste en realizar de nuevo la descomposición Wavelet, pero ahora, sobre la información presente en los coeficientes de aproximación. Esto es realizado por medio de la aplicación sucesiva de filtros pasa-altas y pasa-bajas, así como también, por medio de un sub-muestreo en base 2 sobre la señal original. La figura 2-10 muestra la representación esquemática del algoritmo correspondiente al árbol de descomposición de niveles. Una vez que los coeficientes de detalle y de aproximación son obtenidos, es posible utilizar la información estadísticas sobre la media y la desviación estándar para la construcción de un vector de características.

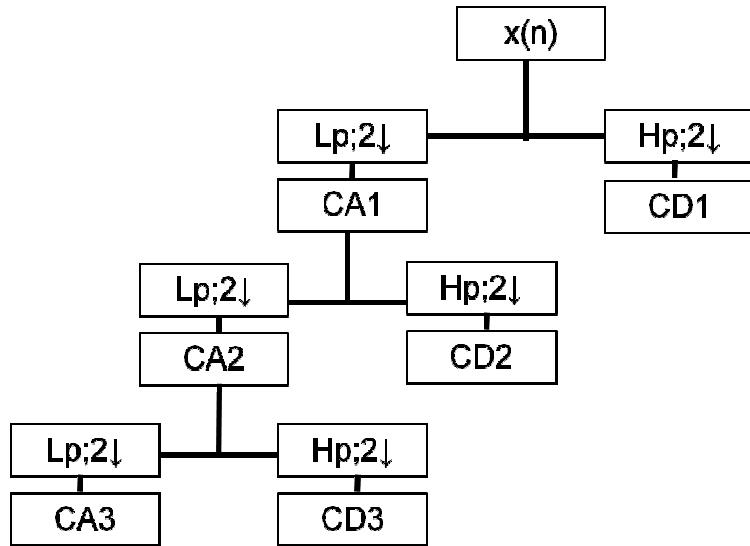


Figura 2-10. Árbol de descomposición Wavelet para el cálculo de los coeficientes de aproximación (CA_i) y detalle (CD_i) y Lp and Hp hacen referencia a los filtros pasa-bajas y pasa-altas respectivamente.

Transformada Hilbert-Huang

Una de las principales características de la señal de sEMG es que su naturaleza no es estacionaria, por lo que presenta varias complicaciones para su estudio y análisis. Múltiples técnicas han sido utilizadas para el análisis de estas señales, entre ellas están las técnicas de tiempo frecuencia tales como la transformada Wavelet y el espectrograma; sin embargo, las técnicas basadas en la transformada de Fourier tienden a realizar suposiciones tales como la periodicidad, linealidad o estacionariedad de la señal, haciendo que el análisis carezca de significado físico [23]. Una técnica para analizar datos variantes en el tiempo es la transformada Hilbert-Huang (HHT). Esta técnica consiste en aplicar la transformada Hilbert a un grupo de señales obtenidas de la descomposición adaptiva de la señal original. Estas señales reciben el nombre de *Intrinsic Mode Functions* (IMF) y tienen las siguientes características: En todo el conjunto de datos, el número de extremos (máximos y mínimos) y el número de cruces por

cero deben ser o iguales o diferir a lo más por uno. En cualquier punto, el valor medio de la envolvente definido por el máximo local y el valor medio de la envolvente definida por el mínimo local es cero [23]. El proceso para obtener las IMF recibe el nombre de descomposición modal empírica (EMD) [21] y consta de los siguientes pasos:

- Se obtienen todos los máximos locales de la serie de datos $x(t)$ y después se unen con una línea *Cubic Spline* [28]. Se hace lo mismo con los mínimos locales.
- Se obtiene la media de la envolvente superior e inferior (m_1) y se obtiene la primera componente (h_1) como: $h_1 = x(t) - m_1$
- Si esta componente no cumple con las condiciones para ser una IMF, entonces se repiten los pasos hasta obtener una componente h_n que sea IMF.
- La primera IMF es llamada $c_1(t)$ y se define el residuo como: $r_1 = x(t) - c_1$.

El proceso se repite hasta que el residuo se convierte en una función monotónica o ninguna IMF puede ser obtenida.

Finalmente se obtiene una descomposición de la señal original en múltiples IMFs a diferentes escalas de frecuencia.

$$x(t) = \sum_{j=1}^n c_j(t) + r_n \quad 2.15$$

Donde r_n es el residuo final y n es el número de IMFs obtenidas. Cada nivel de descomposición presenta diferentes componentes espectrales, siendo la primera IMF c_1 la de frecuencia más alta hasta llegar a la última componente c_n cuya frecuencia es mucho más baja.

El siguiente paso para completar la HHT consiste en aplicar la transformada Hilbert a las IMFs obtenidas mediante EMD. La transformada Hilbert se define como:

$$y(t) = \frac{1}{\pi} P \int_{-\infty}^{\infty} \frac{x(t')}{t - t'} dt' \quad 2.16$$

Donde P indica el valor principal de Cauchy [19]. Con esta definición podemos tener una señal analítica $z(t)$ definida como:

$$z(t) = x(t) + iy(t) = a(t)e^{i\theta(t)} \quad 2.17$$

Donde $a(t) = [x(t)^2 + y(t)^2]^{\frac{1}{2}}$ y $\theta(t) = \arctan \frac{y(t)}{x(t)}$ [21,22].

Se define la frecuencia instantánea como:

$$f(t) = \frac{1}{2\pi} \frac{d\theta(t)}{dt} \quad 2.18$$

Con la amplitud y la frecuencia instantánea se obtiene una representación de la señal original:

$$x(t) = \text{Real} \sum_{j=1}^n a_j(t) \exp \left(i \int f_j(t) dt \right) \quad 2.19$$

Donde n corresponde a la n-ésima IMF.

Características basadas en la transformada Hilbert-Huang.

El espectro de Hilbert nos brinda información en amplitud, tiempo y frecuencia. Por este motivo las frecuencias cuyas amplitudes sean máximas pueden resultar ser una buena característica para utilizarse en el reconocimiento de patrones; por ejemplo, cuando se presenta actividad de EMG, se tienen amplitudes máximas en el rango de las frecuencias bajas, menores de 100Hz, figura 2-11. Por otro lado, cuando no se presenta dicha actividad, las amplitudes máximas se encuentran dispersas principalmente en la banda de frecuencias altas, figura 2-12. Es por esta

razón que se plantea un método para poder obtener las frecuencias en el espectro de Hilbert cuyas amplitudes sean máximas, *Hilbert-Huang Average Frequency* (HHAF). A continuación se listan los pasos para poder realizar este método:

1. Se ordenan de forma descendente los vectores de Amplitud (A) y Frecuencia (F) con respecto al vector de Amplitud.
2. Se divide el vector de frecuencias en dos partes
3. Se calcula la media del vector de frecuencia más significativo, figura 2-13.

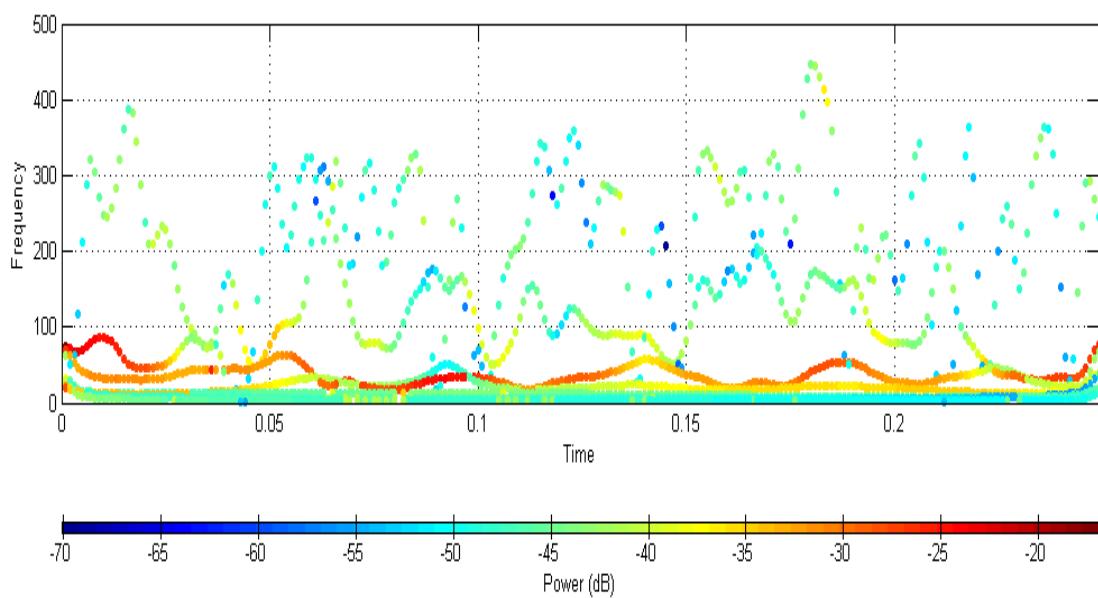


Figura 2-11. Espectro Hilbert-Huang con actividad de EMG.

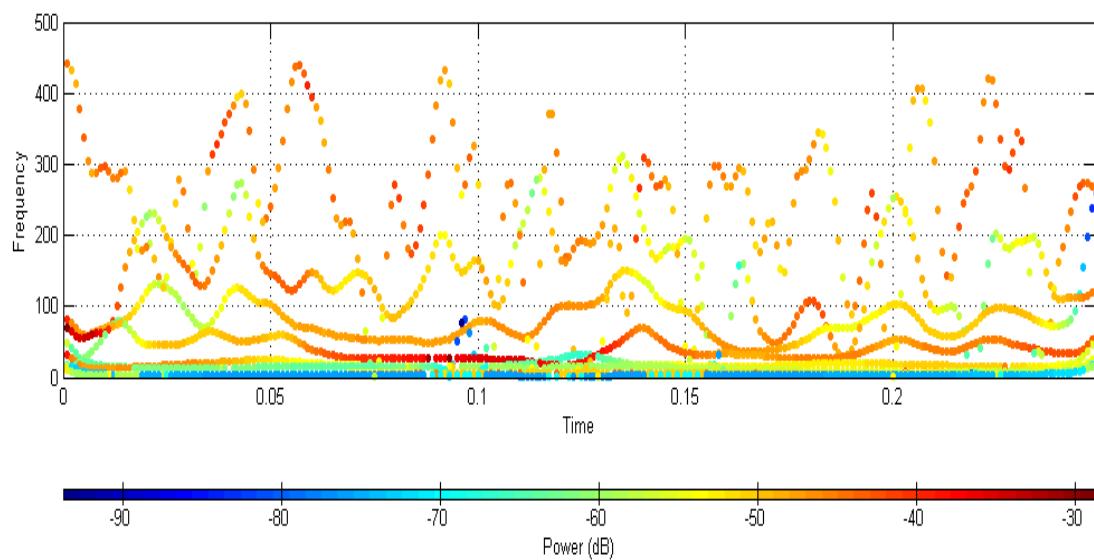


Figura 2-12. Espectro Hilbert-Huang sin actividad de EMG.

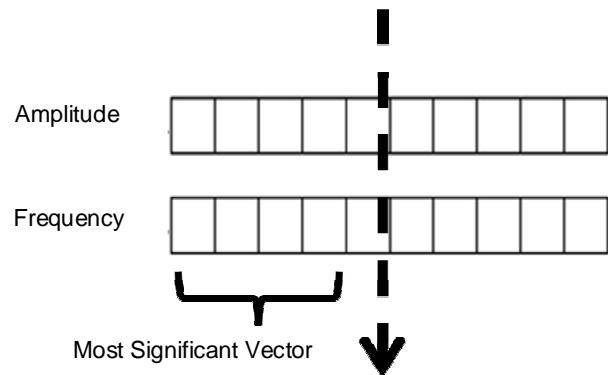


Figura 2-13. Método para la obtención de la frecuencia cuya amplitud es máxima.

Frecuencia media instantánea (MNIF).

La frecuencia media instantánea es una característica que combina la información presente en la derivada de la fase con respecto al tiempo de cada una de las IMFs pero también incluye información de las amplitudes de la señal, es una medida de la frecuencia ponderada [20,21]. Se define la frecuencia media ponderada [21] para cada IMF con N muestras como:

$$WMNF(i) = \frac{\sum_{j=1}^N f_i(j) a_i^2(j)}{\sum_{j=1}^N a_i^2(j)} \quad 2.20$$

Esta frecuencia media instantánea puede usarse como una medida de la frecuencia media de la señal [20]. Finalmente obtenemos la frecuencia media instantánea [21] para las n IMFs como:

$$MNIF = \frac{\sum_{i=1}^n \|a_i\| WMIF(i)}{\sum_{i=1}^n \|a_i\|} \quad 2.21$$

2.4.3 Clasificación

Una vez que ya se ha seleccionado el vector de características, el siguiente paso consiste en la clasificación. Un clasificador es una herramienta matemática que permite separar un cierto grupo de datos en base a sus características distintivas. Existen muchos tipos de clasificadores, entre ellos están los siguientes: máquinas de soporte vectorial (SVM), redes neuronales artificiales (NN), modelos ocultos de Markov, K-vecinos más cercanos, clasificadores bayesianos, lógica difusa, y análisis de discriminante lineal (LDA)[13].

Redes Neuronales

Las redes neuronales artificiales surgen como un intento de modelar el funcionamiento biológico de las neuronas [21]. Una red neuronal tiene como unidad básica a la neurona la cual se encarga de recibir estímulos del exterior (entradas) las cuales son multiplicadas por un vector de pesos y luego sumadas:

$$net = \sum_{i=0}^n w_i x_i \quad 2.22$$

Donde x_i es la entrada a la neurona y w_i es el peso asociado con la entrada i.

El siguiente paso consiste en aplicar una función de activación a la suma ponderada y el resultado es usado como salida de la neurona. Existen varios tipos de funciones de activación: la función lineal, la función escalón, la función lineal por partes y las funciones sigmoidales, figura 2-14. Una red neuronal consiste en agrupaciones de neuronas por medio de capas. Una red neuronal *feedforward* está compuesta por un arreglo de capas de neuronas donde la salida de las neuronas de la capa k es la entrada de las neuronas de la capa k+1, figura 2-15.

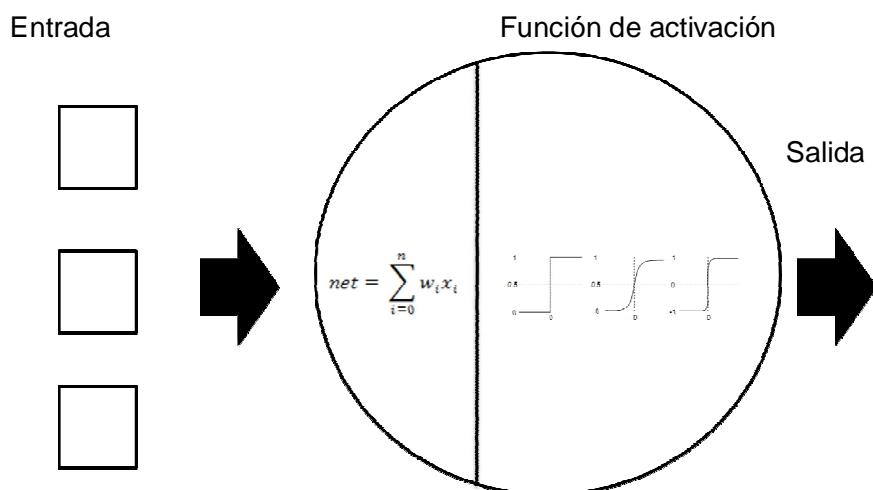


Figura 2-14. Neurona artificial [13].

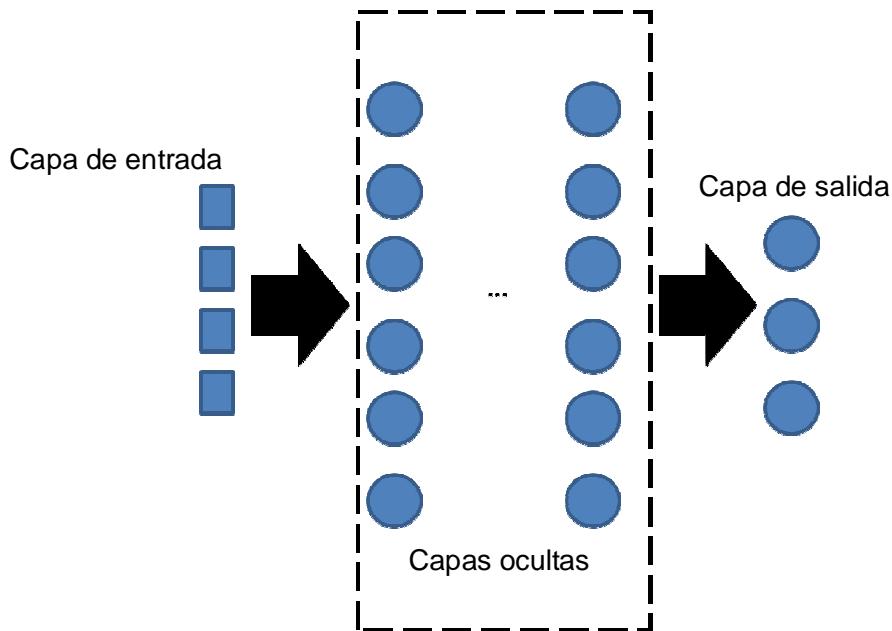


Figura 2-15. Red neuronal con una capa de entrada, una capa oculta y una capa de salida [13].

Algoritmo de retro-propagación (*Back propagation*)

Una red neuronal con retro-propagación BPNN, consiste en una red *feedforward* que tiene al menos una capa oculta, una capa de entrada y una de salida. Cada capa de neuronas realiza la suma ponderada seguida por la aplicación de la función de activación. El algoritmo de retro-propagación se basa en el descenso del gradiente para minimizar el error cuadrático medio del error (diferencia entre la salida obtenida y la deseada) [21].

Pasos para el algoritmo de retro-propagación [13].

1. Se crea una red *feedforward* con n_{in} nodos de entrada, n_{hidden} neuronas ocultas, n_{out} neuronas de salida.
2. Se inicializan los pesos de la red a valores aleatorios pequeños.

3. Se establece una condición de paro, generalmente hasta encontrar un error cuadrático medio lo bastante pequeño y para cada par $\langle X, T \rangle$, se hace lo siguiente:
 - a. Se calcula la salida de la red con el vector de entrada X (*feedforward*).
 - b. Se calcula el error para cada neurona k de salida (retro-propagación). $\delta_k = o_k(1 - o_k)(t_k - o_k)$
 - c. Para cada neurona oculta, se calcula su error: $\delta_h = o_h(1 - o_h) \sum_{k \in outputs} w_{kh} \delta_k$
 - d. Se actualizan todos los pesos de la red.

$$w_{ji} = w_{ji} + (\eta \delta_j x_{ji})$$

Donde X es el vector de entrada de la red y T es el vector salida deseada, n_{in} son los nodos de entrada, n_{hidden} número de neuronas en la capa oculta, n_{out} número de neuronas en la capa de salida. t_k es el valor deseado para la k -neurona de salida, $output$ es el conjunto de neuronas de salida de la red; w_{kh} es el peso de la neurona oculta h a la neurona de salida k ; η es la tasa de aprendizaje; x_{ji} es la entrada del nodo i a la neurona j ; w_{ji} es el pesos asociado del nodo i a la neurona j [3].

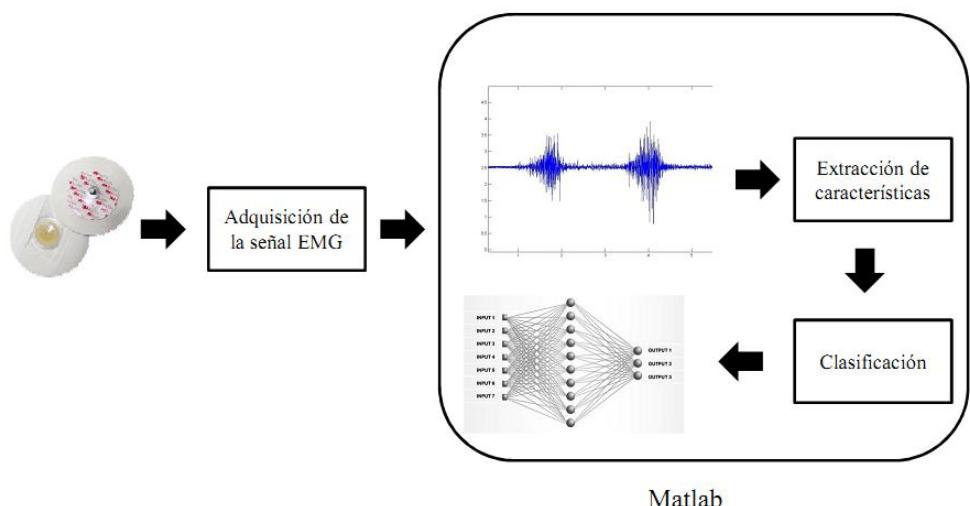
Capítulo 3: Desarrollo

3.1 Introducción

En este capítulo se explica el desarrollo de dos métodos para el reconocimiento de patrones en las señales de EMG. En el primer método se describe el desarrollo y la construcción de un prototipo de adquisición para señales de EMG, así como también, la selección de los vectores de características para realizar el reconocimiento de 3 movimientos de la pierna. En el segundo método se describe el desarrollo de un sistema para la estimación de la posición y velocidad angular de la pierna durante ejercicios de extensión y flexión usando Redes Neuronales Artificiales.

3.2 Método I: Reconocimiento de patrones en señales de EMG

El primer método consiste en el desarrollo y construcción de un prototipo para la adquisición de señales de EMG. Se ha desarrollado un programa en Matlab para la extracción de características, así como también, la implementación de la etapa de clasificación usando Redes Neuronales. El sistema para el reconocimiento de patrones en las señales de EMG tiene las siguientes etapas: Etapa de adquisición, Etapa de extracción de características y Etapa de Clasificación, figura 3-1. En la etapa de adquisición se describe el acondicionamiento de la señal vía hardware. En la etapa de extracción de características se presentan las características seleccionadas para ser evaluadas en el proceso de reconocimiento de patrones. Finalmente, en la etapa de Clasificación, se entrena una Red Neuronal con los vectores de características seleccionados en la etapa anterior.



Matlab

Figura 3-1. Diagrama de las etapas del sistema de adquisición y clasificación de señales de EMG.

La selección del número de canales y músculos para la obtención de los registros de EMG es una parte vital del desarrollo del prototipo. Es importante tratar de minimizar el número de canales, pero al mismo tiempo, obtener la mayor cantidad de información de los músculos monitoreados. La principal razón para mantener pequeño el número de canales es porque de esta manera, se tiene un sistema menos costoso y mucho más compacto. Es importante seleccionar aquellos músculos que presenten la mayor actividad de EMG durante los movimientos realizados y que sean lo suficientemente grandes para la colocación de los electrodos. La tabla 3-1 muestra una recopilación de algunos trabajos en los que se destaca el número de canales, las características y clasificadores usados para el reconocimiento de patrones.

Tabla 3-1. Algunos trabajos sobre reconocimiento de patrones de señales de EMG.

Titulo	Vector de Características	Clasificador	Número de Canales y equipo usado
Classification of prehensile EMG patterns with simplified fuzzy ARTMAP networks [28]	Máximo en la amplitud de la señal de EMG rectificada y filtrada por un <i>Moving Average</i> .	Simplified Fuzzy ARTMAP Neural Networks	4 (Muscle Tester ME3000, by Mega Electronics, Ltd)
Fuzzy Wavelet Packet based Feature Extraction Method for Multifunction Myoelectric Control. [29]	WPT de señales de EMG y uso de Fuzzy c-means (FCM) para juzgar la conveniencia de las características. Reducción de dimensionalidad con PCA.	Perceptrón Multi-capa.	16 (datos de University of New Brunswick in Canada)
Blind Source Separation Based Classification Scheme for Myoelectric Prosthesis Hand [30]	RMS	Red Neuronal (Backpropagation)	4 (Delysis eight channel sEMG acquisition system)
Evaluation of Support Vector Machines in Upper Limb Motion Classification Using Myoelectric Signal. [14]	MAV, WL, ZC, SSC, RMS y AR [16]	Soport Vector Machine (SVM)	4 (BiometricsLtd SX230)
Practical Surface EMG Pattern Classification by Using a Selective Desensitization Neural Network. [7]	IEMG	Red neuronal de Desensitización	10 (Personal-EMG by Oisaka Electronic Device Ltd)
Recognition of Lower Limb Muscle EMG Patterns by using Neural Networks during the Postural Balance Control. [31]	Integral of the absolute value (IAV), VAR, ZC, Central Frequency	Redes Neuronales (Backpropagation)	5 (MyoSystem 1400, Noraxon USA, Inc.)
Fuzzy EMG Classification for Prosthesis Control [32]	MAV, Mean Absolute Value Slope (MAVSLP), ZC, Wave Complexity (WC)	FuzzySystem	1 (Single bipolar elec-trode pair)
The Development of a Virtual Myoelectric Prosthesis Controlled by an EMG Pattern Recognition System Based on Neural Networks [33]	Coeficientes AR	Redes Neuronales (Backpropagation)	5
Application of Wavelet Analysis in EMG Feature Extraction for Pattern Classification [34]	MAV, RMS (reconstrucción Wavelet discreta, 4 niveles)		2
Wavelet Transform Moments for Feature Extraction from Temporal Signals [35]	100 coeficientes DWT por canal.	SVM	4
Caracterización Multicanal no lineal de señales EMG con la Transformada Hilbert-Huang [36]	Momentos estadísticos del espectro Hilbert-Huang	Clasificadores Bayesianos	3 (DelsysBagnoli 4)

Un factor muy importante para la consideración del número de músculos a monitorear, es el tipo de movimiento que se realizará. En nuestro caso solo se considerarán los movimientos de la pierna en el plano sagital, por lo tanto, solo se pueden realizar los movimientos de extensión y flexión de la pierna. En base a la tabla 3-1 y pensando en que se debe de construir un circuito de adquisición de señales para cada canal, se optó por usar un sistema de 4 canales. Para la selección de los músculos se tomó en cuenta la *Physiological Cross-sectional Area* (PCA) [37] el cual nos da los siguientes porcentajes sobre el área que ocupan: *Rectus Femoris* (8%), *Vastus Lateralis* (20%), *Semitendinosus* (3%), y *Biceps Femoris* (10%), estos músculos cubren un total de 41% del área de la sección transversal de todo el muslo. El área restante es ocupada por: *Vastus Medialis* (15%), *Semimembranosus* (10%), *Vastus intermedius* (13%), *Gastrocnemius* (19%), *Sartorius* (1%), y *Gracilis* (1%) [38]. Finalmente, se decidió monitorear los siguientes cuatro músculos: *Vastus Medialis*, *Vastos Lateralis*, *Biceps Femoris* y el músculo *Semimembranosus*. Estos músculos se muestran en la figura 3-2.

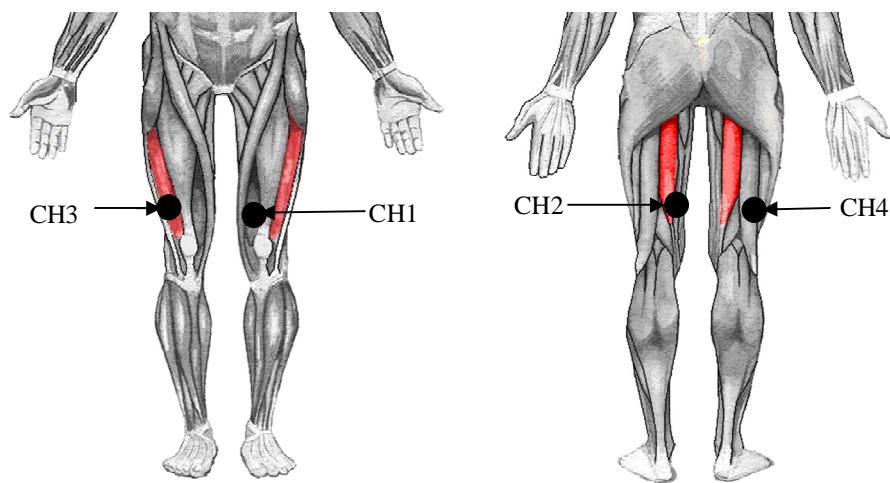


Figura 3-2. Diagrama de las etapas del sistema de adquisición y clasificación de señales de EMG [54].

3.2.1 Etapa de Adquisición de la señal de EMG

Esta etapa consiste en desarrollar una tarjeta de circuito impreso para la adquisición de la señal de EMG, figura 3-3. El circuito impreso consta de una etapa de amplificación y una etapa de filtrado (filtro pasa banda 20-500Hz). Los datos adquiridos serán digitalizados usando una tarjeta de adquisición de datos (DT9812). Ésta información será almacenada para la construcción de una base de datos de las señales de EMG para su uso en el entrenamiento del clasificador. La figura 3-4 muestra el diagrama esquemático del circuito de adquisición de señales de EMG de un solo canal.

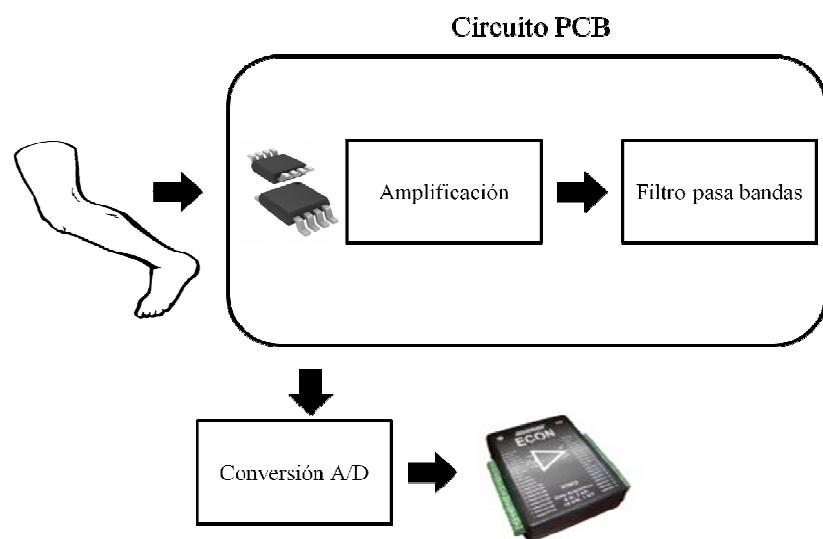


Figura 3-3. Diagrama esquemático de la etapa de adquisición de señales de EMG.

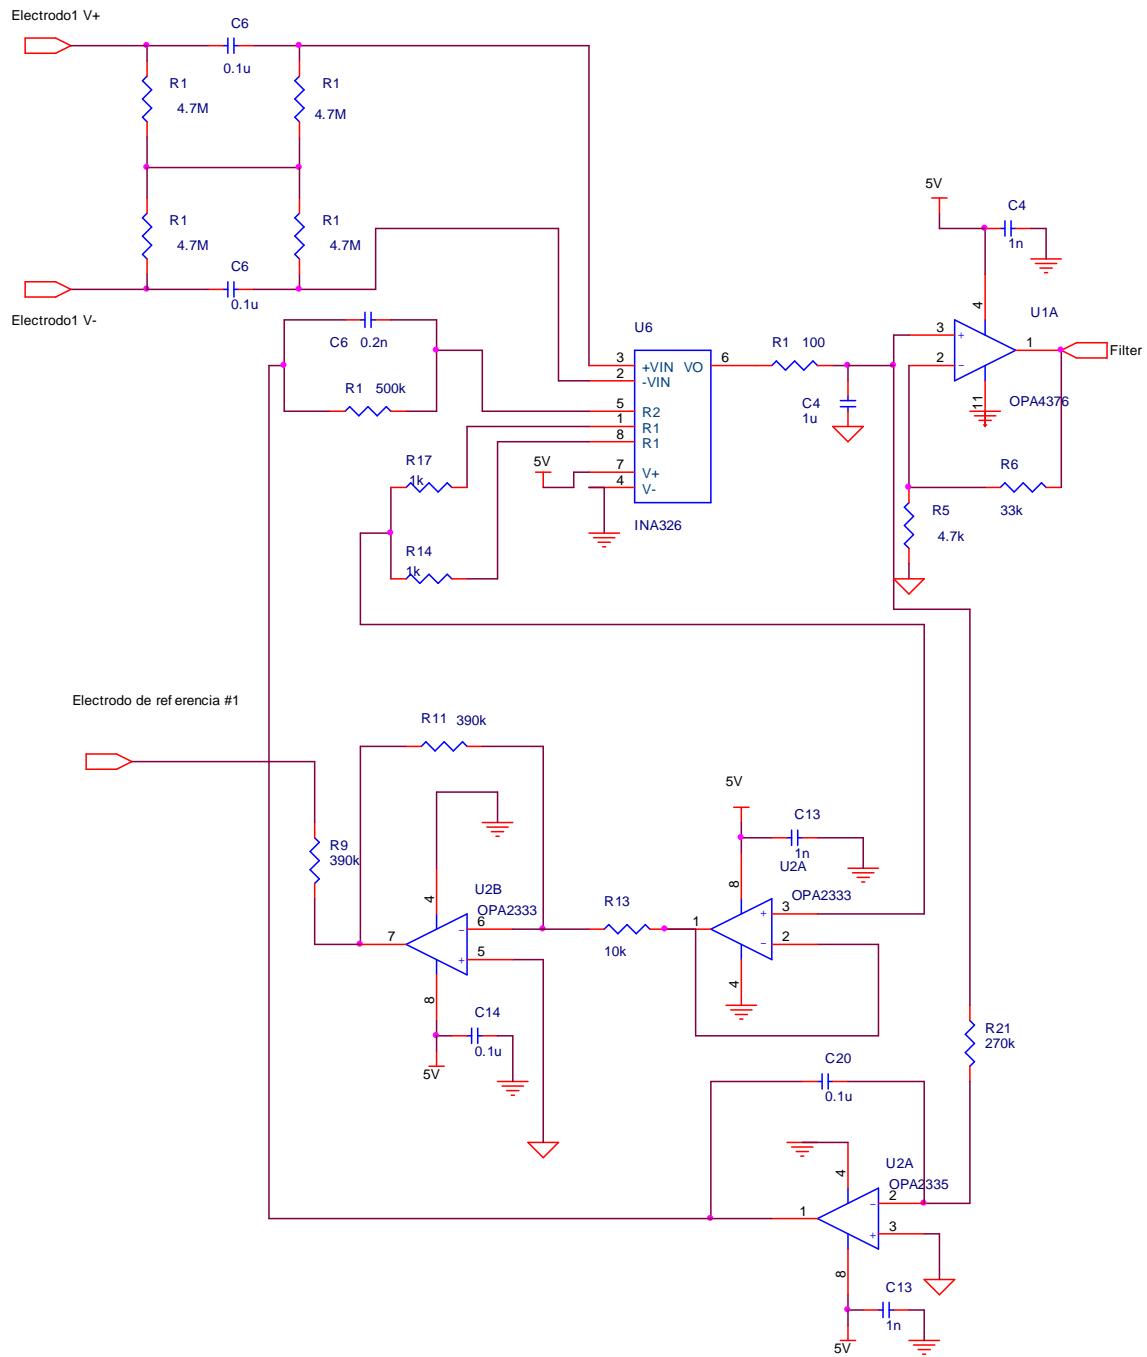


Figura 3-4.Circuito de EMG de un solo canal

El circuito fue diseñado para trabajar a 5V y es alimentado por una pila de 9V, por tal razón, se diseño una etapa para la regulación del voltaje y la generación de la referencia de la señal o tierra virtual. Este nivel de voltaje estará fijado a la mitad de la fuente de alimentación regulada (5V), por lo que el voltaje de tierra virtual será de 2.5V. Se usó un amplificador operacional OPA2335 como buffer para mantener el voltaje de tierra virtual. El circuito de esta etapa se muestra en la figura 3-5.

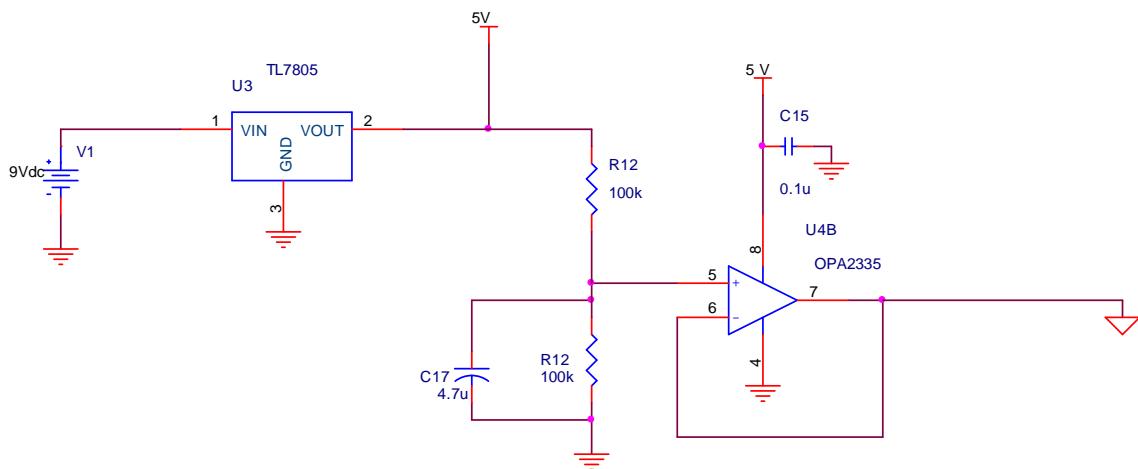


Figura 3-5. Diagrama esquemático de la etapa de alimentación y Tierra virtual.

El amplificador de instrumentación debe operar a bajo voltaje (3.3V – 5V) y tener un alto CMRR (>90dB). El amplificador seleccionado fue en INA326 y fue configurado para proporcionar una ganancia de 500. Una etapa de amplificación con una ganancia de 8 para poder alcanzar una ganancia total de 4000 es realizada. Una red de resistores y capacitores fue añadida a la entrada del amplificador de instrumentación con el fin de mejorar el CMRR. Esta red actúa como filtro pasa altas para la diferencia de voltaje entre las dos entradas del amplificador y también provee una trayectoria de CD para las corrientes de

polarización del amplificador [39, 40]. La configuración de la adquisición de la señal mioeléctrica es del tipo diferencial, es decir, se utilizan dos electrodos para obtener la diferencia de potencial y también se hace uso de un electrodo de referencia el cual no se debe ubicar en la misma zona que los otros dos electrodos. El electrodo de referencia no se encuentra físicamente conectado a tierra por lo que para evitar variaciones de voltaje se debe hacer uso del circuito de RLD (*Right Leg Driven*). El circuito de RLD sirve para reducir los voltajes de modo común que son ingresados al amplificador de instrumentación por el cuerpo. El RLD se encarga de tomar el promedio del voltaje de modo común del amplificador de instrumentación y posteriormente invierte la señal y se la suma al potencial de cuerpo. El diseño de este circuito se basó en el ejemplo propuesto por Texas Instruments (TI), figura 3-6.

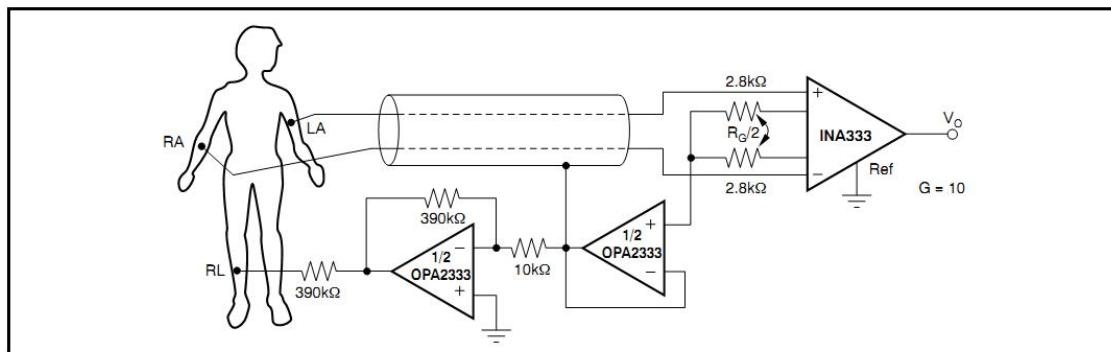


Figura 3-6.Circuito de RLD [55]

Un circuito integrador fue implementado para disminuir el voltaje de offset a la salida del amplificador de instrumentación. Este circuito tiene la función de reducir el ruido del voltaje de entrada y el ruido $1/f$ [40]. Este circuito se diseñó tomando en cuenta la frecuencia más alta esperada (500Hz) y considerando 10 veces el

tiempo de descarga del capacitor. Los valores de R y C se obtuvieron de la siguiente manera [41]:

$$f = \frac{1}{T}, T = RC \quad 3.1$$

$$\frac{1}{50} = RC = 0.2 \approx (270k\Omega)(0.1uF) \quad 3.2$$

Después de la adquisición de la señal, se procede a hacer un filtrado pasa-bandas de 20-500Hz usando un filtro activo pasa altas y luego uno pasa bajas, figura 3-7. Los valores de los capacitores y resistores fueron calculados como sigue:

Diseño del filtro pasa altas

$$f_c = \frac{1}{2\pi RC} \text{ usando } C = 0.1uF \text{ y } f_c = 20 \quad 3.3$$

$$(20)2\pi C = \frac{1}{R}R \approx 82k\Omega \quad 3.4$$

Diseño del filtro pasa bajas

$$f_c = \frac{1}{2\pi RC} \text{ usando } C = 0.1uF \text{ y } f_c = 500 \quad 3.5$$

$$(500)2\pi(0.1u) = \frac{1}{R}R \approx 3.3k\Omega \quad 3.6$$

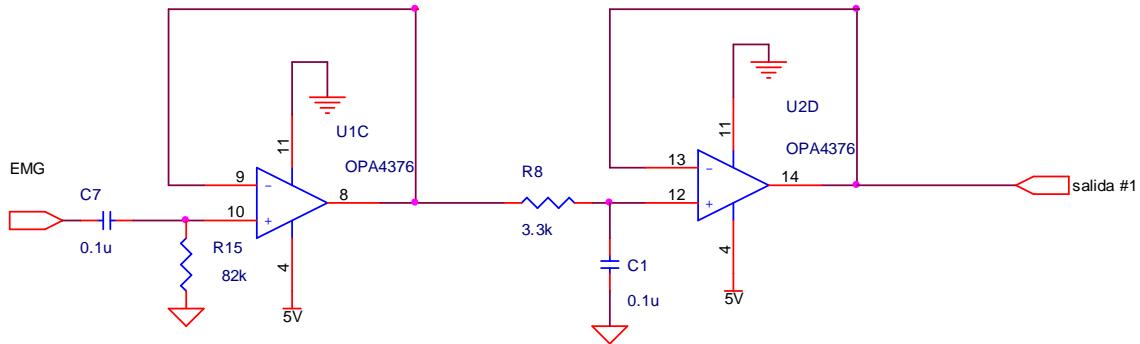


Figura 3-7.Filtro pasa bandas (20-500Hz).

Diseño para la adquisición de 4 canales

Para realizar la tarea de reconocimiento de patrones en las señales de EMG, se debe tomar en cuenta que cada movimiento realizado por la pierna involucra más de un músculo. Es por esta razón que es necesario tener un sistema capaz de registrar varias señales de EMG al mismo tiempo. Para el diseño del circuito de EMG de cuatro canales, se replicó el circuito mostrado en la figura 3-4. Para evitar tener 4 electrodos de referencia (uno por cada circuito) se realizó una etapa de promediado. Se promedio el voltaje proveniente de cada circuito RLD y esta salida fue conectada a un único electrodo de referencia, figura 3-8.

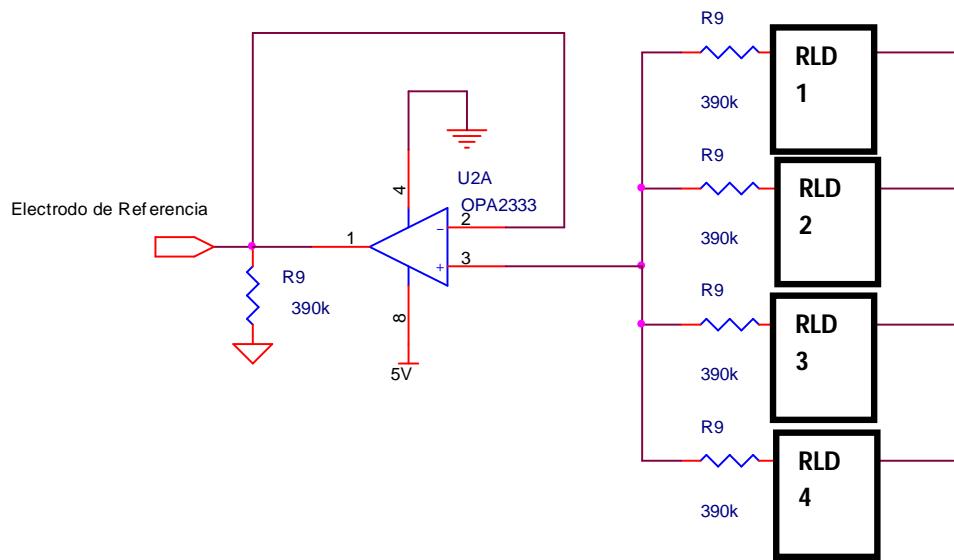


Figura 3-8.Circuito promediador para el electrodo de referencia.

Digitalización de las señales de EMG

Para la digitalización de las señales se utilizó una tarjeta de adquisición de datos DT9812 usando una resolución de 12 bits. Los datos fueron adquiridos mediante un programa implementado en LabVIEW que se encarga de hacer la conexión entre la tarjeta y la PC. Posteriormente fueron almacenados en un archivo de texto.

Interfaz Gráfica para análisis de patrones de EMG

Se desarrolló una interfaz de usuario (GUI) usando Matlab para la selección de los patrones de EMG. La interfaz cuenta con las siguientes características:

- **Graficación:** Seleccionar el archivo de texto generado por LabVIEW y graficar las señales de sEMG provenientes de los 4 canales. Figura 3-9.

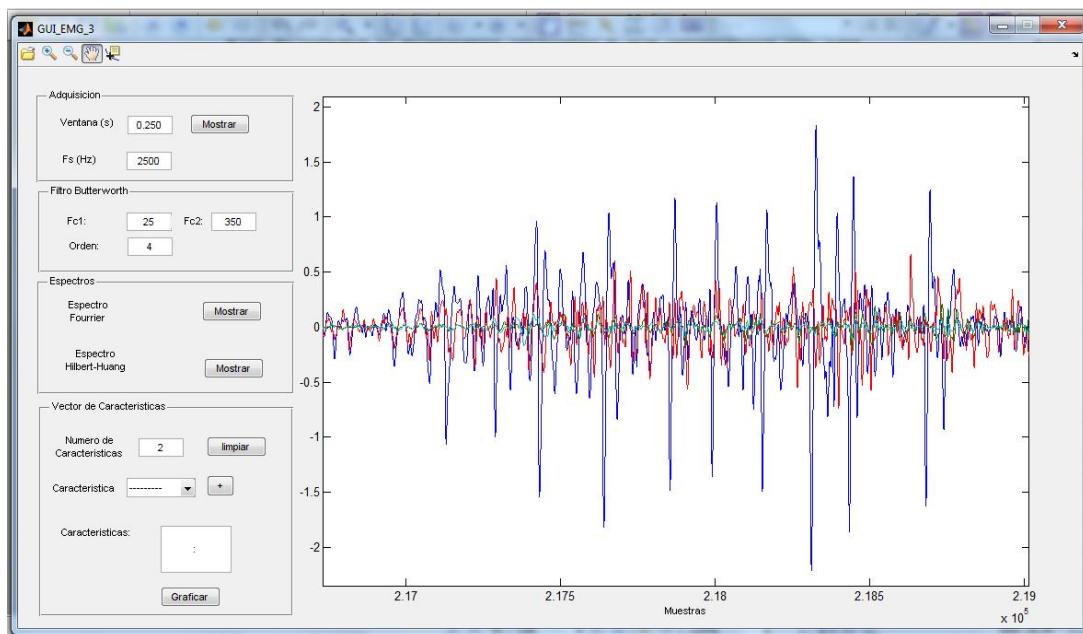


Figura 3-9. Interfaz de usuario usada para la selección de los patrones de EMG.

- Adquisición de la señal: Se presentan las opciones para poder seleccionar el segmento temporal de la señal de EMG para analizar. En esta sección se establece la frecuencia de muestreo con la que han sido adquiridos los datos.



Figura 3-10. Selección del segmento temporal y la frecuencia con la que han sido adquiridos los datos.

- Filtro pasa bandas: Aplica un filtro digital pasa-bandas Butterworth a la señal de EMG con las características especificadas por el usuario.



Figura 3-11. Parámetros del filtro Butterworth.

- Visualización de los espectros en el dominio de la frecuencia: Se presenta la opción de poder visualizar el espectro de Fourier o visualizar el espectro usando la transformada Hilbert-Huang.



Figura 3-12.Opciones para visualizar el espectro de Fourier y el espectro Hilbert-Huang.

- Construcción de un vector de características: Algunas características en el dominio del tiempo están disponibles para poder ser visualizadas (Media, RMS, Desviación Estándar y Varianza). Es posible seleccionar cuantas características por canal se deseen.



Figura 3-13. Construcción de vectores de características.

3.2.2 Segmentación y extracción de características

Se han hecho pruebas con dos ventanas temporales para la segmentación de los datos y la extracción de las características. El tamaño de la ventana fue elegido de acuerdo a las restricciones de tiempo real cuyo límite no debe superar los 300ms [3]. La primera ventana temporal es de 100ms y la segunda de 250ms. La segmentación usada es del tipo disjunta.

La extracción de características consiste en la selección de valores que son representativos para un determinado conjunto de datos. El número de características extraídas suele variar de problema a problema. En [15] se recomienda el uso de 4 características por canal, sin embargo, este parámetro no es definitivo y en muchos casos es posible representar una clase de movimiento usando menos de 4 características. Las características fueron seleccionadas luego de consultar los trabajos mostrados en la tabla 3-1. Se procuró incluir aquellas características que han sido las más usadas y que además han dado buenos resultados. De igual forma, se han propuesto dos nuevas características basadas en la transformada Hilbert-Huang usando la MNIF y HHAF. Las características seleccionadas son mostradas en la tabla 3-2.

Tabla 3-2. Características propuestas para el reconocimiento de patrones en señales de EMG.

Características	Dominio
MAV	Tiempo
RMS	Tiempo
STD	Tiempo
VAR	Tiempo
WL	Tiempo
ZC	Tiempo
MNIF	Tiempo-frecuencia
HHAF	Tiempo-frecuencia
DWT(árbol de descomposición)	Tiempo-frecuencia

3.2.3 Materiales y métodos

Para la etapa de clasificación se han propuesto tres clases de movimiento con la pierna. Estos movimientos fueron seleccionados de acuerdo a las limitaciones de movimiento únicamente en el plano sagital con las que cuenta la prótesis [2]. Los movimientos seleccionados son: dorsiflexión, extensión y flexión de la pierna. La posición inicial o de reposo corresponde a la persona sentada con el pie apoyado en el suelo, figura 3-14. Los movimientos seleccionados son los más básicos que se pueden realizar con la pierna y están caracterizados por la activación de los principales músculos del muslo: *Vastus Medialis*, *Vastus Lateralis*, *Rectus Femoris*, *Biceps Femoris*, *Semitendinosus/Semimembranosus*.

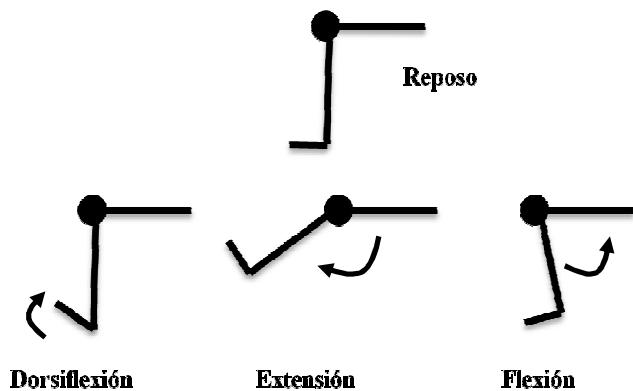


Figura 3-14. Tres clases de movimiento para el experimento.

Descripción del experimento

El experimento consiste en registrar la actividad Mioeléctrica de 4 músculos del muslo para poder hacer una clasificación de movimientos. Se considerarán tres movimientos: dorsiflexión, extensión y flexión de la pierna. Los registros serán realizados sobre un sujeto cuya edad oscila entre los 20 a 30 años, saludable y sin antecedentes de enfermedades musculares. Para la implementación futura en la prótesis transfemoral, se propone que el sistema sea basado únicamente en la información de EMG de la persona que usará el dispositivo, de esta manera, el sistema se adaptará a las características particulares del usuario.

Materiales:

- Hardware para adquisición de señales de EMG
- Electrodos superficiales de Ag/AgCl
- Matlab
- Tarjeta de adquisición de datos DT9812.

Procedimiento

El procedimiento es como sigue: la persona permanecerá sentada en una silla en la posición inicial o de reposo y posteriormente se le indicará que realice cualquiera de los 3 movimientos. Se realizarán 25 repeticiones por cada movimiento y se tratará de que los movimientos sean realizados de una manera “natural”, es decir, que la fuerza aplicada sea moderada. Los movimientos serán realizados de forma calmada y con descansos de 5 a 10 segundos para de evitar la fatiga muscular. De este conjunto de datos registrados (*dataset*) se usarán 20 patrones por cada movimiento para el conjunto de entrenamiento del clasificador. Los 5 conjuntos de datos restantes serán destinados al conjunto de prueba. Finalmente tendremos una base de datos de entrenamiento de $20 \times 3 = 60$ datos, mientras que el conjunto de prueba estará formado por $5 \times 3 = 15$ datos. Posteriormente los datos serán filtrados y se realizará la extracción de características, figura 3-15.

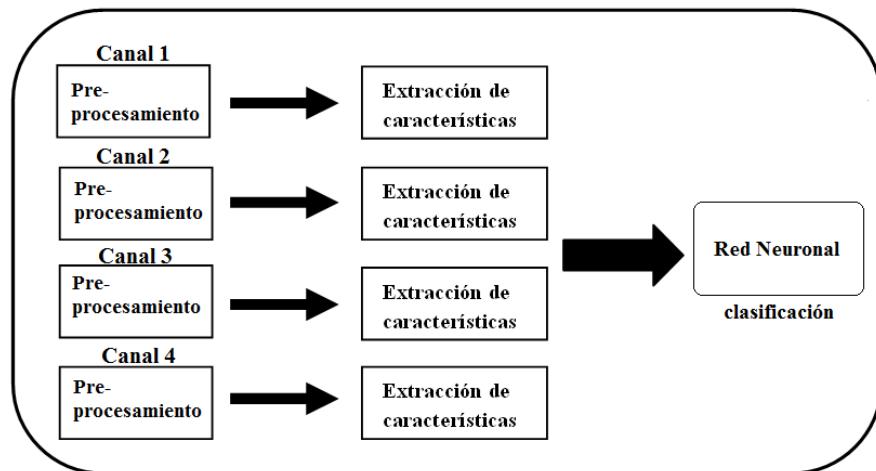


Figura 3-15. Método para la adquisición y clasificación de las señales de EMG

3.2.4 Clasificación

Se utiliza como clasificador una Red Neuronal con un entrenamiento por retro-propagación que utiliza el algoritmo de Levenberg-Marquardt. La configuración de la red es la siguiente: una capa de entrada, una capa oculta y una capa de salida. Las Redes Neuronales han sido exitosamente usadas para la clasificación de las señales de EMG [29, 30, 31]. Una de sus principales ventajas es que pueden ser implementadas en Hardware y son aptas para aplicaciones de tiempo real. Se harán pruebas variando el número de neuronas de la capa oculta, primero usando la misma cantidad que en la capa de entrada y luego con el doble de esta cantidad.

3.3 Método II: Estimación del ángulo y velocidad durante la flexión y la extensión de la pierna

Las señales de sEMG contienen información que proviene directamente desde el cerebro que es usada para regular la fuerza, la posición y la velocidad con la que se deben de realizar los movimientos deseados. Sin embargo, hay muchos inconvenientes, entre ellos tenemos al retraso electromecánico (REM) [42] y la fatiga muscular. El retraso electromecánico se define como el tiempo de retraso entre el inicio de la actividad eléctrica en el músculo y el inicio de la acción motriz. El REM ha sido localizado entre los 30 y los 100ms [42]. La manifestación de la fatiga muscular es típicamente monitoreada durante movimientos isométricos sostenidos y se presenta como un incremento en la amplitud de la señal y una reducción del espectro en la banda de frecuencias altas (suele llamarse compresión del espectro de EMG) [20]. Para este trabajo se desarrolló un sistema para la estimación de la posición y velocidad angular durante ejercicios de flexión y extensión de la pierna usando Redes Neuronales. El problema de la estimación angular ha sido ampliamente estudiado en la literatura [43-48] para el control de prótesis o con propósitos de rehabilitación, en este contexto, el uso de redes neuronales ha dado muy buenos resultados [43, 47, 48].

3.3.1 Materiales y Métodos

El diagrama de bloques del método propuesto es presentado en la figura 3-16. El objetivo es estimar la posición y la velocidad angular de la pierna usando únicamente las señales de sEMG. Las señales serán pre-procesadas para posteriormente realizar la extracción de características. Estas características serán utilizadas para el entrenamiento de la Red Neuronal (NN). Se ha usado un electrogoniómetro fijado a una maquina de extensión de piernas para medir la posición angular. Como salida u objetivo de la Red Neuronal se han usado la posición y la velocidad angular 50 ms después de la muestra actual, esto se hace con el fin de evitar el retraso electromecánico.

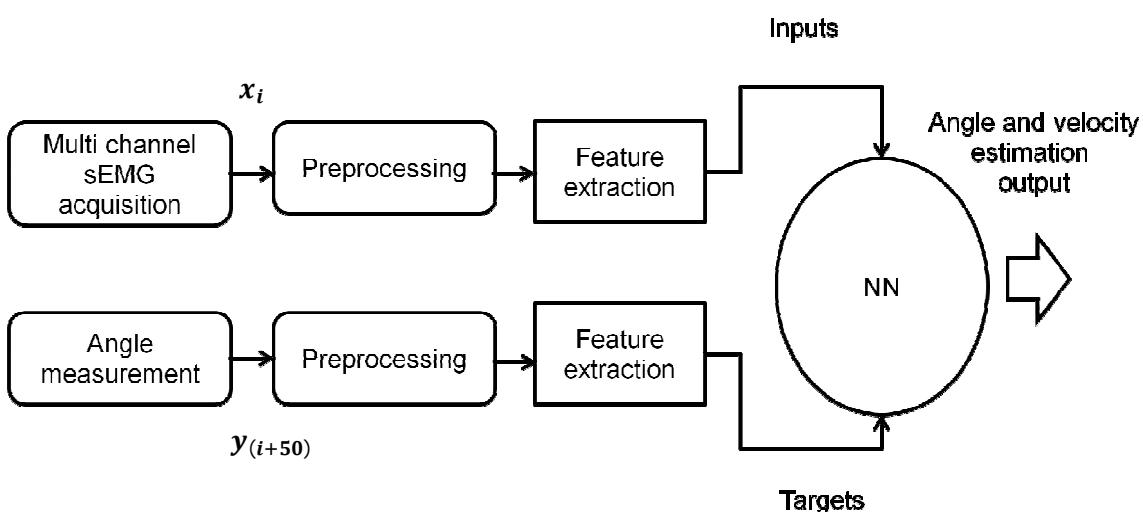


Figura 3-16. Diagrama de bloques del método propuesto para la estimación del ángulo y la velocidad. . x_i corresponde a la muestra de la señal de sEMG en el tiempo i y $y_{(i+50)}$ corresponde a la posición angular 50ms después del tiempo i .

Materiales

-Electromiógrafo inalámbrico (BTS FreeEMG).

-Maquina de extensión de piernas.

-Electrogoniómetro

Protocolo experimental

El experimento consiste en realizar ejercicios de flexión y extensión de la pierna. Para realizar estos ejercicios se usará una máquina de extensión de piernas la cual permite variar el peso levantado por el usuario. Se realizará una calibración basada en la carga máxima levantada por el sujeto, a esta carga se le denomina MRL por las siglas de la expresión en inglés *Maximum Reachable Load*. El protocolo fue dividido en dos días. En el primer día se realizará la prueba de máxima carga (MRL). En el segundo día se realizará el experimento de flexión y extensión de pierna.

Día 1: en este día el sujeto debe realizar una prueba para encontrar la máxima carga que es capaz de levantar sin problemas (MRL). El sujeto deberá estar sentado en la máquina de extensión de piernas en la posición inicial, figura 3-17 a) y deberá realizar varias extensiones de piernas con diferentes cargas. La carga deberá ser mantenida durante 5 segundos, figura 3-17 b). Se comenzará con una carga de 10kg y se irá incrementando por 5kg cada vez. Este proceso se detendrá cuando el sujeto no pueda realizar la extensión completa de la pierna. Este valor de carga alcanzado corresponderá al MRL y se usará como valor de referencia.

Día 2: En el segundo día el sujeto debe realizar un ejercicio con el 30% de la MRL. El ejercicio consiste en realizar dos contracciones isométricas durante 5 segundos con intervalos de 10 repeticiones de flexiones y extensiones de pierna. Se realizará un descanso de 5 segundos después de cada secuencia de ejercicios.

Durante estas pruebas se registrará tanto la actividad de sEMG, como el ángulo de flexión medido por el electrogoniómetro.

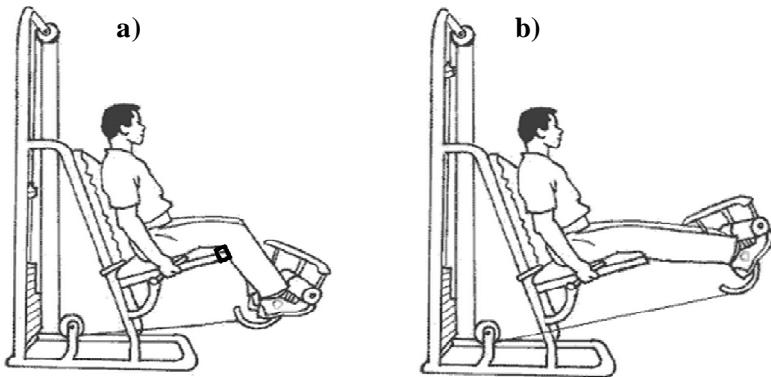


Figura 3-17. Experimento de extensión y flexión de la pierna usando la máquina de extensión de piernas.

Adquisición de datos

El experimento fue desarrollado en el laboratorio de ingeniería biomédica de la Universidad de Roma TRE con la colaboración de parte del grupo de investigación BioLab TRE. Las señales de sEMG fueron adquiridas de tres músculos de muslo: *Rectus Femoris*, *Vastus Lateralis*, *Vastus Medialis*, figura 3-18. La localización de los electrodos de superficie fue hecha acorde a las especificaciones del SENIAM [29]. La piel fue afeitada y limpiada usando alcohol para mejorar el contacto entre los electrodos. La adquisición de los datos fue hecha usando el sistema inalámbrico BTS FreeEMG con una frecuencia de muestreo de 1kHz y con 16 bits de resolución. Para el registro de la posición angular, el electrogoniómetro fue fijado a la máquina de extensión de piernas, figura 3-20. Los datos han sido adquiridos usando una tarjeta NIUSB6009 de *National Instruments* con una frecuencia de muestreo de 1kHz con 12 bits de resolución. La adquisición de las señales de EMG y de la posición angular fueron sincronizados para poder tener

los datos al mismo tiempo, este proceso fue hecho usando una rutina en LabView. El ángulo medido por el electrogoniómetro fue calibrado en el intervalo de [-90°, 0°], figura 3-21.

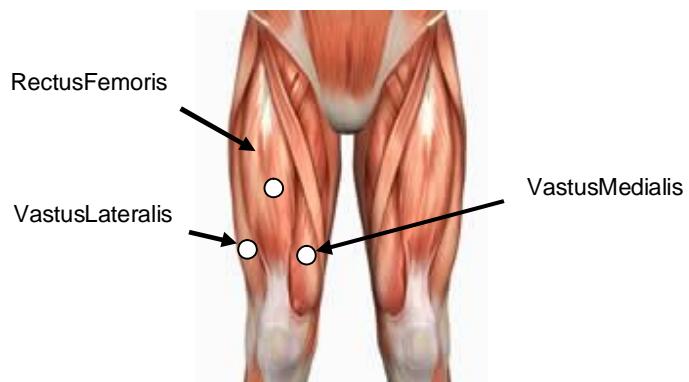


Figura 3-18. Localización de los electrodos de superficie.



Figura 3-19. Posicionamiento de los electrodos del sistema BTS FreeEMG.



Figura 3-20. Localización del electro goniómetro.

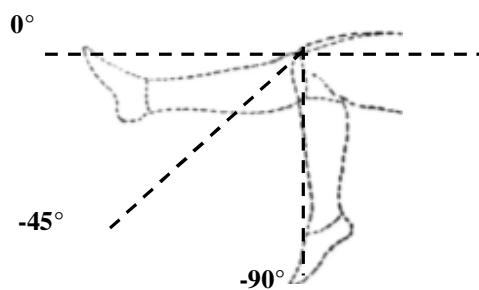


Figura 3-21. Posición angular medida por el electrogoniómetro.

Procesamiento de la señal

La señal de sEMG fue registrada y normalizada en el intervalo de [-1,1] usando el máximo valor de cada muestra. Se ha realizado una etapa de filtrado con un filtro digital Butterworth de cuarto orden con una banda de paso de 20-350Hz. La posición angular adquirida fue filtrada usando un filtro pasa bajas de orden 4 con una frecuencia de corte de 4Hz. Los filtros fueron implementados con ayuda de las herramientas del *toolbox* de procesamiento digital de señales de Matlab.

3.3.2 Extracción de características

En esta etapa hemos usado características en el dominio del tiempo extraídas en una ventana temporal del 100ms. Las características usadas son: STD, MAV, RMS y WL.

Extracción de características en la posición angular

Para propósitos del entrenamiento de la red neuronal, fue necesario usar la posición y la velocidad angular como objetivo o salida de entrenamiento. Esta información fue extraída por medio de dos características: el ángulo central y la velocidad angular. Estas características fueron calculadas 50ms después de la muestra actual para evitar en cierta medida el retraso electromecánico (30 - 100ms).

Angulo central

Dada la señal discreta $y = [y_1, y_2, \dots, y_i, \dots, y_N]$ donde y_i corresponde a la posición angular medida en el tiempo i , y N es el tamaño de la ventana de análisis, el ángulo central $\bar{\theta}$ es definido como:

$$\bar{\theta} = y_c$$

Donde $c = \text{int}(N/2)$ y $\text{int}(*)$ corresponde a la parte entera de la división.

Velocidad angular

Dada la señal discreta $y = [y_1, y_2, \dots, y_i, \dots, y_N]$, la velocidad angular es definida como:

$$\dot{\theta} = \frac{y_{i+1} - y_i}{x_{i+1} - x_i}$$

Donde N es el tamaño de la ventana de análisis.

3.3.3 Clasificación

Las redes neuronales nos permiten hacer un mapeo de la difícil relación entre las señales de sEMG y los parámetros relacionados a la velocidad y posición angular de la pierna. En su etapa de entrenamiento la Red Neuronal puede “aprender” haciendo una comparación entre su salida actual y su objetivo, de esta manera, puede hacer la corrección del error por medio de un ajuste de sus pesos. Para la tarea de estimación de velocidad y posición angular se han usado dos vectores de características. El primero (FV1) está formado por las siguientes características: MAV, RMS, STD y WL. El segundo (FV2) está formado por: MAV, RMS y WL. La Red Neuronal implementada es del tipo *Backpropagation* y ha sido implementada usando el *toolbox* de Redes Neuronales de Matlab. La red cuenta con dos capas ocultas y una de salida. Se ha usado una función de activación sigmoidal para las capa de salida y capas ocultas. El número de neuronas en cada capa oculta es igual a $2N$, siendo N el número de elementos del vector de características, figura 3-22. Para el vector de salida de la Red Neuronal se han usando las características de velocidad angular y ángulo central.

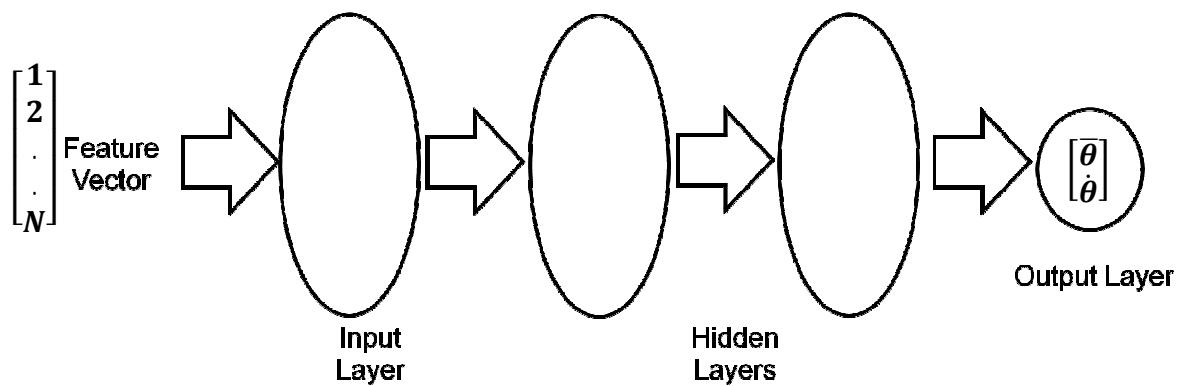


Figura 3-22. Estructura de la red neuronal. Se han usado la posición $\bar{\theta}$ y la velocidad angular $\dot{\theta}$ como salida de entrenamiento para la Red Neuronal.

Capítulo 4: Resultados

4.1 Introducción

En este capítulo se presentan los resultados obtenidos usando los dos métodos mencionados en el Capítulo 3. Método I: Reconocimiento de patrones en señales de EMG. Método II: Estimación de ángulo y velocidad durante la flexión y extensión de la pierna. Para el primer método se presentan las señales registradas por el hardware de adquisición de sEMG, así como también, los resultados de clasificación obtenidos usando los diferentes vectores de características. Para el segundo método, los errores de estimación para la posición y velocidad angular obtenidos de 3 diferentes sujetos son presentados. Este último método fue desarrollado en conjunto con el equipo de investigación del laboratorio Biolab3 de la Universidad de Roma TRE.

4.2 Método I: Reconocimiento de patrones en señales de EMG

4.2.1 Hardware de Adquisición de señales de EMG

Se construyó el circuito impreso del diseño esquemático presentado en el capítulo 3, figura 4-1. Este circuito cuenta con el hardware necesario para poder realizar la adquisición de 4 canales de sEMG simultáneamente y es alimentado con solo una pila de 9V.

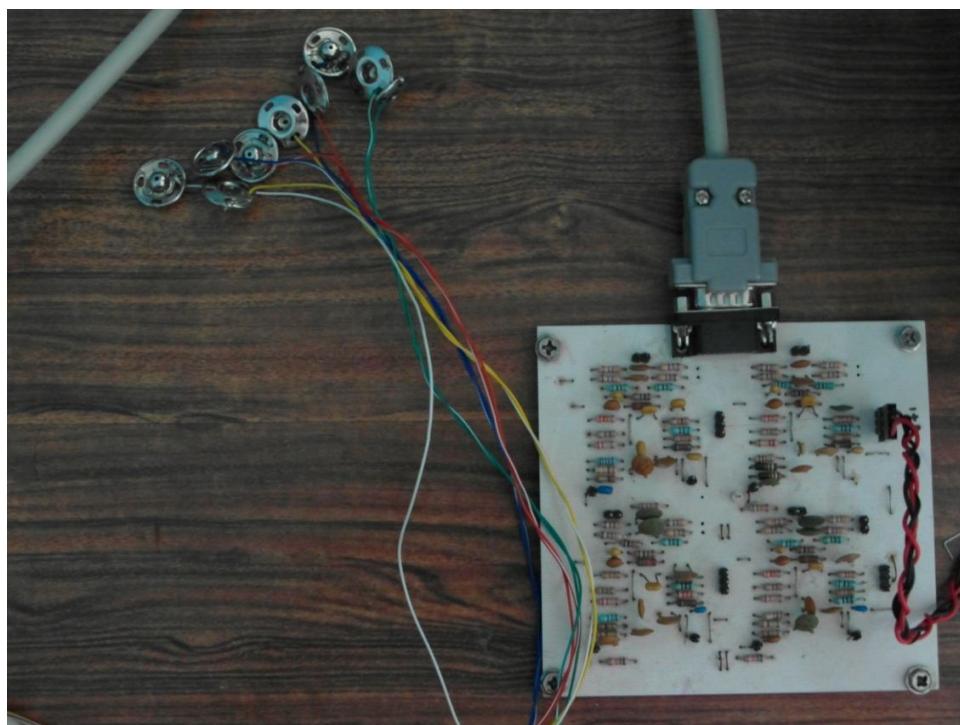


Figura 4-1.Circuito impreso para la adquisición de las señales de EMG.

Para la selección de los circuitos integrados utilizados en la construcción del circuito PCB se tomaron en cuenta varios factores. Se buscó seleccionar aquellos circuitos electrónicos que puedan operar a bajo voltaje (3-5V) y con una única fuente de alimentación. Esto es con el fin de tratar de disminuir el consumo de energía y de esta forma, poder mantener larga la vida útil de una batería. La reducción del espacio que ocupa el circuito es también un factor importante, es por esta razón que se optó por usar encapsulados del tipo superficial. Estos requerimientos serán de gran utilidad en la aplicación futura de una prótesis transfemoral, en donde se requerirá que el dispositivo trabaje a bajo voltaje y que sea lo más pequeño posible. Los componentes seleccionados que cumplen con estas características son los de la compañía Texas Instruments. Los modelos de

los chips seleccionados son mostrados en la tabla 4-1. Para la construcción de este prototipo se utilizaron los siguientes números de componentes: INA326 x 4, OPA2333 x 9, OPA2335 x 9, OPA4376 x 2. Con lo que tenemos un aproximado de 94.03 USD. Esta cantidad puede ser reducida al reemplazar algunos de los chips OPA2333 y OPA2335 (los cuales cuentan con 2 amplificadores operacionales) por el OPA4376 el cual cuenta con 4 amplificadores operacionales; de esta forma, se puede reducir la circuitería a: 4 INA326 y 12 OPA4376 y se tendría un total de 58.96 USD. Los precios fueron tomados de la página de Newark [50].

Tabla4-1.Componentes electrónicos usados en la construcción del prototipo.

Circuito integrado	Precio (USD)	Descripción
INA326	\$4.39	Instrumentation Amplifier
OPA2333	\$4.43	Operational Amplifier (Op-Amp)
OPA2335	\$3.30	Operational Amplifier (Op-Amp)
OPA4376	\$3.45	Operational Amplifier (Op-Amp)

Las señales de sEMG fueron adquiridas y filtradas usando el circuito impreso y posteriormente fueron digitalizadas con ayuda de la tarjeta de adquisición de datos DT9812 a una frecuencia de muestreo de 1kHz. El espectro de frecuencia de un registro de sEMG adquirido por el circuito PCB es mostrado en la figura 4-2. Después de la digitalización las señales fueron procesadas en Matlab para realizar la extracción de características y la clasificación.

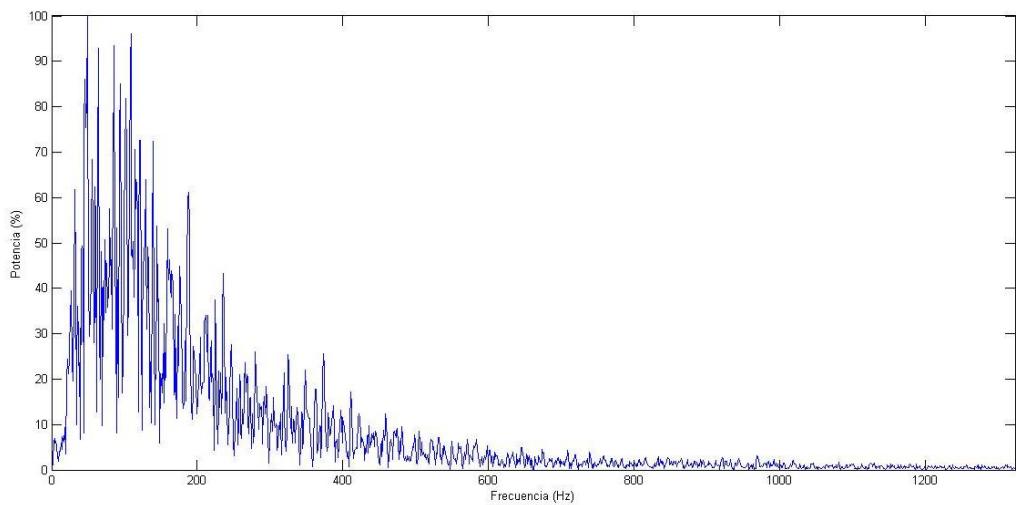


Figura 4-2. Espectro de frecuencia de un registro de EMG.

Las señales de sEMG correspondientes a los tres tipos de movimientos por clasificar: Dorsiflexión, Flexión y Extensión, fueron adquiridas usando los cuatro canales del hardware de adquisición. Los electrodos de superficie fueron colocados sobre los músculos *Vastus Medialis* (Azul), *Semimembranosus* (Cian), *Vastus lateralis* (Rojo) y *Biceps Femoris*, (Verde), figuras 4-3 y 4-4 y 4-5.

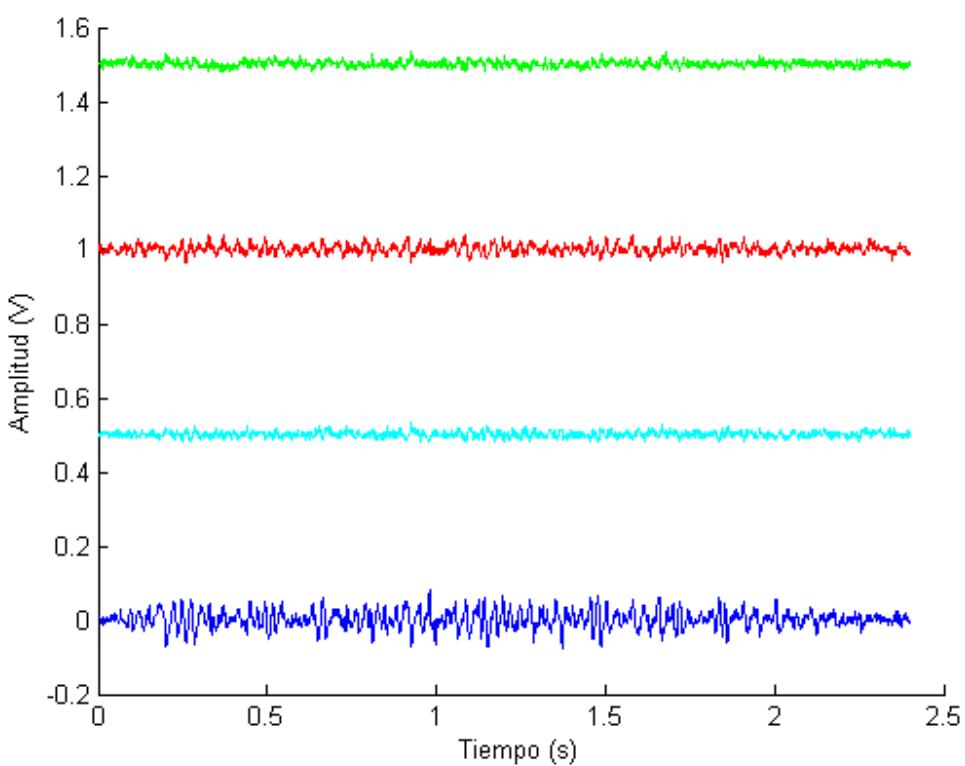


Figura 4-3. Registro simultáneo de los 4 canales de sEMG, movimiento de dorsiflexión.

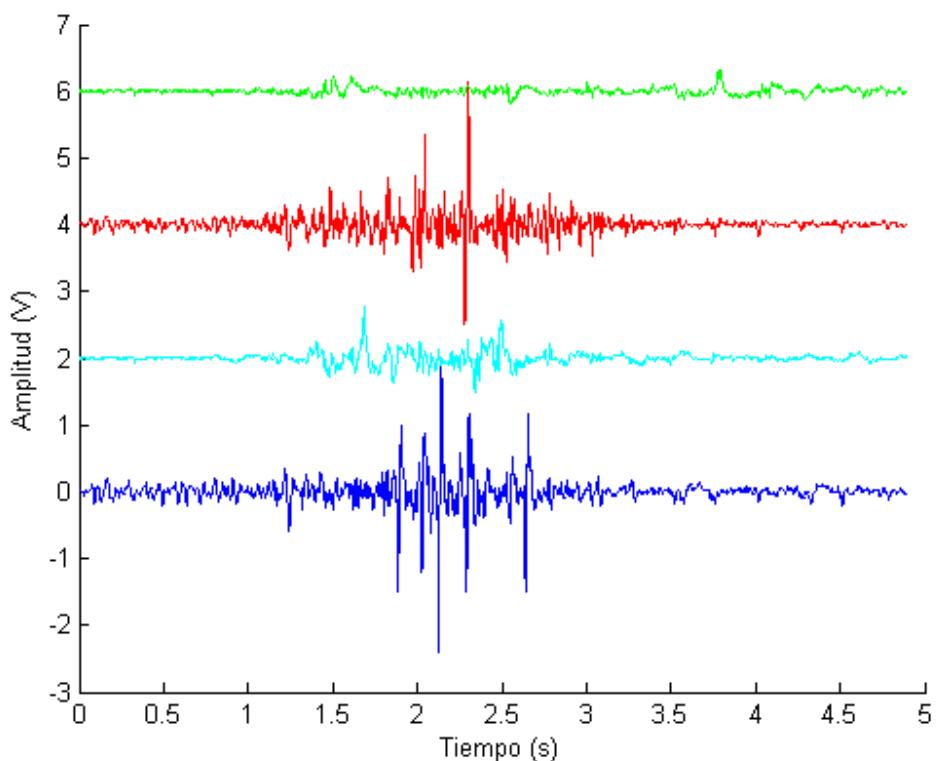


Figura 4-4. Registro simultáneo de los 4 canales de sEMG, movimiento de Extensión.

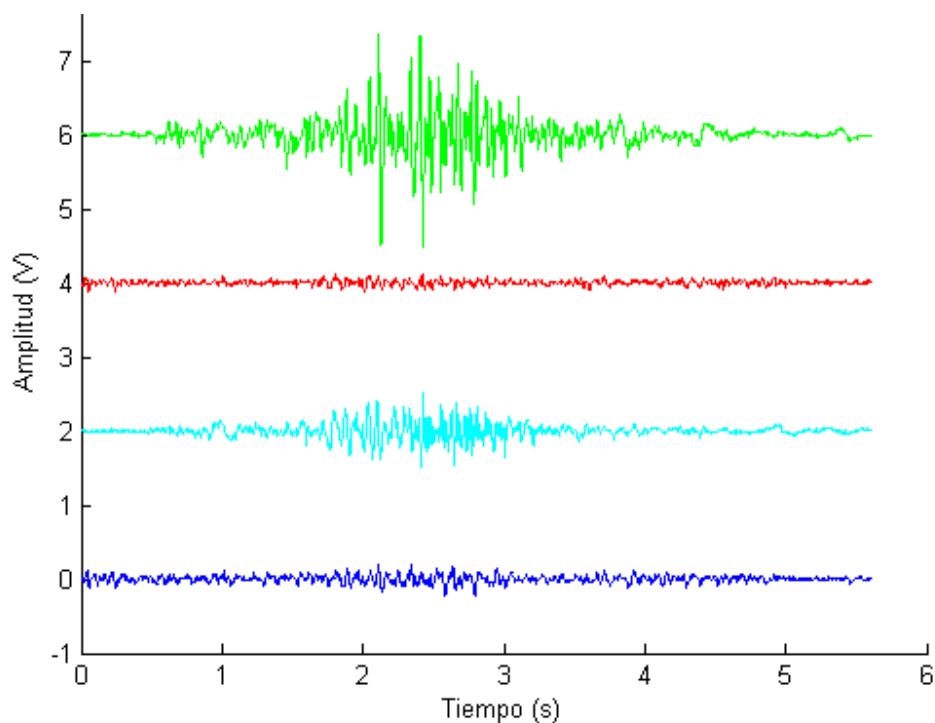


Figura 4-5. Registro simultáneo de los 4 canales de sEMG, movimiento de Flexión.

En las figuras anteriores es posible observar que durante los movimientos de Dorsiflexión y de Extensión, se presenta una alta actividad en los músculos frontales (*Vastus Lateralis* y *Vastus Medialis*). Análogamente, durante el movimiento de Flexión, la mayor actividad de sEMG se encuentra en los músculos posteriores (*Biceps Femoris* y *Semimembranosus*).

Ruidos y Artefactos

El ruido y los artefactos están siempre presentes en los sistemas de adquisición de señales biomédicas. Los artefactos son aquellas perturbaciones que influyen en el registro de las señales, como por ejemplo, el movimiento de los cables o vibraciones producidas por el paciente. El prototipo construido mostró ser demasiado susceptible al ruido generado por el campo magnético que se crea por el espacio existente entre los cables de los electrodos, figura 4-6. El cambio en el campo magnético que pasa a través de esta área induce una corriente eléctrica en el circuito. Una técnica para evitar en cierta medida esta fuente de ruido es por medio del trenzado de cables y procurando que el paciente se encuentre cerca del sistema de adquisición [51].

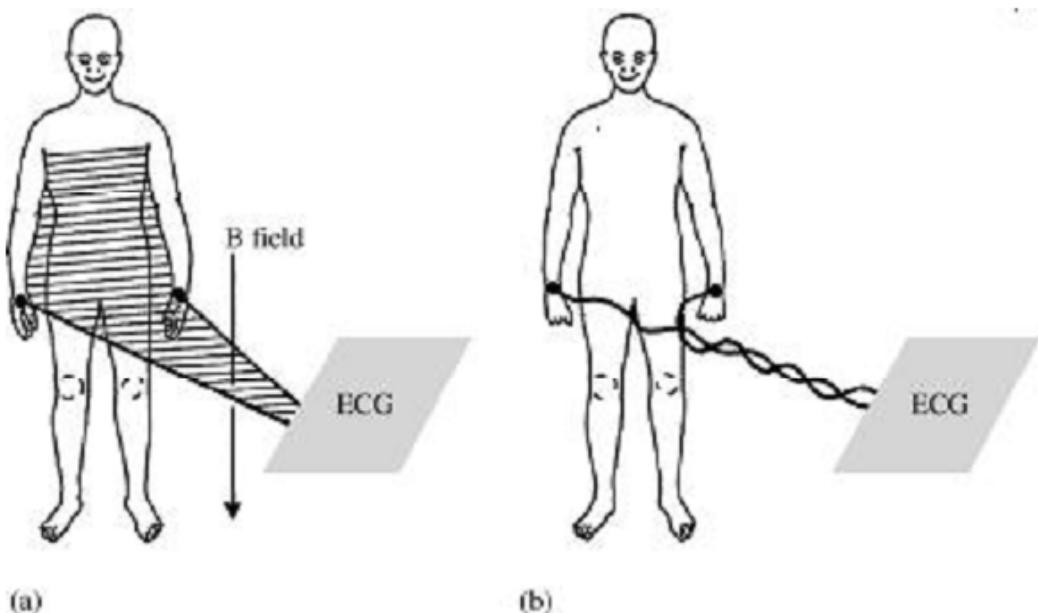


Figura 4-6. Campo magnético recolectado por los cables de adquisición. a) Los cables conductores forman un lazo cerrado (área sombreada) donde el paciente y el dispositivo electrónico son considerados en el circuito. El cambio en el campo magnético que pasa a través de esta área induce una corriente en el lazo. b) Este efecto puede ser minimizado entrelazando los cables y manteniéndolo cerca del cuerpo para reducir el área que se forma entre ellos [51].

Interfaz Gráfica para análisis de patrones de sEMG.

Con la interfaz gráfica desarrollada en Matlab es posible observar el cambio de las características de los 3 diferentes movimientos a clasificar. El espectro de Fourier de las señales de sEMG para los cuatro canales es mostrado a continuación. Claramente es posible observar cómo se distribuye la energía de la señal para cada músculo y varía dependiendo del movimiento realizado.

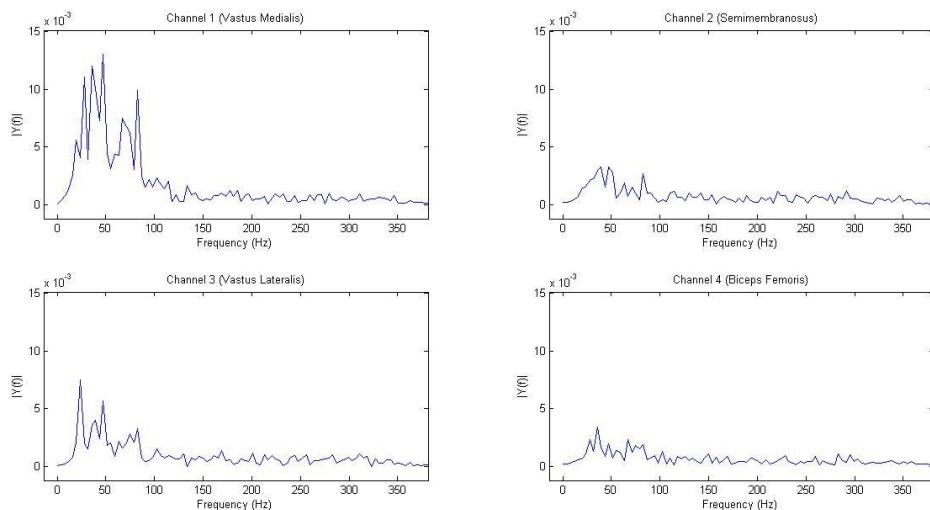


Figura 4-7.Espectro de Fourier para los 4 canales de sEMG, movimiento de Dorsiflexión.

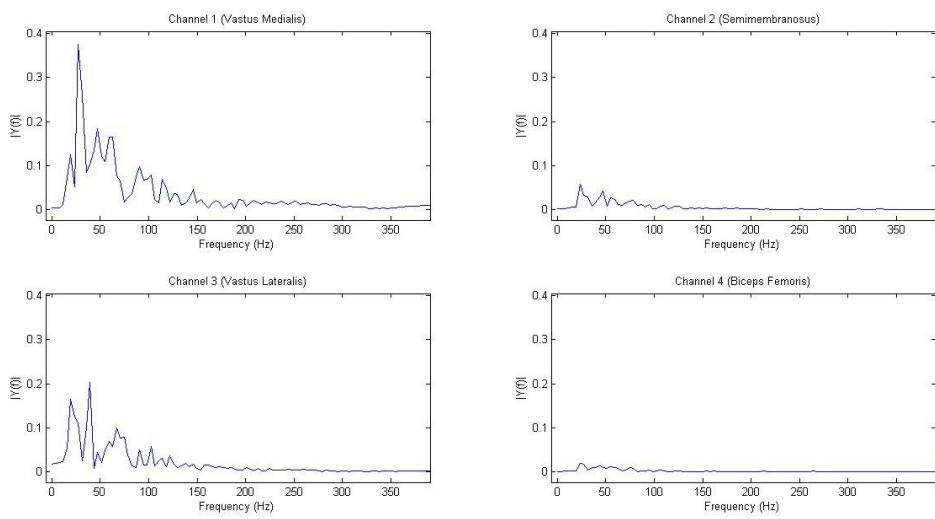


Figura 4-8.Espectro de Fourier para los 4 canales de sEMG, movimiento de Extensión

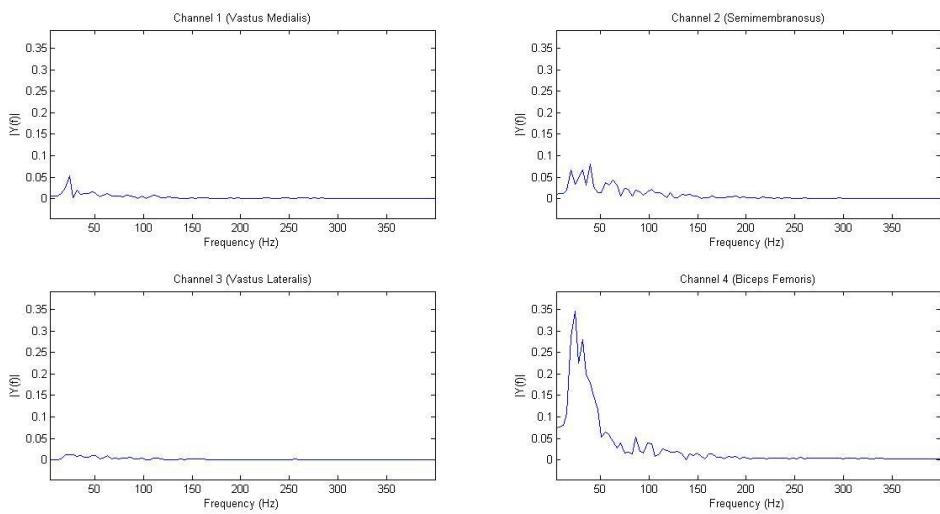


Figura 4-9.Espectro de Fourier para los 4 canales de sEMG, movimiento de Flexión.

Descomposición Modal Empírica y espectro Hilbert

La transformada Hilbert-Huang, es el resultado de aplicar la transformada Hilbert a un grupo de señales obtenidas como resultado de un algoritmo de descomposición. Por otro lado, la Descomposición Modal Empírica (EMD) es un algoritmo iterativo que descompone la señal original en un grupo de señales con características muy particulares conocidas como *Intrinsic Mode Functions* (IMF). Para realizar la transformada Hilbert-Huang se tiene que aplicar la transformada Hilbert a las IMFs obtenidas en el proceso de EMD. Las bibliotecas usadas para el cálculo del espectro de Hilbert y el algoritmo de EMD fueron descargadas de [52]. La interfaz gráfica desarrollada en Matlab cuenta con la opción de calcular y graficar el espectro de Hilbert-Huang. Para probar esta herramienta se realizó el cálculo del espectro de Hilbert de la suma de dos señales senoidales, una de 60Hz y una de 20Hz. En la figura 4-10 es posible observar como los componentes de frecuencia se encuentran ubicados en los 20 y 60Hz lo cual corresponde a los armónicos de la señal de prueba: $y = \sin(60t) + \sin(20t)$. La figura 4-11 muestra la descomposición modal empírica de un registro de sEMG. A continuación, se procedió a graficar el espectro de Hilbert-Huang de las señales de sEMG de cada músculo para cada uno de los tres movimientos (dorsiflexión, flexión y extensión de pierna).

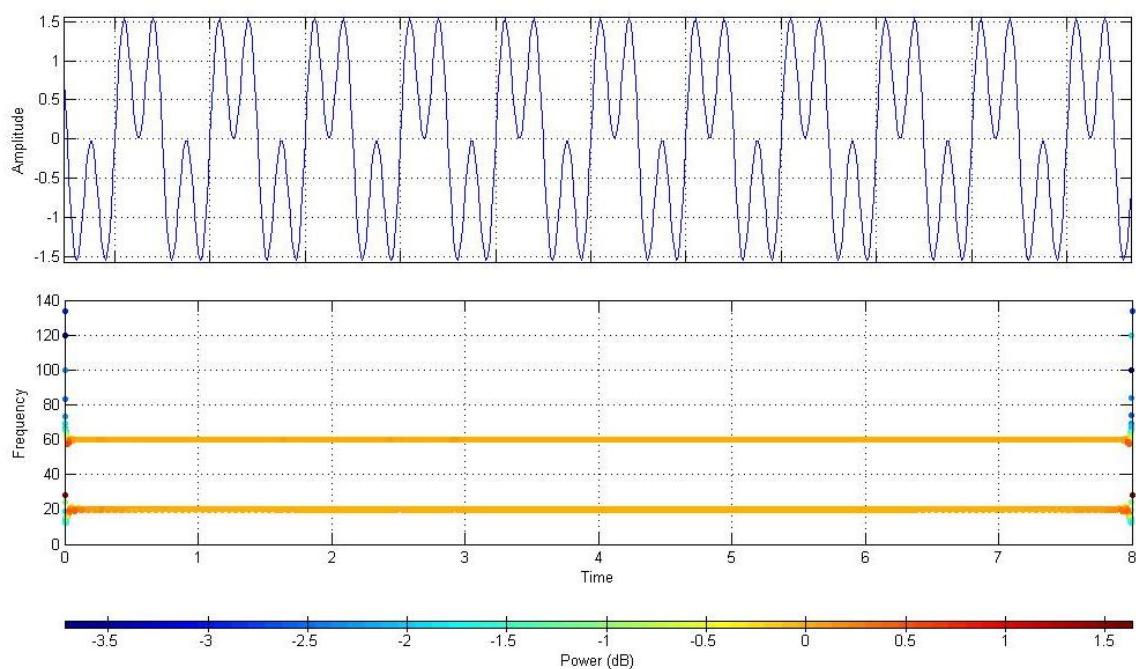


Figura 4-10. Espectro Hilbert-Huang de la señal $y = \sin(60t) + \sin(20t)$. El espectro muestra los dos componentes de frecuencia localizados en los 20 y 60Hz, lo que corresponde con la señal de prueba.

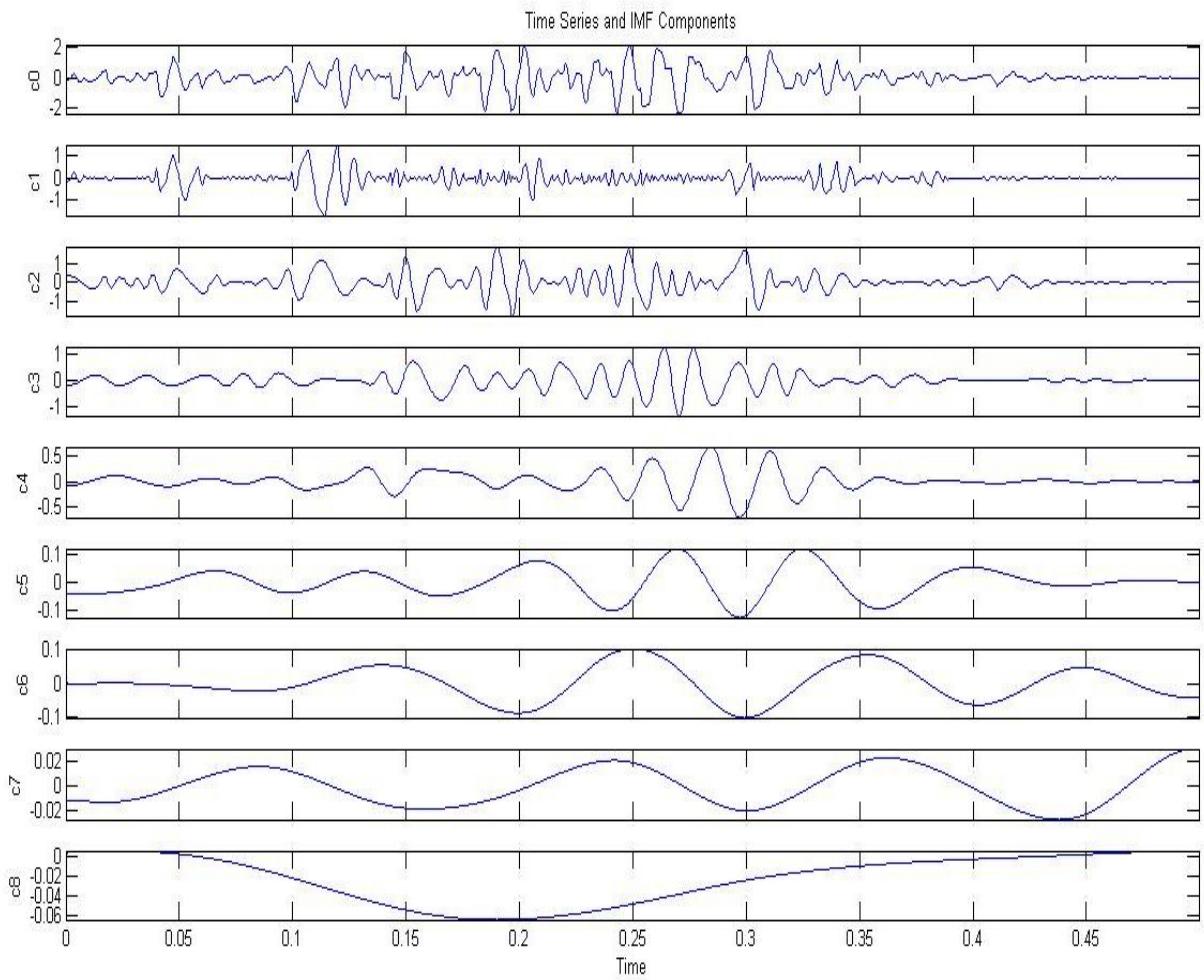


Figura 4-11. Descomposición Modal Empírica de un registro de sEMG en 6 componentes o IMFs.

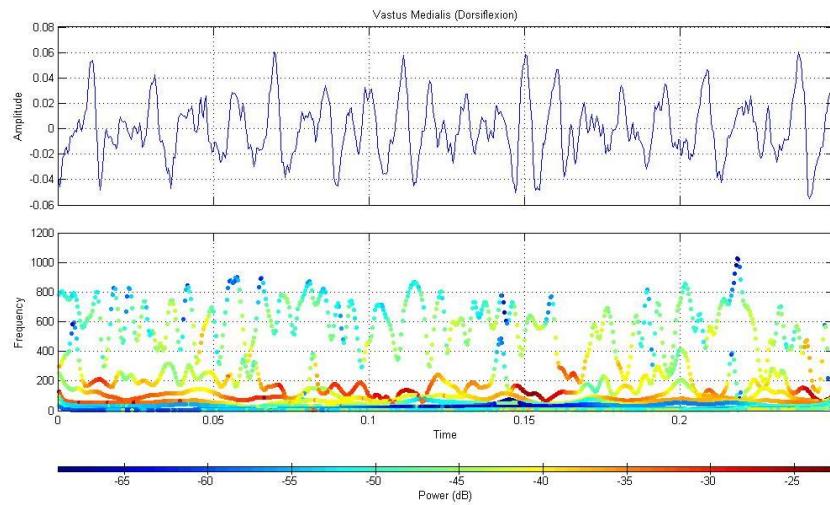


Figura 4-12. Espectro Hilbert de las señales de sEMG provenientes del *Vastus Medialis* durante el movimiento de Dorsiflexión.

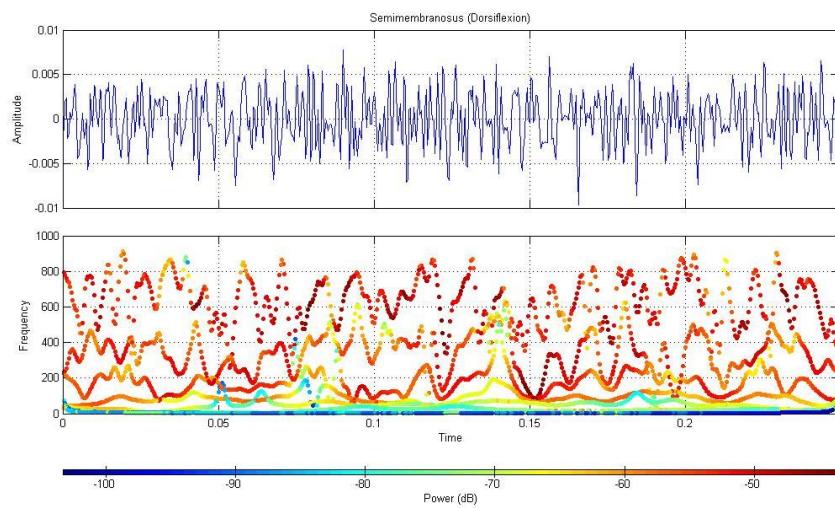


Figura 4-13. Espectro Hilbert de las señales de sEMG provenientes del *Semimembranosus* durante el movimiento de Dorsiflexión.

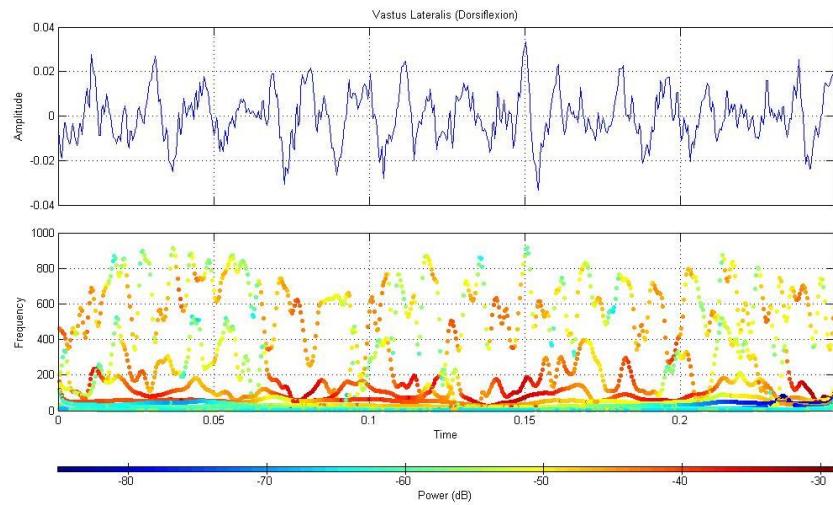


Figura 4-14. Espectro Hilbert de las señales de sEMG provenientes del *Vastus Lateralis* durante el movimiento de Dorsiflexión.

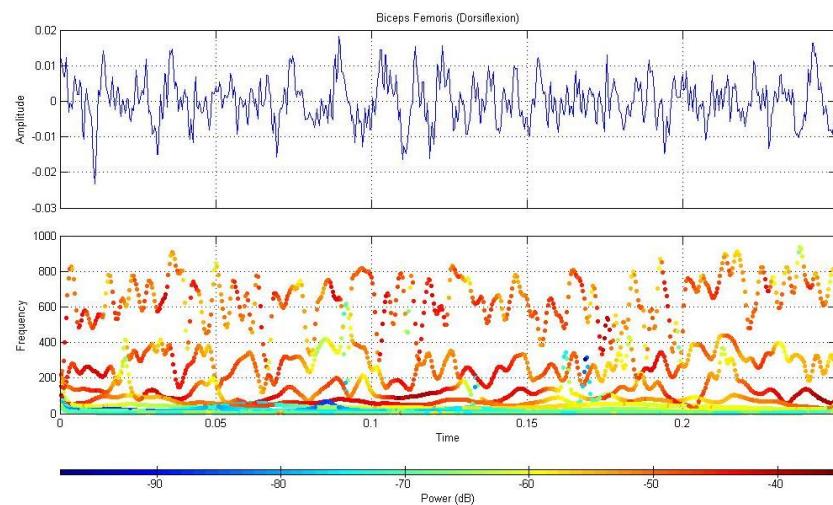


Figura 4-15. Espectro Hilbert de las señales de sEMG provenientes del *Biceps Femoris* durante el movimiento de Dorsiflexión.

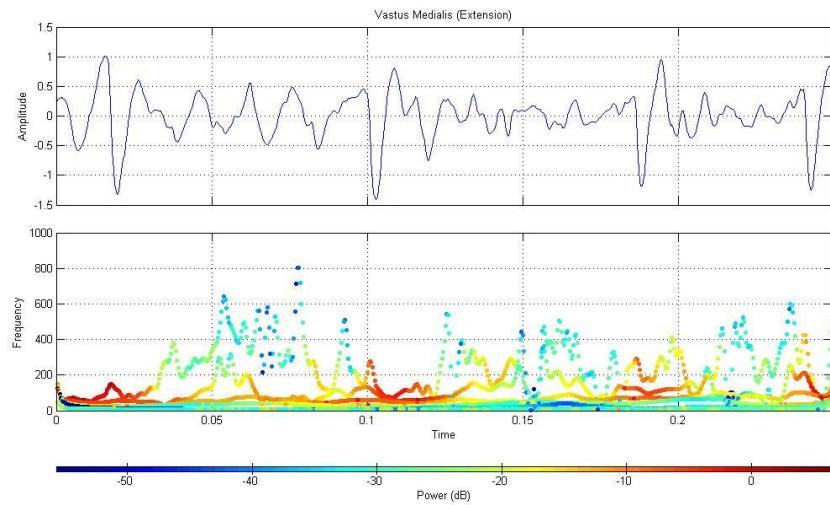


Figura 4-16. Espectro Hilbert de las señales de sEMG provenientes del *Vastus Medialis* durante el movimiento de Extensión.

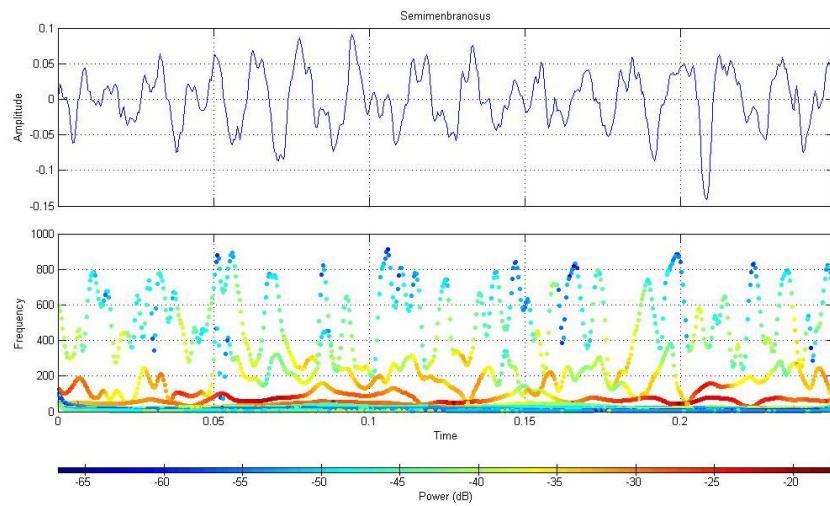


Figura 4-17. Espectro Hilbert de las señales de sEMG provenientes del *Semimembranosus* durante el movimiento de Extensión.

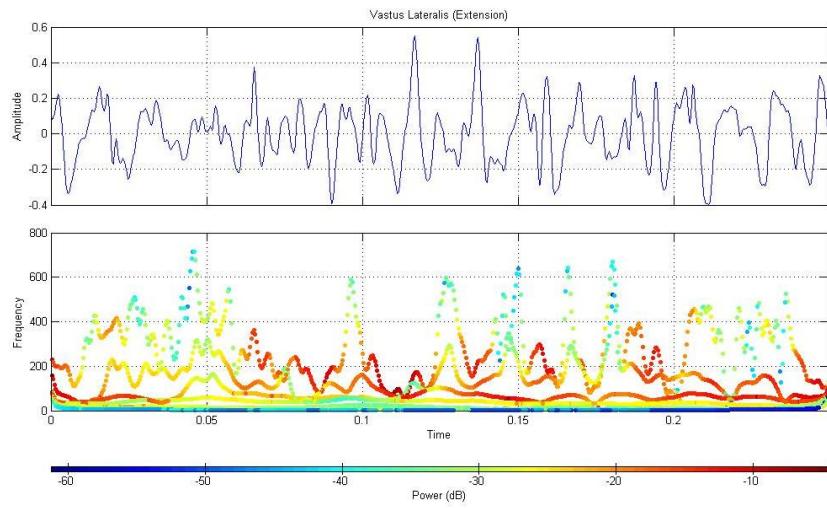


Figura 4-18. Espectro Hilbert de las señales de sEMG provenientes del *Vastus Lateralis* durante el movimiento de Extensión.

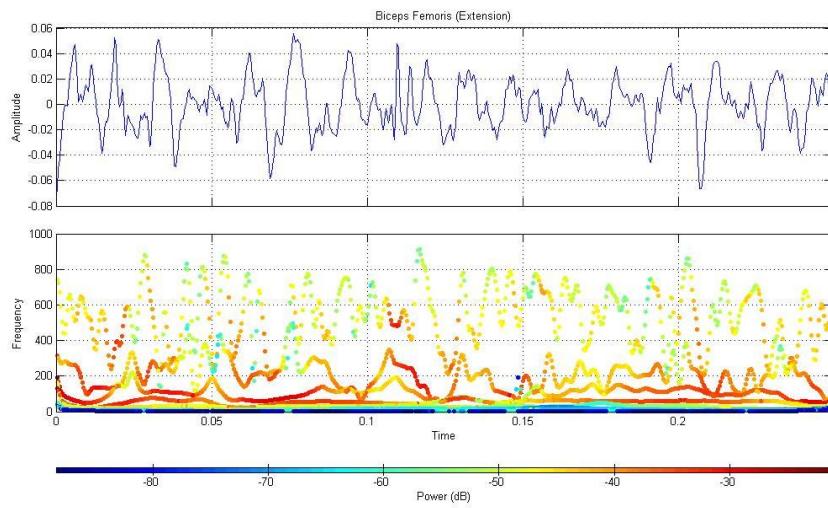


Figura 4-19. Espectro Hilbert de las señales de sEMG provenientes del *Biceps Femoris* durante el movimiento de Extensión.

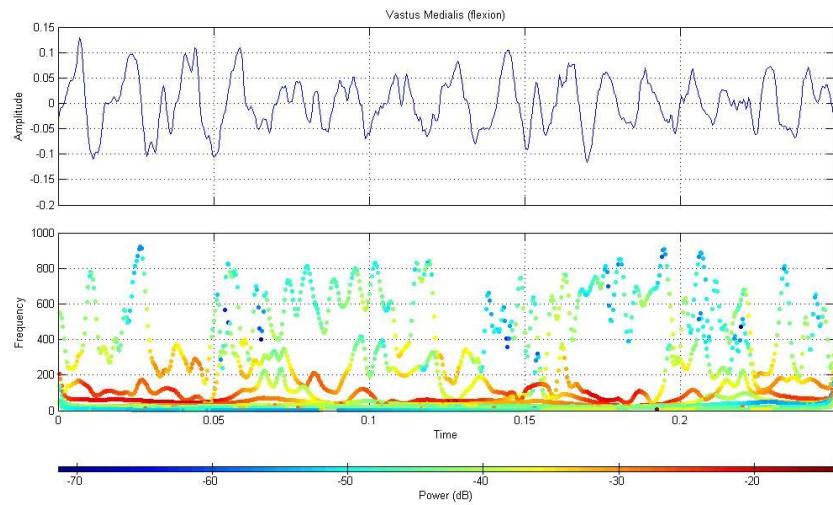


Figura 4-20. Espectro Hilbert de las señales de sEMG provenientes del *Vastus Medialis* durante el movimiento de Flexión.

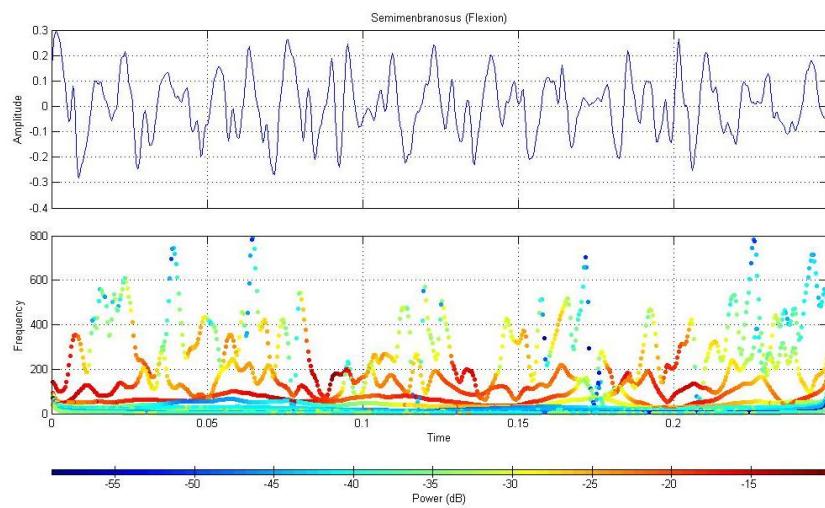


Figura 4-21. Espectro Hilbert de las señales de sEMG provenientes del *Semimembranosus* durante el movimiento de Flexión.

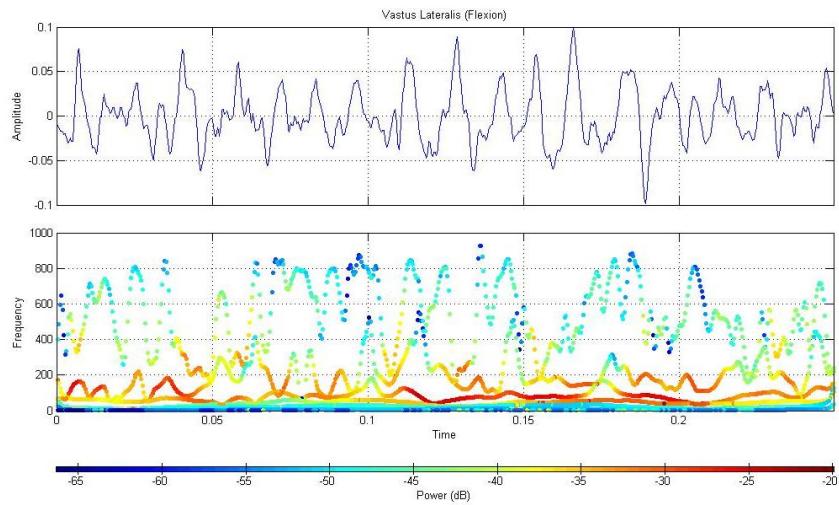


Figura 4-22.Espectro Hilbert de las señales de sEMG provenientes del *Vastus Lateralis* durante el movimiento de Flexión.

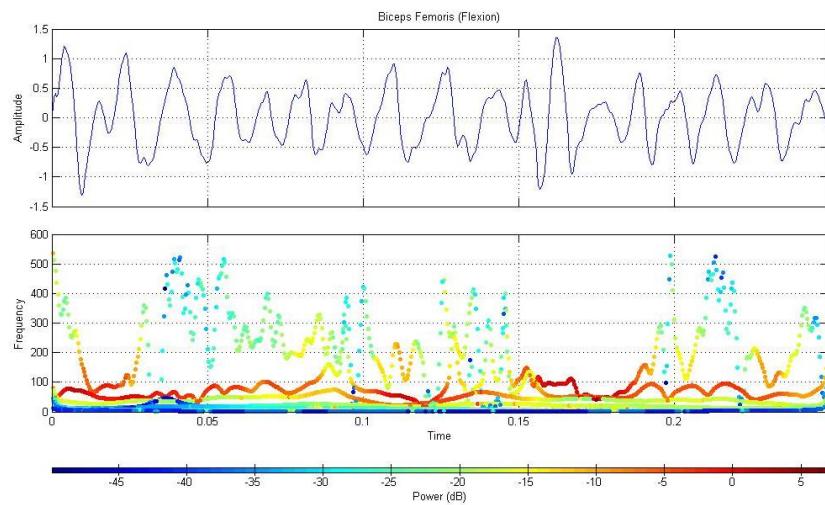


Figura 4-23.Espectro Hilbert de las señales de sEMG provenientes del *Biceps Femoris* durante el movimiento de Flexión.

4.2.2 Extracción de Características

En la etapa de extracción de características se utilizaron dos tamaños de ventanas temporales, una de 100ms y una de 250ms. El tipo de segmentación usado fue del tipo disjunta. Los vectores de características usados en el ejercicio de clasificación son mostrados en la tabla 4-2. Para el caso del FV12 se utilizó el árbol de descomposición con la transformada wavelet discreta con tres niveles de descomposición usando la Daubechies de orden siete como Wavelet madre.

Tabla4-2. Vectores de características usados en el reconocimiento de patrones de sEMG.

	Características
FV1	MAV, RMS, STD, VAR, WL, ZC
FV2	MAV, RMS, ZC, WL
FV3	MAV, RMS, VAR, STD
FV4	VAR, STD, ZC, WL
FV5	MAV, WL, STD
FV6	MAV, ZC, STD
FV7	RMS, ZC
FV8	RMS, WL
FV9	RMS, STD
FV10	RMS, HHAF
FV11	RMS, MNIF
FV12	RMS (CA3,CD3, CD2,CD1), STD (CA3,CD3, CD2,CD1)

4.2.3 Clasificación

Para la clasificación de patrones se optó por usar un clasificador el cual pueda ser implementado en hardware para aplicaciones en tiempo real. Finalmente, se prefirió trabajar con Redes Neuronales debido a su capacidad de adaptación y su gran popularidad en el área de reconocimiento de patrones en señales biomédicas [43, 47, 48]. Un problema presente en el diseño de las redes neuronales es el número de capas ocultas y el número de neuronas en estas capas. En este trabajo se hicieron pruebas con una Red Neuronal con una sola capa oculta pero variando el número de neuronas en esta capa. Primero con igual número de neuronas que en la capa de entrada (N) y posteriormente con el doble de esta cantidad ($2N$). La red neuronal fue entrenada con el algoritmo de *backpropagation*. La función de activación usada en la capa oculta y en la capa de salida fue la *tangent sigmoid*. El conjunto de entrenamiento está formado por 60 registros, 20 por cada patrón, mientras que para el conjunto de prueba se obtuvieron 15 registros en total, 5 por cada patrón. La tabla 4-3 muestra un resumen de los porcentajes de clasificación obtenidos.

Tabla 4-3. Porcentajes de clasificación obtenidos con la Red Neuronal. (Promedio de 10 entrenamientos)

Classification percentage (Average %)		100ms	250ms
FV1	N	96.33	98.83
	2N	91.50	95.5
FV2	N	89.08	97.41
	2N	94.58	95.33
FV3	N	92	95.33
	2N	96.83	98.99
FV4	N	91.33	96.33
	2N	88.41	95.66
FV5	N	98.9	99.66
	2N	92.33	92.91
FV6	N	98.58	99.24
	2N	95.24	95.83
FV7	N	96.08	96.58
	2N	99.08	94.83
FV8	N	98.66	95.24
	2N	90.83	92.08
FV9	N	95.165	95
	2N	92.41	92.41
FV10	N	93.24	95.3
	2N	89.33	85.58
FV11	N	96	95.58
	2N	96.49	95.08
FV12	N	94.49	94.25
	2N	93.33	90.49

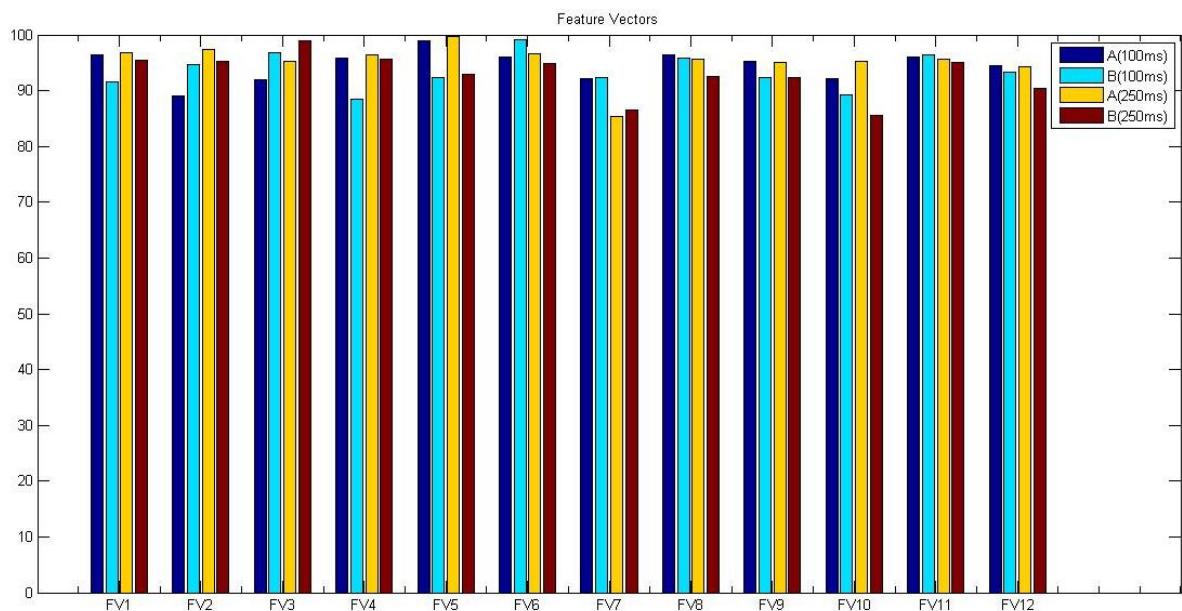


Figura 4-24. Porcentaje de clasificación (promedio sobre 10 entrenamientos de la Red Neuronal). Para N número de neuronas en la capa oculta (A). Para 2N número de neuronas (B) y para cada ventana temporal (100 y 250 ms) respectivamente.

Es posible observar que ciertas características se muestran sensibles a cambios en cuanto al tamaño de las ventanas temporales. Tal es el caso del ZC, que ha resultado ser una característica bastante buena para la ventana temporal de 100ms pero ha bajado su desempeño para el caso de la ventana temporal de 250ms. También es posible observar que el FV11 con la MNIF se muestra más estable a los cambios del tamaño de la ventana temporal y al número de neuronas en la capa oculta de la Red Neuronal. Este vector de características ha mostrado ser mejor que el vector basado en la Transformada Wavelet Discreta. Esto es debido a que es posible obtener un mayor porcentaje de clasificación con menos características (8 para el caso del FV11 y 32 en el caso del FV12). De esta forma, la MNIF ha mostrado ser una herramienta útil y confiable en el reconocimiento de patrones en las señales de sEMG.

4.3 Método II: Estimación de ángulo y velocidad durante la flexión y extensión de la pierna

Este método consiste en realizar una estimación del ángulo de flexión de la pierna usando redes neuronales y fue desarrollado en conjunto con el equipo de investigación del laboratorio de ingeniería biomédica de la Universidad de Roma TRE como resultado de una estancia de investigación supervisada por Ph.D. Silvia Conforto. Las señales de sEMG registradas con el Electromiógrafo inalámbrico BTS FreeEMG correspondientes a los ejercicios de extensiones isométricas y dinámicas son mostradas en las figuras 4-25 y 4-26. Para el entrenamiento de la Red Neuronal se han usado los registros de las señales de sEMG correspondientes tanto a las flexiones isométricas, como a las dinámicas. Las señales de sEMG fueron registradas sobre 3 músculos: *Rectus Femoris*, *Vastus Lateralis* y *Vastus Medialis*. Las señales fueron adquiridas de tres sujetos sanos cuyas edades oscilan entre los 25-35. Posteriormente se realizó la digitalización de las señales con una frecuencia de muestreo de 1kHz con 12 bits de resolución usando la tarjeta NIUSB6009 de National Instruments. Posteriormente a la digitalización, se procedió a realizar un filtrado digital usando un filtro Butterworth pasa bandas (30-350Hz) de orden 4. Así mismo, las señales fueron normalizadas usando el mayor valor del la muestra de la señal en el intervalo de [-1,1].

Se decidió usar dos tipos de vectores de características. El primero (FV1), compuesto por RMS, MAV, STD y WL. El segundo (FV2) formado por RMS, MAV y STD. Como Salida u objetivo de la Red Neuronal se utilizó un vector formado por el ángulo central ($\bar{\theta}$) y por la velocidad angular ($\dot{\theta}$).

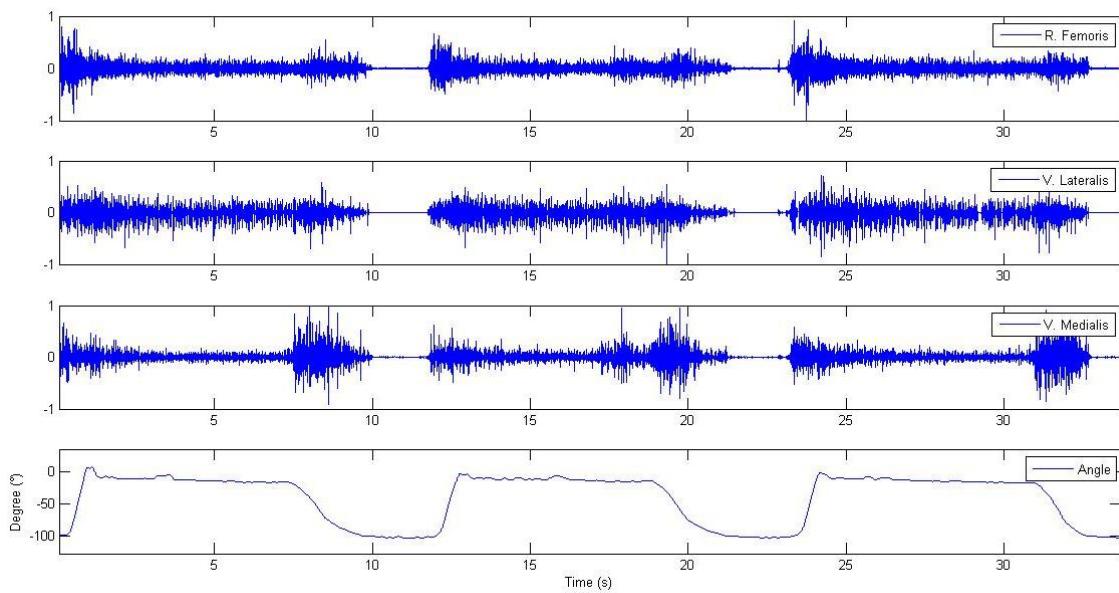


Figura 4-25.Registros de sEMG correspondientes a las flexiones isométricas.

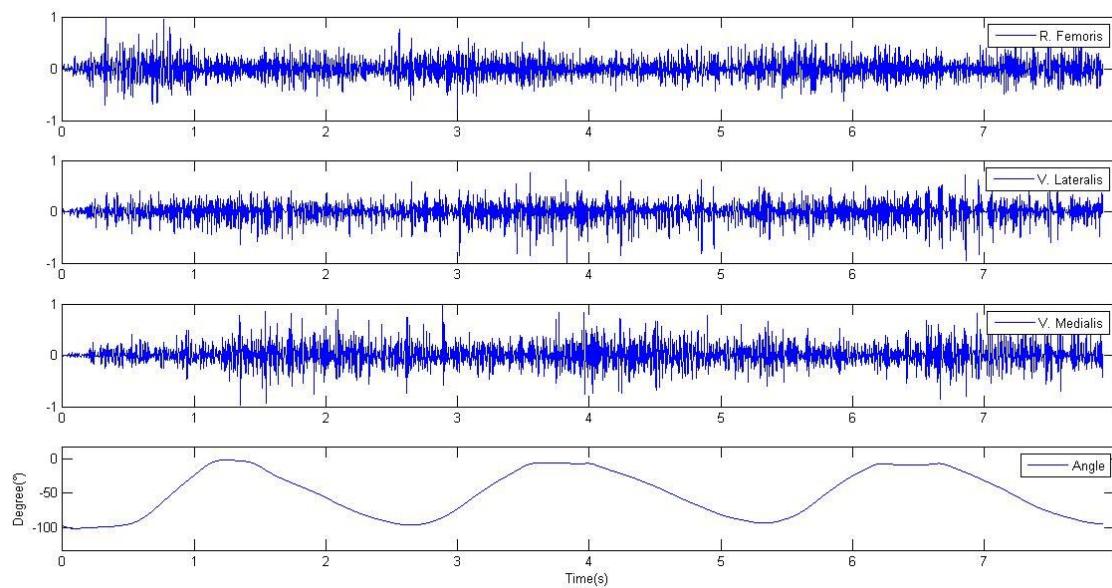


Figura 4-26.Registros de sEMG correspondientes a las flexiones dinámicas.

Fatiga muscular

La fatiga muscular representa un gran problema debido a que genera cambios en la frecuencia y en la amplitud de las señales de sEMG. La figura 4-27 muestra la comparación del espectro de Fourier para un registro de sEMG proveniente del músculo *Rectus Femoris* con y sin presencia de fatiga muscular. Es posible observar cómo se presenta la comprensión del espectro. En la figura 4-27 y 4-28 se muestra el espectro de Hilbert-Huang de la misma señal.

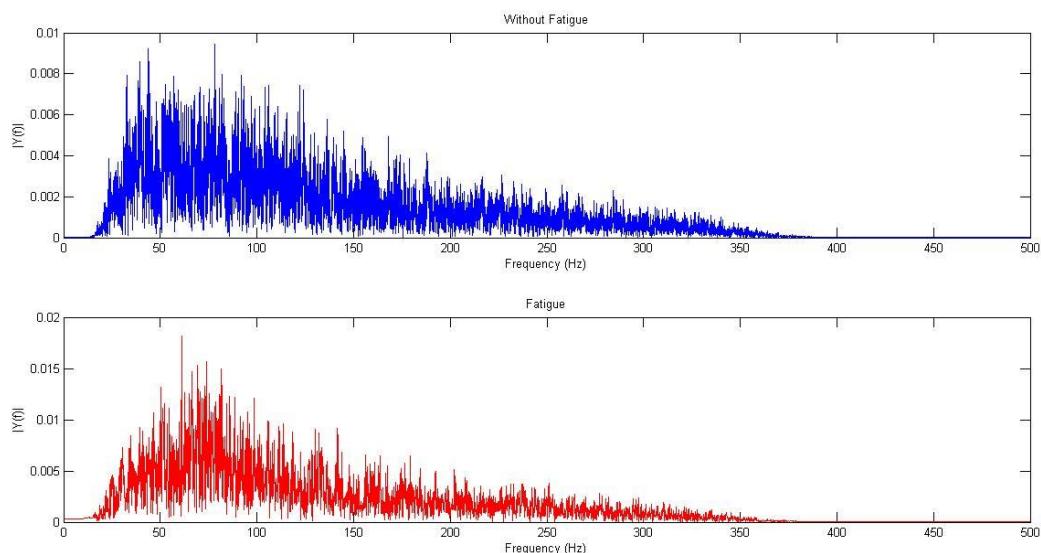


Figura 4-26. Espectro de Fourier de la señal de sEMG filtrada y normalizada del músculo *Rectus Femoris* durante una extensión isométrica de pierna a) sin fatiga muscular, b) con fatiga muscular. Es posible observar cómo se presenta la comprensión del espectro de frecuencia y el cambio en la amplitud de la señal bajo condiciones de fatiga.

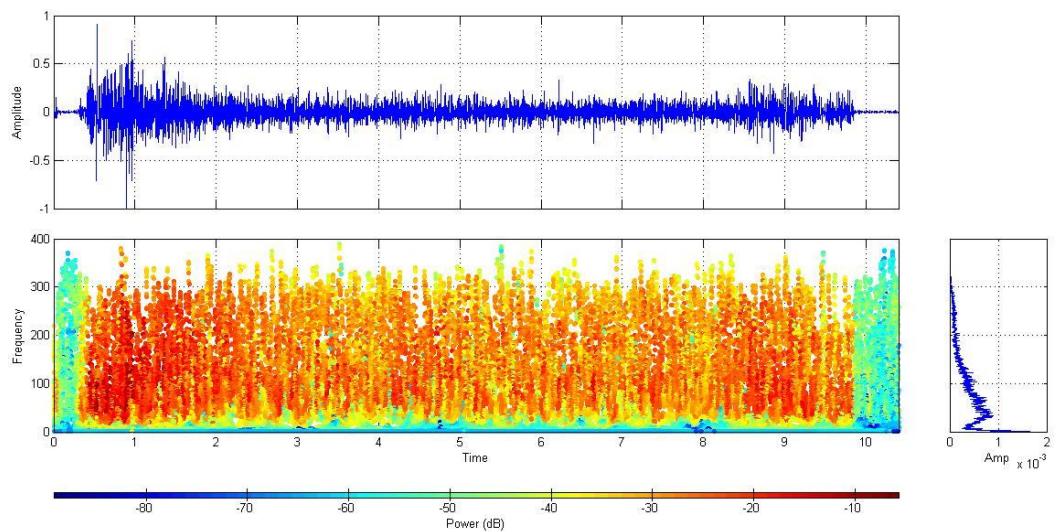


Figura 4-27. Espectro Hilbert-Huang de la señal de sEMG del músculo *Rectus Femoris* durante una extensión isométrica sin fatiga muscular.

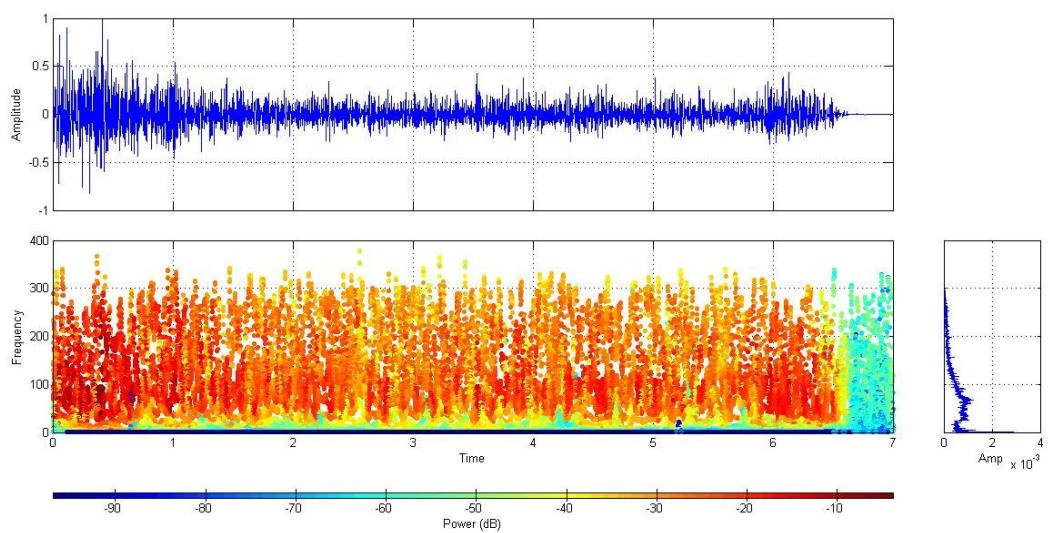


Figura 4-28. Espectro Hilbert-Huang de la señal de sEMG del músculo *Rectus Femoris* durante una extensión isométrica con fatiga muscular.

Para evaluar el rendimiento de los vectores de características se usaron las siguientes medidas: el error medio relativo (RMSE) y el coeficiente de correlación (CC) [15].

$$RMSE = \sqrt{\frac{\sum_{i=1}^N |x(i) - y(i)|^2}{N}} \times 100\% \quad 4.1$$

$$CC = \frac{\sum_{i=1}^N (x(i) - \bar{x}) * (y(i) - \bar{y})}{\sqrt{\sum_{i=1}^N (x(i) - \bar{x})^2 * \sum_{i=1}^N (y(i) - \bar{y})^2}} \quad 4.2$$

Donde $x(i)$ representa la posición angular medida, $y(i)$ es la posición angular estimada. \bar{x} y \bar{y} corresponden a la media del valor real y el valor estimado respectivamente. Para la evaluación [53] sugiere una excelente predicción si: $RMSE(\%) < 15\%$ y $CC > 0.9$. Las predicciones fueron probadas usando señales de sEMG que no pertenecen al conjunto de datos de entrenamiento. Se ha entrenado la Red Neuronal usando datos sin fatiga muscular. Las pruebas de estimación se han hecho usando datos con y sin fatiga muscular para poder observar los cambios que se presentan bajo estas condiciones. Los porcentajes promedios de error de posición y velocidad angular obtenidos para los dos vectores de características durante 5 entrenamientos de la Red Neuronal son mostrados en la tabla 4-4 y tabla 4-5. Las figuras 4-29 y 4-30 muestran las graficas del RMS y CC obtenidos de los movimiento dinámicos. El FV2 ha demostrado ser ligeramente mejor que el FV1.

Tabla 4-4. Valores promedios de RMSE y CC para la posición angular obtenidos con la Red Neuronal para los tres sujetos. (Promedio de 5 entrenamientos)

Posición Angular		Isométrico				Dinámico			
		Sin Fatiga		Con Fatiga		Sin Fatiga		Con Fatiga	
		FV1	FV2	FV1	FV2	FV1	FV2	FV1	FV2
Sujeto1	RMSE(%)	11.2402	11.3853	20.522	20.2959	15.0192	15.072	26.488	24.799
	CC	0.9653	0.9553	0.8826	0.8838	0.9025	0.9003	0.6714	0.7398
Sujeto2	RMSE(%)	10.8703	9.5518	13.0202	14.5112	11.7790	12.0478	19.3283	19.2288
	CC	0.9204	0.9393	0.8920	0.8724	0.9172	0.9102	0.7436	0.7458
Sujeto3	RMSE(%)	8.3351	8.0336	9.7301	9.1113	7.4209	7.6804	11.3474	9.4456
	CC	0.9714	0.9806	0.9670	0.9749	0.9752	0.9755	0.9295	0.9597

Tabla 4-5. Valores promedios de RMSE y CC para la velocidad angular obtenidos con la Red Neuronal para los tres sujetos. (Promedio de 5 entrenamientos)

Velocidad Angular		Isométrico				Dinámico			
		Sin Fatiga		Con Fatiga		Sin Fatiga		Con Fatiga	
		FV1	FV2	FV1	FV2	FV1	FV2	FV1	FV2
Sujeto1	RMSE(%)	32.1369	32.5948	45.8513	38.5261	85.6508	105.07	130.448	131.489
	CC	0.6986	0.7134	0.3910	0.6173	0.3952	0.1369	-0.2847	-0.0815
Sujeto2	RMSE(%)	45.699	47.7057	100.253	77.8942	51.0357	49.8096	129.752	117.3343
	CC	0.4663	0.4444	-0.1104	0.0896	0.6944	0.6692	-0.0603	-0.0152
Sujeto3	RMSE(%)	23.6573	24.7029	25.0538	25.3408	28.3206	27.5470	53.0119	52.9409
	CC	0.7097	0.6668	0.6560	0.6416	0.9083	0.9087	0.5640	0.5846

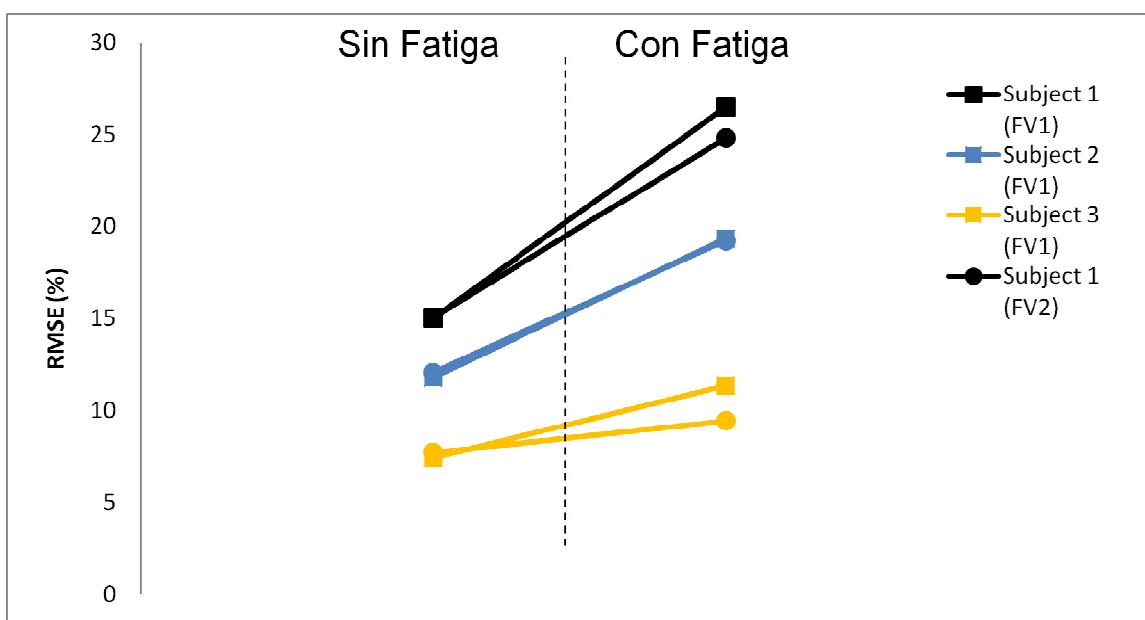


Figura 4-29. Graficas del RMSE correspondiente a los movimientos dinámicos. Es posible observar como el FV2 obtuvo mejor desempeño que el FV1.

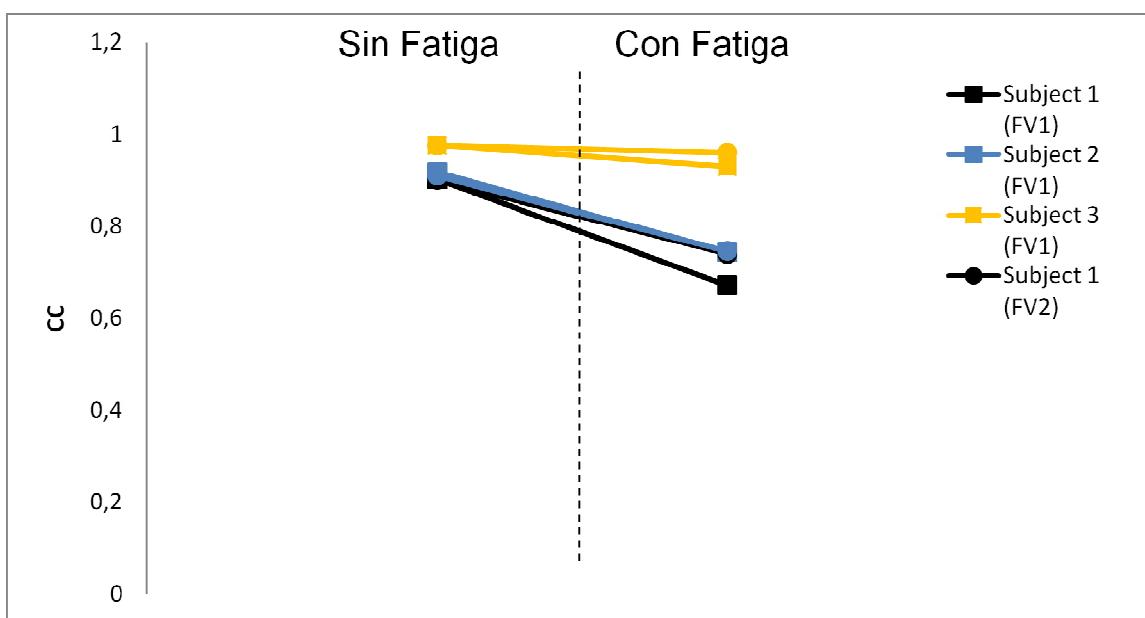


Figura 4-30. Graficas del CC correspondiente a los movimientos dinámicos. Es posible observar como el FV2 obtuvo mejor desempeño que el FV1.

Los resultados obtenidos de las estimaciones de la posición y la velocidad angular muestran una gran variación de sujeto a sujeto. Los mejores resultados fueron obtenidos con los datos del sujeto 3, mientras que el error de estimación para sujeto 2 fue el más elevado. Para el caso de la estimación de la posición angular se obtuvieron excelentes resultados usando los vectores de características propuestos. Sin embargo, para la estimación de la velocidad angular se presentaron valores de RMSE mucho más elevados. Por otro lado, es evidente el incremento del error de estimación bajo condiciones de fatiga muscular. Esto es debido al cambio de las características en frecuencia y en amplitud que sufre la señal de sEMG bajo condiciones de fatiga. A continuación, se presentan los resultados de la estimación realizada por la Red Neuronal para el sujeto 3 usando el vector de características FV2. A continuación se muestran los resultados de estimación obtenidos.

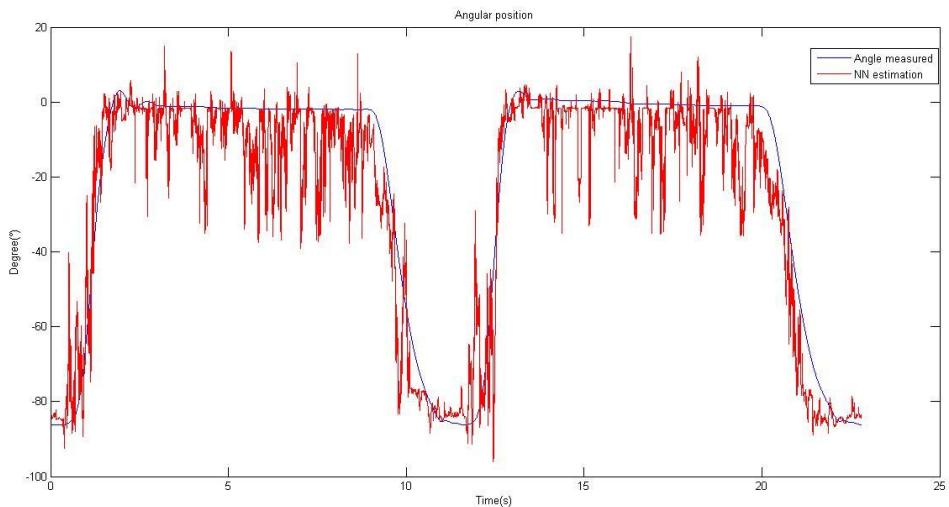


Figura 4-31. Estimación del ángulo de flexión de la pierna durante una contracción isométrica.

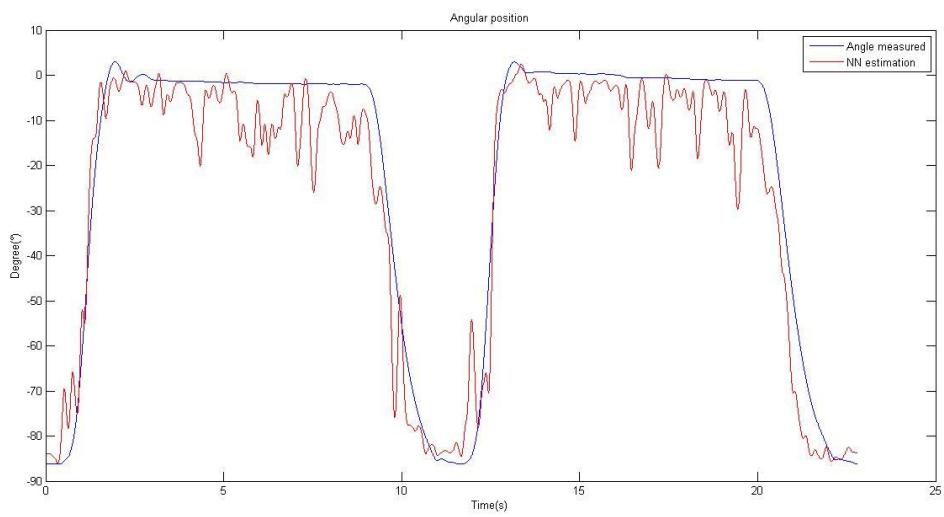


Figura 4-32. Resultado de la estimación del ángulo de flexión de la pierna durante una contracción isométrica luego de aplicar un filtrado pasa-bajas de 4Hz Butterworth de orden 2.

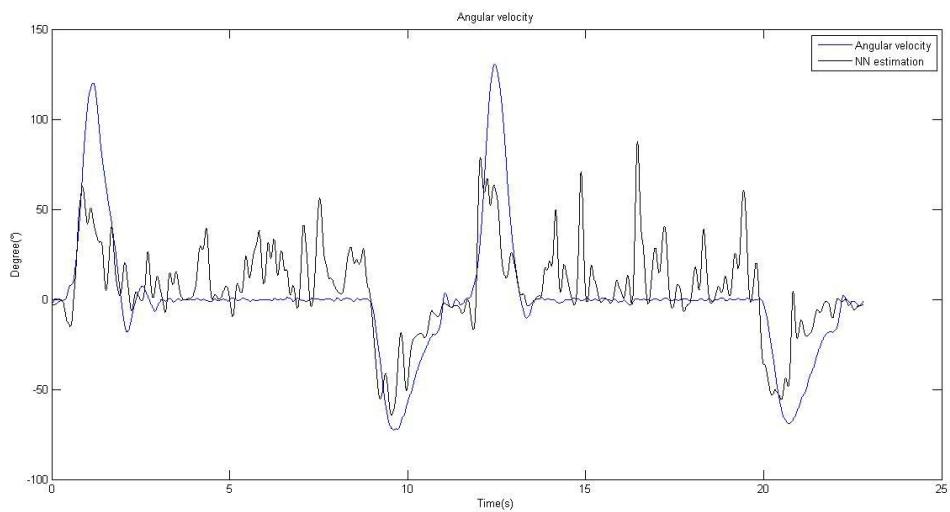


Figura 4-33. Resultado de la Estimación de la velocidad angular durante el ejercicio de flexión isométrica de la pierna, luego de aplicar un filtrado pasa-bajas de 4Hz Butterworth de orden 2

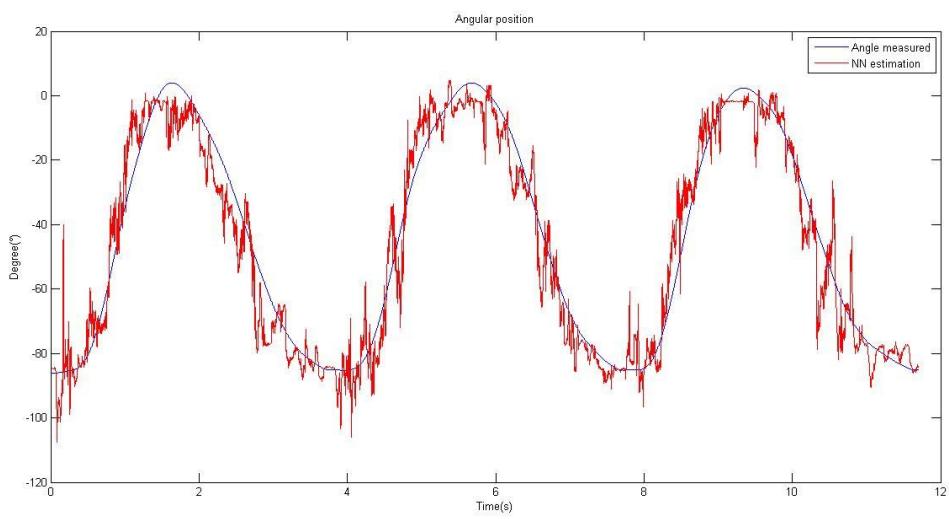


Figura 4-34. Estimación del ángulo de flexión de la pierna durante una contracción dinámica.

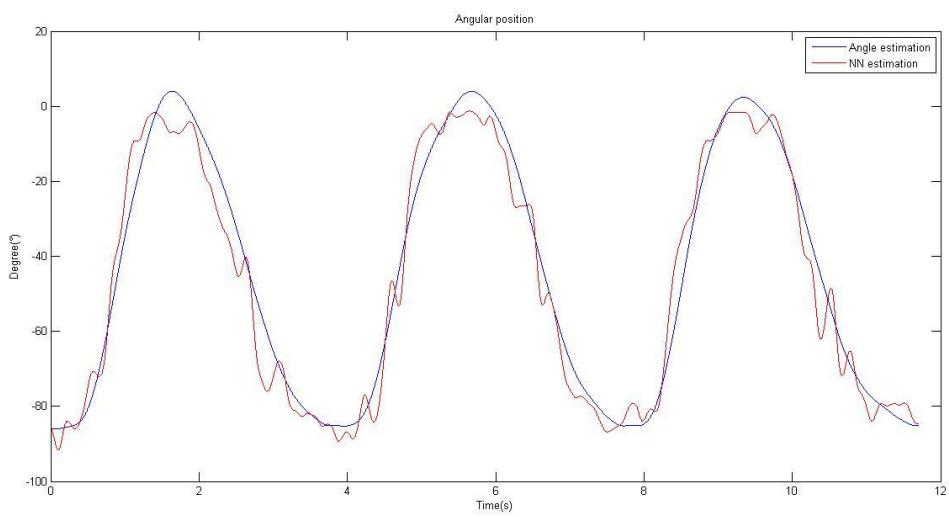


Figura 4-35. Estimación del ángulo de flexión de la pierna durante una contracción dinámica. La señal fue filtrada usando un filtro pasa-bajas de 4Hz Butterworth de orden 2.

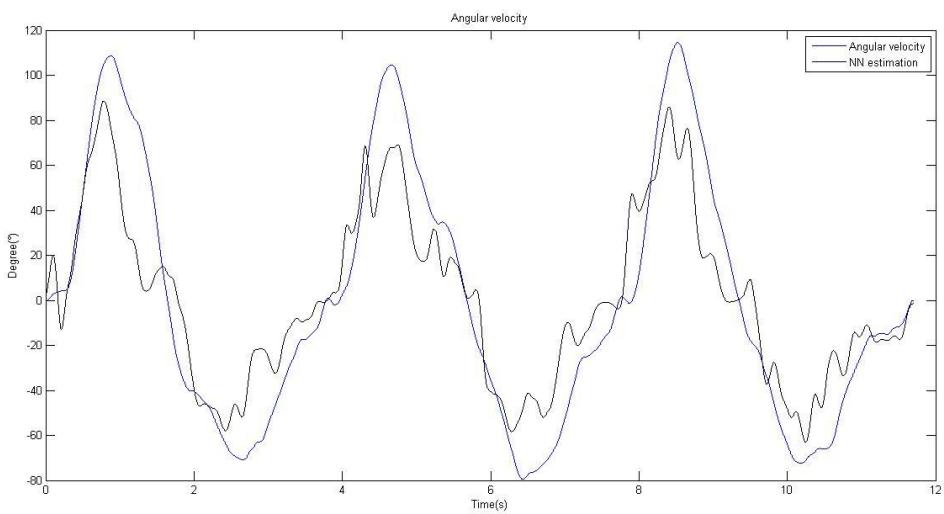


Figura 4-36. Resultado de la Estimación de la velocidad angular durante el ejercicio de flexión dinámica de la pierna,

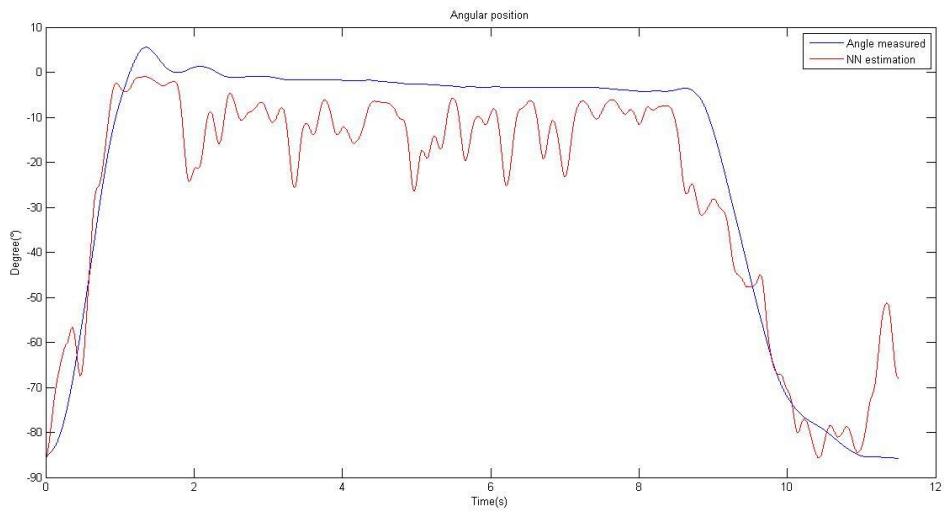


Figura 4-37. Resultado de la estimación del ángulo de flexión de la pierna durante una contracción isométrica bajo condiciones de fatiga muscular.

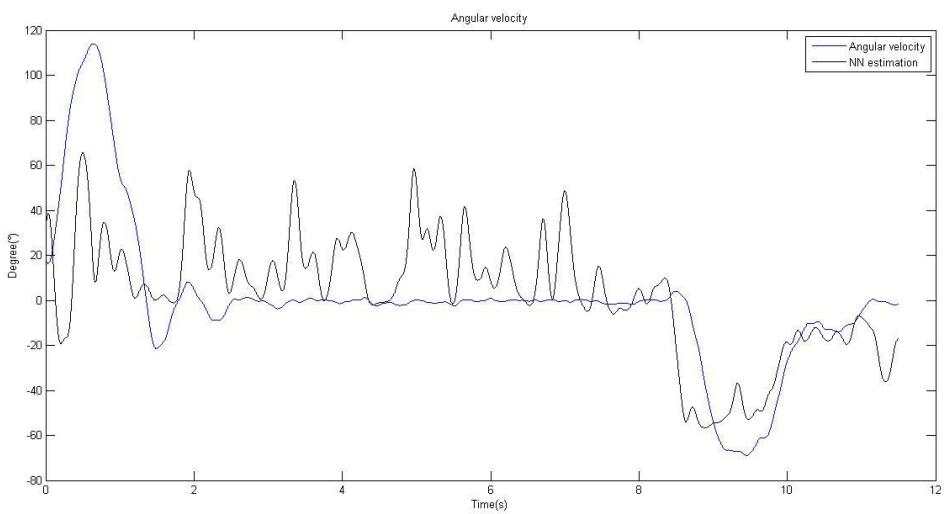


Figura 4-38. Resultado de la estimación de la velocidad angular durante el ejercicio de flexión de isométrica de la pierna bajo condiciones de fatiga muscular.

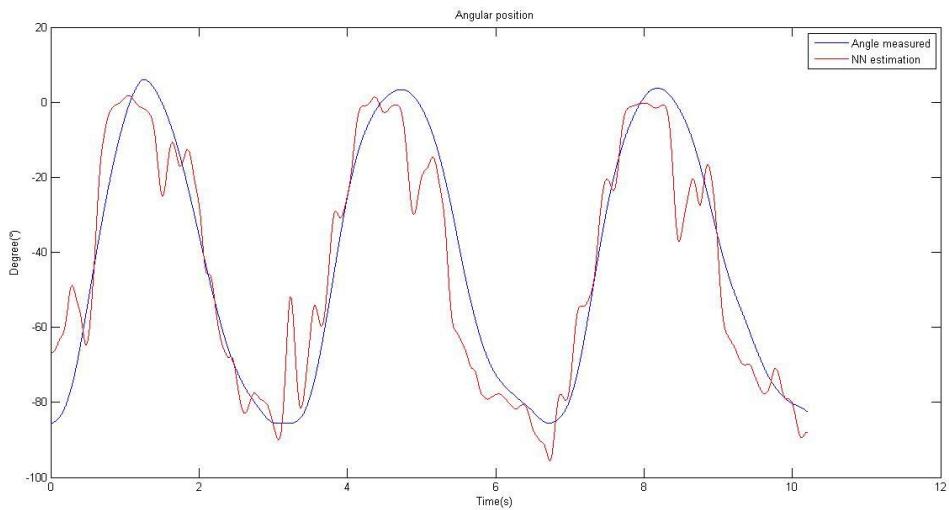


Figura 4-39. Resultado de la estimación del ángulo de flexión de la pierna durante una contracción dinámica bajo condiciones de fatiga muscular.

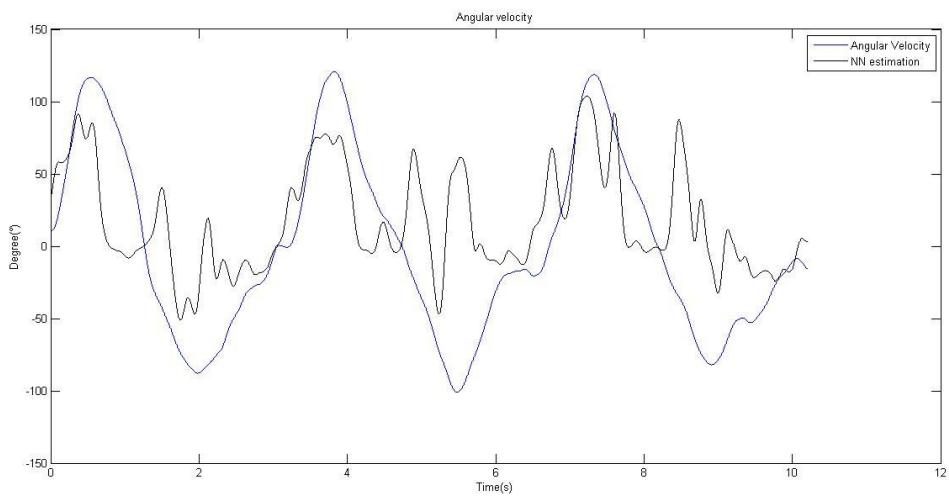


Figura 4-40. Resultado de la estimación de la velocidad angular durante el ejercicio de flexión dinámica de la pierna bajo condiciones de fatiga muscular.

El error de estimación de la velocidad angular ha mostrado ser mucho más elevado que el de la posición angular. Una estrategia para evitar este problema podría ser utilizar solo la información de la posición angular y después de un número determinado de muestras, calcular la velocidad mediante la derivada numérica de la posición angular. El retraso electromecánico ha presentado un incremento el cual fue reflejado en la estimación de la Red Neuronal para ambos casos de movimientos, isométricos y dinámicos, figura 4-41 y figura 4-42. La fatiga muscular hace que la estimación de la red neuronal se adelante al movimiento realizado.

Finalmente, se presenta una imagen comparativa de una señal de sEMG adquirida por el BTS FreeEMG y el prototipo de adquisición de sEMG desarrollado, figura 4-43. Las señales fueron normalizadas y filtradas usando un filtro pasa bandas (30-350 Hz) Butterworth de orden 4.

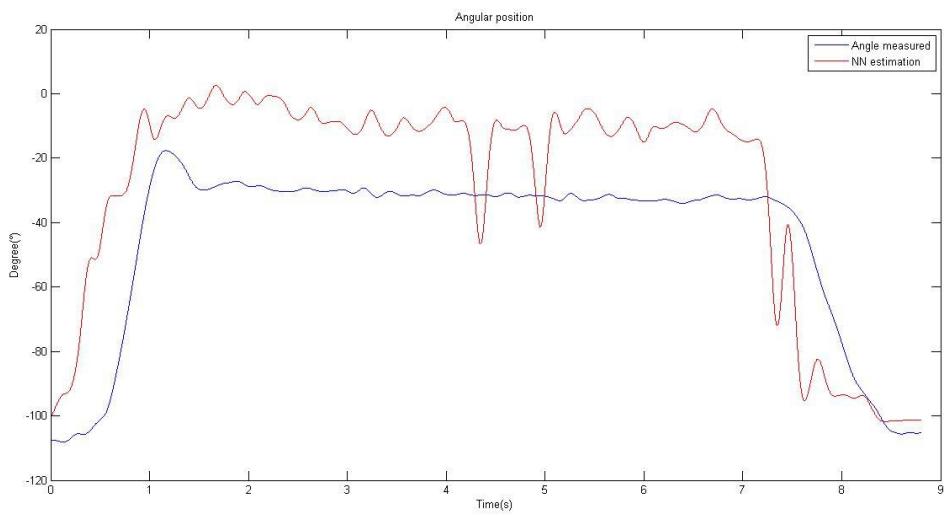


Figura 4-41. Resultado de la estimación de la posición angular durante el ejercicio de flexión isométrica de la pierna bajo condiciones de fatiga muscular (Sujeto 1).

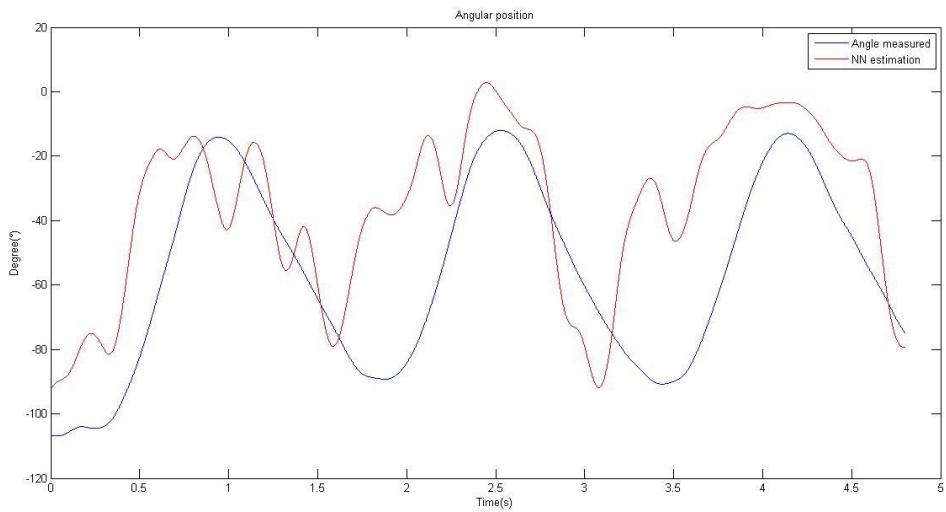


Figura 4-42. Resultado de la estimación de la velocidad angular durante el ejercicio de flexión dinámica de la pierna bajo condiciones de fatiga muscular (Sujeto 1).

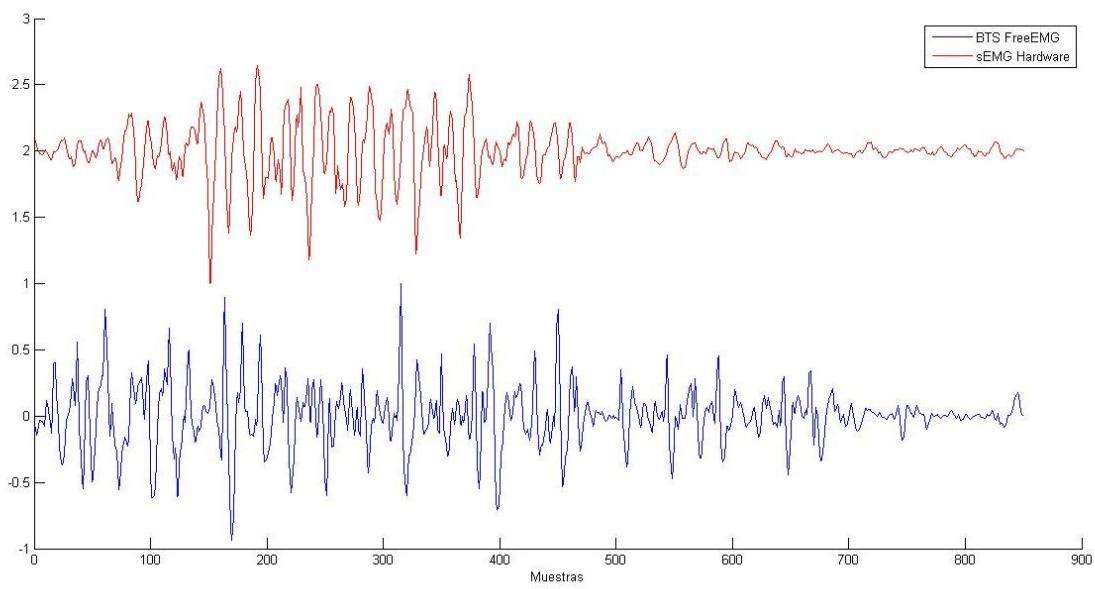


Figura 4-43. Señal de sEMG registrada con el BTS FreeEMG y con el prototipo construido. Las señales fueron normalizadas y filtradas.

Capítulo 5: Conclusiones

5.1 Conclusiones

En este trabajo se presentan dos estrategias para el control de una prótesis transfemoral utilizando Redes Neuronales. La primera estrategia se basa en el reconocimiento de patrones en las señales de sEMG para la identificación de tres movimientos: Dorsiflexión, Flexión y Extensión. El segundo método consiste en realizar una estimación de la posición y velocidad angular durante la flexión y extensión de la pierna. Para el primer enfoque se han evaluado 12 vectores de características usando técnicas en el dominio del tiempo y en el dominio de tiempo-frecuencia. De entre las características de tiempo-frecuencia se destaca el uso de la MNIF, la cual se propone como una nueva característica para la clasificación de patrones en señales de sEMG. Las características extraídas en el dominio del tiempo presentan la ventaja de utilizar mucho menos tiempo de procesamiento a diferencia de las características en tiempo-frecuencia como las basadas en la Transformada Hilbert-Huang y en la Transformada Wavelet Discreta. Se observó que usando la MNIF con la Transformada Hilbert-Huang se obtienen mejores resultados que usando la Transformada Wavelet, además de presentar más tolerancia a los cambios en las ventanas temporales y en el número de neuronas en la capa oculta de la Red Neuronal. La longitud de este vector de características es de solo 8 elementos, a diferencia de los 32 usados en la Transformada Wavelet Discreta. El uso de la Transformada Hilbert-Huang presenta la ventaja de no ser dependiente del problema como es el caso de la DWT con la selección de la Wavelet madre. De esta forma, se propone el vector de características usando la MNIF basada en la HHT como una nueva opción para su uso en el área de reconocimiento de patrones en señales de Electromiografía.

El segundo método se basó en la estimación de la posición y velocidad angular usando únicamente las señales de sEMG como entrada a una Red Neuronal y como objetivo o salida, el ángulo de flexión y la derivada de la posición angular con respecto al tiempo (velocidad angular). Para este trabajo se tomaron en cuenta dos problemas inherentes en las señales de sEMG: el retraso electromecánico y la fatiga muscular. Para tratar con el retraso electromecánico se tomó un adelanto en la salida de la Red Neuronal de 50ms, de esta forma, es posible omitir 50ms del retraso electromecánico y utilizar este tiempo extra como tiempo de procesamiento. Para el caso de la fatiga muscular se hicieron pruebas de clasificación con datos con y sin fatiga con el fin de evaluar el desempeño de la Red Neuronal en el proceso de la estimación bajo estas condiciones. Se hicieron pruebas de estimación con tres sujetos voluntarios entre las edades de 26 ± 4.36 y se analizaron registros de sEMG bajo contracciones isométricas y contracciones dinámicas; de igual manera, se tomaron registros de los mismos movimientos bajo condiciones de fatiga y no fatiga. Los resultados de estimación (errores de estimación) obtenidos variaron ampliamente de sujeto a sujeto debido a la naturaleza estocástica de la señal de sEMG. Para los casos analizados sin fatiga muscular, se han obtenido muy buenos resultados para la estimación de la posición angular; sin embargo, los resultados de estimación para la velocidad angular no fueron muy satisfactorios. Finalmente, se realizaron las mismas pruebas, pero ahora con datos que presentaban fatiga muscular. Los resultados muestran un cambio en el error de estimación haciendo que este se incremente en ambos casos, para la posición y para la velocidad angular. En base a los resultados de estimación obtenidos, es posible concluir que la fatiga muscular representa un serio problema sobre todo para el control de prótesis. En conclusión, se deben de proponer nuevas soluciones que puedan reducir este problema ya que la fatiga muscular siempre estará presente durante el uso de una prótesis y generará un incremento en el error de estimación, lo que ocasionaría muchos problemas al momento de controlar las acciones del dispositivo electromecánico. También se debe hacer un estudio más detallado para tratar de evaluar el comportamiento del retraso electromecánico en condiciones de fatiga.

muscular. Finalmente, se recomienda continuar con el método de la estimación de la posición y velocidad angular ya que provee una forma más completa para realizar el control de la prótesis transfemoral teniendo la posición y la velocidad en el mismo instante de tiempo.

5.2 Trabajo Futuro

Como trabajo Futuro, se plantean los siguientes objetivos:

- Implementación de un segundo prototipo del hardware para la adquisición de señales de sEMG reduciendo el tamaño ocupado por el circuito impreso y reemplazando los componentes pasivos por sus equivalentes de montaje superficial.
- Implementación de la metodología de la estimación de la posición angular en tiempo real y con un sistema basado en un DSP o microcontrolador
- Desarrollar una metodología para evaluar el retraso electromecánico en condiciones de fatiga para el control eficiente de un dispositivo protésico.
- Desarrollar un método para evitar los cambios producidos por la fatiga muscular.
- Realizar pruebas de estimación usando otro tipo de clasificador como podría ser una Maquina de Soporte Vectorial o alguna otra configuración de Redes Neuronales.
- Implementación de todo el sistema en hardware y controlar el movimiento de la prótesis transfemoral.
- Realizar pruebas con pacientes que sufren amputaciones transfemorales.
- Realizar un análisis usando la información de posición, velocidad y fuerza aplicada para proveer así un control mucho más completo.

- Realizar un análisis sobre la marcha humana para poder proveer el control completo de la prótesis y que el paciente pueda moverse de la manera más natural posible.

Referencias

- [1] <http://www.inegi.org.mx>, 14/06/12.
- [2] Patricia Guzmán Jiménez, Dr. Rubén Alejos Palomares, "Diseño y construcción de una prótesis robotizada", Tesis para obtener el grado de ingeniero en Mecatrónica, Universidad de las Américas, Puebla (UDLAP). 2010.
- [3] Mohammadreza Asghari Oskoei, Huosheng Hu, "Review, Myoelectric control systems—A survey", Biomedical Signal Processing and Control, vol 2, pp. 275–294. Julio 2007.
- [4] Sverre Grimnes, Orjan Grottem Martinsen, "Bioimpedance and bioelectricity basics", Academic Press, 1° edición, Abril, 2011.
- [5] Jeffrey R. Cram, Eleanor Criswell, "Introduction to Surface Electromyography", Jones and Bartlett Publishers, Inc. 2nd edición, Marzo 2010.
- [6] Merletti Roberto, "Electromyography - Physiology, Engineering, and Noninvasive Applications", IEEE Press Engineering in Medicine and Biology Society, 2004.
- [7] Hiroshi Kawata, Fumihide Tanaka, AtsuoSuemitsu, and Masahiko Morita, "Practical Surface EMG Pattern Classification by Using a Selective Desensitization Neural Network", ICONIP'10 Proceedings of the 17th international conference on neural information processing: models and applications, vol. 2, pp. 42-49, 2010.
- [8] D. Farina, R. Merletti, "Comparison of algorithms for estimation of EMG variables during voluntary isometric contractions", Journal of Electromyography and Kinesiology 2000, vol. 10, pp. 337-349, 2000.
- [9] <http://www.seniam.org/> , 17/09/12
- [10] Konrad Peter, "The ABC of EMG. A Practical Introduction to Kinesiological Electromyography", Tech. Report Noraxon INC. USA, Abril 2005.
- [11] Carlo J. De Luca, "Surface Electromyography: detection and recording", DelSys Laboratories Technical staff, 2002.

- [12] H. K. Bhullar, G. H. Loundon, J. C. Fothergill, and N. B. Jones, "Selective non invasive electrode to study myoelectric signals", Med. Biol. Eng. Compt., vol 28, pp. 581-590, 1990
- [13] Ericka Janet Rechy-Ramirez and Huosheng Hu, "Stages for Developing Control Systems using EMG and EEG Signals: A survey", School of Computer Science and Electronic Engineering University of Essex, United Kingdom. Technical report: CES-513, ISSN 1744-8050 June, 2011.
- [14] M.A. Oskoei and H. Hu, "Support vector machine-based classification scheme for myoelectric control applied to upper limb", Biomedical Engineering, IEEE Transactions on 2008, vol. 55, pp. 1956–1965, 2008.
- [15] Dennis Tkach, He Huang, and Todd A. Kuiken Tkach, "Study of stability of time-domain features for electromyographic pattern recognition", Journal of NeuroEngineering and Rehabilitation, vol. 7, pp. 7-21, 2010.
- [16] T.W. Beck, M.S. Stock, J.M. Defreitas, "Time-frequency analysis of surface Electromyographic signals during fatiguing isokinetic muscle actions", Journal of Strength and ConditioningResearch, vol 26, pp. 1904-14, 2011.
- [17] Yanjuan Geng, Dandan Tao, Liang Chen1, and Guanglin Li, "Recognition of Combined Arm Motions Using Support Vector Machine", Informatics in Control, Automation and Robotics, Springer, vol. 2, pp. 807–814, 2011.
- [18] N. M. Sobahi, "Denoising of Signals Based on Wavelet Transform", Asian Transactions on Engineering, vol. 1, Issue 05, pp. 17-23, 20011.
- [19] N. E. Huang, Z. Shen, S. R. Long, M. C. Wu, H. H. Shih, Q. Zheng, N. C. Yen, C. C. Tung, and H. H. Liu, "The empirical mode descomposition and the hilbert spectrum for nonlinear and non-stationary time series analysis," in Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences, vol. 454, no. 1971, pp.903–995, 1998.
- [20] HongboXie, Zhizhong Wang, "Mean frequency derived via Hilbert-Huang transform with application to fatigue EMG signal analysis", Computer Methods and Programs in Biomedicine, vol. 82, issue 2, pp. 114-120, 2006.
- [21] Cong Zong and Mohamed Chetouani, "Hilbert-Huang transform based physiological signals analysis for emotion recognition", International Symposium on Signal processing and information Technology, (ISSPIT), pp. 334-339, 2009.
- [22] S. Haykin. "Neural Networks – a Comprehensive Foundation".Prentice hall, 2ndedicion 1999.

- [23] H. Li, L. Yang, and D. Huang, "Application of Hilbert-huang transform to heart rare variability analysis", the 2nd International Conference on Bioinformatics and Biomedical Engineering, pp. 648-651, 2008.
- [24] JANG, J-S. "Neuro-Fuzzy Modeling: Architecture, Analyses and Applications". PhD dissertation, Dept. Elect. Eng., California Univ., Berkeley, CA, 1992.
- [25] P. Nilas, P. Rani, N. Sarkar, "An innovative high-level human-robot interaction for disabled persons, Proceedings of the IEEE international Conference on Robotics and Automation, vol. 3, pp. 2309-2312, 2004.
- [26] Camilo Sandoval Rodríguez, Rodolfo Villamizar Mejía, Eusebio Delgado Velosa, Andrés Cordero Cardozo. "Estimación de velocidad del movimiento de una mano usando redes neuronales artificiales y mediciones electromiográficas". Revista Ingeniería Biomédica, vol 4, no 8, pp. 41-56, 2012.
- [27] L. Hargrove, K. Englehart and B. Hudgins, "A training strategy to reduce classification degradation due to electrode displacements in pattern recognition based myoelectric control", Journal Biomedical Signal Processing and Control, vol. 3, pp. 175-180, 2008.
- [28] M. Vuskovic and S. J. Du, "Classification of prehensile EMG patterns with simplified fuzzy ARTMAP networks," in Proc. Int. Joint Conf. Neural Networks, vol. 3, pp. 2539–2544, 2002.
- [29] Rami N. Khushaba, Adel Al-Jumaily. "Fuzzy Wavelet Packet based Feature Extraction Method for Multifunction Myoelectric Control". International Journal of Biological and Life Sciences, vol. 2, pp. 186, 2006.
- [30] Ganesh R. Naik and Dinesh Kumar, "Blind Source Separation Based Classification Scheme for Myoelectric Prosthesis Hand". Intelligent Mechatronics, 2011.
- [31] J. Jeong, W. Cho, Y. Kim, and H. Choi, "Recognition of lower limb muscle EMG patterns by using neural networks during the postural balance control," in 3rd Kuala Lumpur International Conference on Biomedical Engineering 2006, ser. IFMBE Proceedings, Springer Berlin Heidelberg, vol. 15, pp. 82–85, 2007.
- [32] F.H.Y. Chan, Y.S. Yang, F.K. Lam, Y.T. Zhang, and P.A. Parker. "Fuzzy EMG Classification for Prosthesis Control", IEEE Trans. Rehabilitation Eng., vol. 8, pp 305-311, 2000.
- [33] Alcimar Soares, Adriano Andrade, Edgard Lamounier, Renato Carrijo, "The Development of a Virtual Myoelectric Prosthesis Controlled by an EMG Pattern Recognition System Based on Neural Networks", Journal of Intelligent Information Systems, vol 21, pp. 127–141, 2003.

- [34] A. Phinkymark, C. Limsakul, P. Phukpattaranont, "Application of Wavelet analysis in EMG Feature Extraction for Pattern Classification", Measurement Science Review, vol 11 No. 2, pp. 45-52, 2011.
- [35] Punzón M. Rubén, Orozco G. Alvaro, Castellanos D. German, "Caracterización Multicanal no lineal de señales EMG con la Transformada Hilbert-Huang", Scientia et Technica XV, No. 41, pp. 36-41, Mayo 2009.
- [36] Carreño Ignacio, VuskovichMarko, "Wavelet Transform Moments for Feature Extraction form Temporal Signals", Informatics in control, automation and robotics II 2007, part 3, vol 2, pp. 235-242, 2007
- [37] G.T Yamaguchi, A.G. Sawa, D. W. Moran, M.J. Fessler, J.M. Winters, "A Survey of Human Musculo-tendon Actuator Parameters", In J. Winters and S.L.-Y. Woo, editors, Multiple Muscle Systems: Biomechanics and Movement Organization, Springer-Verlag, vol 2, pp. 717-773, 1990.
- [38] Massimo Sartori, DaetanoChemello, MonicaReggiani, Enrico Pagello, "Control of a Virtual Leg via EMG Signals From Four Thigh Muscles", Intelligent Autonomous Systems 10, vol 10, pp. 137-144, 2008.
- [39] Enrique Mario Spinelli, Ramon Pallás-Areny, Miguel Angel Mayosky, "AC-Coupled Front-End for Biopotential Measurements", IEEE Trans. on Biomedical Engineering, vol. 50, No. 3, pp. 391-395, Marzo 2003.
- [40] Basañez Márquez Marisol, "Diseño e Implementación de un Sistema de Adquisición, Procesamiento y Clasificación de Señal Mioeléctrica para Prótesis Transhumeral de Tres Grados de Libertad", Tesis de maestría, Instituto Nacional de Astrofísica, Óptica y Electrónica, 2008.
- [41] Adel S. Sedra, Kenneth C. Smith, Jorge Humberto Romo Núñez, "Circuitos Microelectrónicos". 4º Edición, Oxford UniversityPress, 1999.
- [42] S. Conforto, P. Mathieu, M. Schmid, D. Bibo, J.R. Florestal, T. D'Alessio, "How much can we trust the electromechanical delay estimated by using electromyography?", Proceedings of the 28th IEEE, EMBS Annual International Conference, New York City, USA, pp. 1256-1259, 2006.
- [43] Li Dapeng, Zhang Yaxiong, "Artificial Neural Network Prediction of Angle Based on surface Electromyography", Control, Automation and Systems Engineering (CASE), 2011 International Conference, pp 1-3, 2011.
- [44] Deepak Joshi, A. Mishra, Sneha Anand, "ANFIS based Knee angle prediction: An approach to design speed adaptive contra lateral controlled AK prosthesis", Applied Soft Computing, vol 11, pp 4757-4765, 2011.
- [45] Alberto LópezDeliz, J. L. Azevedo de Carvalho, GeovanyAraújo Borges, Suélia de Siqueira Rodrigues, Icaro dos Santos, Adson Ferreira da Rocha, "Fusion of Electromyographic Signals with Proprioceptive Sensor Data in Myoelectric Pattern Recognition for Control of Active Transfemoral Legs

Prostheses", 31st Annual International Conference of the IEEE EMBS Minneapolis, Minnesota, USA, pp. 4755-4758, 2009.

- [46] Christian Antfolk, Christian Cipriani, Marco Controzzi, Maria Chiara Carrozza, G. Lundborg, Brigitte Rosén, F. Sebelius, "Using EMG for Real-time Prediction of Joint Angles to Control a Prosthetic Hand Equipped with a Sensory Feedback System", Journal of Medical and Biological Engineering, vol 30, pp 399-406, 2010.
- [47] Feng Zhang, Pengfeng Li, Zeng-Guang Hou, Zhen Lu, Yixiong Chen, Qingling Li, Min Tan, "sEMG-based continuous estimation of joint angles of humans legs by using BP neural network", Neurocomputing, Volumen 78, issue 1, pp. 139-148, 2012.
- [48] Patrik Kutilek, Barbora Farkasova, "Prediction of lower extremities movement by angle-angle diagrams and neural networks", Acta of Bioengineering and Biomechanics vol. 13 No. 2, pp. 57-65, 2011.
- [49] <http://perso.ens-lyon.fr/patrick.fladrin/emd.html>, 14/08/12.
- [50] <http://www.newark.com> , 03/09/12
- [51] John G. Webster, "Medical Instrumentation, Application and Design", 3rd ed. New York: John Wiley&Sons, 1998.
- [52] <http://software.seg.org>, 03/09/12
- [53] Guo JY, Zheng YP, Xie HB, Koo TK, "Towards the application of one-dimensional sonomyography for powered upper-limb prosthetic control using machine learning models", Prosthetics and Orthotics International, 2012.
- [54] <http://es.wikipedia.org>, 14/11/12
- [55] <http://ti.com>, 14/11/12
- [56] <http://biomecanica2011.wordpress.com/2011/03/> , 14/11/12